UNIVERSIDAD MAYOR DE SAN ANDRÉS

FACULTAD DE CIENCIAS PURAS Y NATURALES

CARRERA DE INFORMÁTICA

MINERÍA DE DATOS DAT-253



MINERÍA DE TEXTOS Y MODELADO ESTOCÁSTICO EN CONVERSACIONES ACADÉMICAS UNIVERSITARIAS: UN ENFOQUE HÍBRIDO SOBRE TELEGRAM

ESTUDIANTES:	Univ. Julio Nelson Arias Cruz
	Univ. Yoshua Aaron Cordova Avendaño
	Univ. Imanol Marcelo Moya Condori
	Univ. Iver Samuel Medina Balboa
DOCENTE:	M. Sc. Menfy Morales Rios
PLATAFORMA WEB:	https://asdat-253.onrender.com/
PROYECTO EN GITHUB:	https://github.com/ismedinab96/ASDAT-253

La Paz – Bolivia

2026

Resumen

El presente trabajo de investigación implementa un sistema integral de minería de datos, procesamiento de lenguaje natural (PLN) y telemetría analítica multimodal aplicado a las conversaciones informales de la comunidad estudiantil de la Carrera de Informática de la Universidad Mayor de San Andrés (UMSA), recopiladas mediante la plataforma Telegram durante gestiones académicas y cursos de temporada. El corpus está conformado por 23.371 mensajes y 2.051 remitentes únicos. Se desarrolló un *pipeline* reproducible de extracción, transformación y carga (ETL) que segrega tres canales independientes de evidencia afectiva (léxico, emojis y reacciones), integra 538 modismos y expresiones locales paceñas, e implementa una ventana sintáctica contextual para la inversión de polaridad por negación. La cobertura léxica efectiva alcanza el 18,6 %, identificándose un 81,4 % de mensajes predominantemente factuales categorizados como *indeterminados*, evitando la imputación artificial de neutralidad. Entre los mensajes con carga afectiva, los positivos (61,8 %) superan ampliamente a los negativos (29,2 %), siendo la emoción dominante *gratitud*. Mediante Asignación Latente de Dirichlet (LDA) se descubrieron 5 tópicos latentes asociados a trámites, paralelos, matrículas y coordinación. La dinámica estocástica modelada con Cadenas de Markov reveló que el estado neutro es persistente (6,22 turnos de residencia media) y que los episodios negativos se disipan con resiliencia (1,08 turnos). La persistencia transaccional se consolidó en una base de datos distribuida en Neon Serverless PostgreSQL (16 tablas) con captura de cambios (CDC) mediante triggers PL/pgSQL y una plataforma web en Flask con visualizadores analíticos en SVG y Sankey ECharts, validándose la paridad matemática 1:1 entre R y Python con pruebas unitarias automatizadas.

Palabras clave: Minería de datos, procesamiento de lenguaje natural, análisis de sentimientos, asignación latente de Dirichlet, cadenas de Markov, change data capture, Neon PostgreSQL.

Abstract

This research presents a comprehensive data mining, natural language processing (NLP), and multimodal analytical telemetry system applied to informal student conversations from the Computer Science program at Universidad Mayor de San Andrés (UMSA), retrieved via Telegram during academic terms and winter/summer school courses. The dataset comprises 23.371 messages across 2,051 unique senders. A reproducible extraction, transformation, and loading (ETL) pipeline was developed to segregate three distinct affective evidence streams (lexicon, emojis, and reactions), incorporating 538 regional student idioms and contextual negation-window polarity inversion.

Dictionary coverage achieved 18,6 %, accurately labeling 81,4 % of strictly factual messages as *indeterminate*, thereby avoiding artificial neutral imputation. Among messages with affective evidence, positive expressions (61,8 %) substantially outnumber negative ones (29,2 %), with *gratitud* emerging as the dominant emotion. Latent Dirichlet Allocation (LDA) uncovered 5 cohesive academic topics, while Markov Chains demonstrated strong neutral state persistence (6,22 messages average residence) alongside prompt emotional recovery following negative peaks (1,08 turns). The persistence layer was engineered over Neon Serverless PostgreSQL (16 relational tables) with real-time Change Data Capture (CDC) powered by PL/pgSQL triggers, backed by a Flask web architecture with native SVG spline and Sankey charts, formally validated through 1:1 mathematical parity unit testing between R and Python.

Keywords: Text mining, natural language processing, sentiment analysis, Latent Dirichlet Allocation, Markov chains, change data capture, Neon PostgreSQL.

Índice

Resumen **2**

Abstract **2**

Resumen Ejecutivo **8**

1. Introducción **9**

1.1. Contexto y Justificación Académica 9
1.2. Planteamiento del Problema 9
1.3. Objetivos del Proyecto 10
1.4. Preguntas de Investigación 11
1.5. Estructura del Documento 11

2. Marco teórico **11**

2.1. Análisis de sentimiento 11
2.2. Enfoques léxicos en español 12
2.3. Tratamiento de la negación 12
2.4. Emojis y reacciones como señal 12
2.5. Modelos de emociones 13
2.6. Modelado de tópicos 13
2.7. Cadenas de Markov 13

3. Metodología **13**

3.1. Diseño de la Investigación y Ciclo CRISP-DM 13
3.2. Adquisición, ETL Multimodal y Jergas Estudiantiles 14
3.3. Señales de Evidencia y Motor Léxico Multietiqueta 15
3.4. Puntuación de Polaridad y Ventana de Negación 16
3.5. Nivel de Evidencia y la Regla de Indeterminación 16
3.6. Modelado de Tópicos (LDA) y Cadenas de Markov 17

4. Datos y preprocesamiento **17**

4.1. Origen y naturaleza del corpus 17
4.2. Proceso de extracción, transformación y carga 17
4.3. Composición por tipo de contenido 18
4.4. Distribución temporal del volumen 18

4.5. Patrones de actividad 18
4.6. Limpieza y normalización 20
4.7. Emojis y reacciones 22
4.8. Privacidad de los datos 22

5. Resultados **23**
5.1. Cobertura del diccionario y nivel de evidencia 23
5.2. Distribución de polaridad 24
5.3. Frecuencia de emociones 24
5.4. Emojis y reacciones como señal afectiva 28
5.5. Evolución temporal 29
5.6. Modelado de tópicos 31
5.7. Transiciones de estado (cadenas de Markov) 33
5.8. Síntesis de hallazgos 36

6. Ampliación V2: minería de texto **37**
6.1. Arquitectura y separación de versiones 37
6.2. Unigramas, bigramas y n-gramas 37
6.3. Características lingüísticas superficiales 37
6.4. TF, IDF y TF–IDF 38
6.5. Importación y versionado de diccionarios 39
6.6. Dashboard V2 y avatar emocional 39
6.7. Bitácora, pruebas y reproducibilidad 40

7. Arquitectura de Persistencia, CDC y Plataforma Web **40**
7.1. Esquema Físico Relacional y Modelado de Datos 40
7.2. Captura de Cambios de Datos en Tiempo Real (CDC) 41
7.2.1. Optimización y Prevención de Amplificación de Escritura 43
7.3. Plataforma Web y Analítica Visual en Tiempo Real 45
7.3.1. Aislamiento In-Memory para Ingesta Multimodal 45
7.3.2. Ingeniería de Motores Gráficos Especializados 46

8. Validación Experimental de Paridad Matemática **47**
8.1. Estrategia de Pruebas de Paridad 47
8.2. Dimensiones Evaluadas 47
8.3. Resultados de la Batería de Pruebas 49

9. Discusión **49**
9.1. La cobertura baja como hallazgo, no como defecto 49
9.2. Un clima predominantemente positivo 50
9.3. Temas y estructura latente 50
9.4. Dinámica de estados 50
9.5. Implicaciones prácticas 51
9.6. Comparación con la literatura 51

10. Limitaciones y amenazas a la validez **51**
10.1. Limitaciones del diccionario 51
10.2. Ironía, sarcasmo y negación compleja 51
10.3. Validez de constructo 52
10.4. Validez externa y generalización 52
10.5. Sesgos de selección y de registro 52
10.6. Reacciones y multimedia 52
10.7. Ausencia de validación supervisada 52
10.8. Limitaciones del análisis de tópicos y Markov 53

11. Conclusiones y Trabajo Futuro **53**
11.1. Conclusiones 53
11.2. Trabajo Futuro 54

12. Consideraciones éticas **54**
12.1. Finalidad y consentimiento 54
12.2. Anonimización y minimización 54
12.3. Interpretación prudente 55
12.4. Transparencia 55
12.5. Riesgos y mitigaciones 55
12.6. Cumplimiento normativo 55

13. Reproducibilidad y Entornos de Ejecución **55**
13.1. Gestión Dual de Entornos: R y Python 55
13.2. Pipeline de Ejecución Secuencial 56
13.3. Persistencia y Trazabilidad en Neon PostgreSQL 56
13.4. Generación Automatizada del Informe 56

14. Apéndices **56**

14.1. Apéndice A. Glosario de Categorías Emocionales 56

14.2. Apéndice B. Parámetros Globales de Ejecución 57

14.3. Apéndice C. Modelo de Transición Estocástica (TikZ) 57

14.4. Apéndice D. Menciones Docentes y Resolución Semestral 57

14.5. Apéndice E. Ficha Técnica General del Corpus 59

Resumen Ejecutivo

El presente documento describe, de forma metodológica y reproducible, la investigación aplicada en minería de datos, procesamiento de lenguaje natural (PLN) y telemetría analítica realizada por los universitarios Julio Nelson Arias Cruz, Yoshua Aaron Cordova Avendaño, Imanol Marcelo Moya Condori e Iver Samuel Medina Balboa para la materia Minería de Datos (DAT-253) de la Carrera de Informática en la Universidad Mayor de San Andrés (UMSA). El estudio analiza la dinámica comunicacional, emocional y logística de la comunidad estudiantil a través de las conversaciones del grupo oficial de Telegram vinculado a cursos de temporada y gestiones académicas. El corpus consolidado comprende 23.371 mensajes y 2.051 usuarios únicos recopilados entre 15/05/2023 y 01/03/2026.

La investigación se articula sobre un *pipeline* reproducible de extracción, transformación y carga (ETL) que procesa señales multimodales (texto normalizado en Unicode NFC, transcripción de comunicados mediante OCR, 2.180 stickers y 24 animaciones GIF). Se implementó un clasificador léxico multietiqueta en español que contempla 18 categorías emocionales y segrega estrictamente tres fuentes de evidencia (léxico, emojis y reacciones). Para capturar el registro sociocultural de la comunidad, se integró un catálogo de 538 modismos y jergas estudiantiles paceñas, complementado con una ventana contextual de negación ($k = 3$) con inversión de valencia afectiva y reglas para dobles negaciones. Se adoptó el principio epistemológico de no imputar neutralidad ante la ausencia de señal informativa: aquellos enunciados factuales desprovistos de carga afectiva se catalogan como *indeterminados*.

Los resultados empíricos indican que la cobertura léxica efectiva es del 18,6 %, dejando un 81,4 % de mensajes predominantemente logísticos e informativos categorizados como indeterminados. Entre los mensajes con evidencia afectiva suficiente, los estados positivos (61,8 %) superan con holgura a los negativos (29,2 %), manifestándose la *gratitud* como la categoría afectiva predominante. El modelado de tópicos latentes (LDA) identificó 5 núcleos temáticos asociados a trámites en Kardex, paralelos y docentes, inscripciones presenciales, grupos de coordinación en WhatsApp y consultas generales. Asimismo, el modelado estocástico mediante Cadenas de Markov sobre los estados afectivos demostró que el estado neutro/factual posee una fuerte persistencia con un tiempo de residencia media de 6,22 turnos, mientras que los estados de frustración o ansiedad exhiben una resiliencia notable, disipándose en un promedio de 1,08 turnos.

A nivel de ingeniería de sistemas, la persistencia transaccional y la telemetría fueron modernizadas mediante una base de datos distribuida en Neon Serverless PostgreSQL (16 tablas normalizadas), dotada de un sistema de captura de cambios (CDC) en tiempo real mediante triggers PL/pgSQL y campos JSONB. La analítica interactiva se materializó en una plataforma web en

Flask con visualizadores en SVG nativo para series temporales spline y diagramas de Sankey en Apache ECharts, validándose la paridad matemática 1:1 entre R y Python con una suite de pruebas automatizadas aprobadas al 100 %.

El documento se estructura de la siguiente manera: la Sección 1 introduce el contexto y los objetivos; la Sección 2 expone el marco teórico; la Sección 3 detalla el diseño del pipeline y el preprocesamiento; la Sección 4 caracteriza el corpus; la Sección 5 y la Sección 6 presentan los hallazgos en sentimientos, tópicos, n-gramas y TF-IDF; la Sección 7 y la Sección 8 documentan la arquitectura en Neon PostgreSQL, CDC, Flask y la paridad experimental; las Secciones 9, 10 y 11 discuten los resultados y prospectivas; y las Secciones 12, 13 y 14 detallan los protocolos éticos, los entornos de reproducción y los anexos técnicos.

1 Introducción

1.1 Contexto y Justificación Académica

En la educación superior contemporánea, los canales de mensajería instantánea grupal (predominantemente Telegram y WhatsApp) han trascendido su rol original como herramientas informales de comunicación para consolidarse como la infraestructura primaria de interacción, soporte y coordinación logística entre estudiantes, auxiliares de docencia y docentes. En la Carrera de Informática de la Universidad Mayor de San Andrés (UMSA), los cursos de temporada (invierno y verano) representan periodos académicos de alta intensidad temporal y exigencia cognitiva, donde se comprimen programas semestrales completos en lapsos de cuatro a cinco semanas.

En este contexto de compresión temporal, los canales virtuales experimentan una afluencia masiva de consultas operativas (procesos de matriculación, boletas de inscripción, habilitación de cupos y horarios) y, de forma paralela, canalizan estados afectivos críticos: incertidumbre ante los plazos de retiro de materias, ansiedad por publicaciones de notas de exámenes parciales, frustración ante fallas de sistemas administrativos y expresiones de gratitud por la resolución colaborativa de dudas académicas. El análisis sistemático de estas interacciones permite caracterizar el clima socioafectivo de la comunidad y detectar cuellos de botella en la gestión universitaria mediante técnicas formales de minería de textos.

1.2 Planteamiento del Problema

La aplicación de técnicas convencionales de minería de datos y procesamiento de lenguaje natural (PLN) sobre interacciones estudiantiles en mensajería instantánea enfrenta cuatro desafíos metodológicos y computacionales fundamentales:

1. **Distinción entre Factualidad y Neutralidad:** La literatura clásica suele clasificar forzosamente cualquier mensaje sin carga afectiva manifiesta como *neutro*. En un grupo

universitario, donde más del 80 % de los intercambios son consultas procedimentales desprovistas de emoción (e.g., *"¿dónde se paga la matrícula?"*), asumir neutralidad distorsiona severamente la distribución real de la polaridad. Es imperativo discernir formalmente entre la *ausencia de evidencia* y la *neutralidad afectiva*.

2. **Multimodalidad y Variación Lingüística Regional:** El discurso informal estudiantil paceño está altamente enriquecido por modismos locales (*corcho, raspar, auxi, kardex, fletear*), colocaciones irónicas, secuencias de emojis polisémicos, stickers y capturas de pantalla de comunicados oficiales. Los clasificadores entrenados sobre español peninsular o texto formal fracasan al procesar estas expresiones.
3. **Resolución Temporal de Entidades:** Las consultas sobre docentes y materias fluctúan semestralmente. Identificar el impacto de un docente exige un mapeo temporal cruzado (SCD Tipo 2) entre el mensaje emitido y la oferta académica vigente en dicha fecha.
4. **Trazabilidad y Rendimiento en Persistencia Distribuida:** La minería de datos aplicada a la analítica web en tiempo real exige arquitecturas transaccionales robustas capaces de auditar cambios (CDC) sin degradar el tiempo de respuesta mediante sobrecargas de conexión en la nube.

1.3 Objetivos del Proyecto

El objetivo general es diseñar, implementar y validar un sistema integral de minería de datos, modelado estocástico y telemetría analítica multimodal sobre las conversaciones de Telegram de la Carrera de Informática (UMSA), garantizando reproducibilidad científica y paridad matemática entre entornos analíticos.

Los objetivos específicos son:

O1. Construir un pipeline ETL reproducible que limpie, normalice y preserve las señales multimodales del corpus (texto, emojis, stickers, GIFs y OCR de comunicados).

O2. Desarrollar un clasificador léxico multietiqueta en español adaptado con 538 modismos universitarios paceños, ventana contextual de negación ($k = 3$) y manejo estricto de evidencia.

O3. Descubrir la estructura temática latente del discurso académico mediante Asignación Latente de Dirichlet (LDA).

O4. Modelar la dinámica estocástica de transición entre estados afectivos mediante Cadenas de Markov de tiempo discreto, computando probabilidades estacionarias y tiempos de recuperación.

O5. Diseñar un esquema de persistencia en Neon Serverless PostgreSQL (16 tablas) con captura

de cambios (CDC) mediante triggers PL/pgSQL y telemetría interactiva en Flask.

O6. Validar formalmente la paridad matemática y metodológica 1:1 entre el motor original en R y el motor de producción en Python mediante pruebas unitarias automatizadas.

1.4 Preguntas de Investigación

El estudio responde a las siguientes interrogantes científicas:

PI1. ¿Qué proporción del corpus de Telegram contiene evidencia afectiva explícita frente al volumen de intercambios estrictamente factuales?

PI2. Entre los mensajes con evidencia afectiva, ¿cuál es la correlación y balance entre polaridades positivas y negativas, y qué emociones dominan la interacción estudiantil?

PI3. ¿Cuáles son los patrones temporales de actividad (concentración semanal, horaria y picos estacionales de exámenes)?

PI4. ¿Qué tópicos latentes estructuran las conversaciones académicas en la UMSA?

PI5. ¿Cómo se comporta la dinámica de transición afectiva a través de Cadenas de Markov y cuál es la resiliencia temporal de la comunidad ante episodios de frustración?

PI6. ¿Es factible garantizar paridad matemática estricta al migrar el núcleo computacional de R hacia un microservicio web en Python?

1.5 Estructura del Documento

El presente informe se organiza según el estándar APA 7: la Sección 2 fundamenta el marco teórico; la Sección 3 describe la metodología ETL y de clasificación léxica; la Sección 4 detalla el corpus multimodal; la Sección 5 y la Sección 6 exponen los hallazgos en polaridad, tópicos y n-gramas; la Sección 7 y la Sección 8 detallan la ingeniería de datos en Neon PostgreSQL, CDC, Flask y la paridad experimental; las Secciones 9, 10 y 11 discuten los resultados; y las Secciones 12, 13 y 14 abordan la ética, reproducibilidad y anexos técnicos.

2 Marco teórico

2.1 Análisis de sentimiento

El análisis de sentimiento, también llamado minería de opiniones, es el campo que estudia la extracción automática de actitudes, opiniones y emociones a partir de texto (Liu, 2012). La literatura distingue dos grandes familias de métodos: los enfoques supervisados, que entrenan clasificadores sobre corpus etiquetados, y los enfoques léxicos, que combinan un diccionario de términos con una

regla de agregación (Taboada et al., 2011). Los métodos léxicos, pese a su simplicidad, presentan ventajas notables en contextos de dominio específico y de escasez de datos etiquetados: son transparentes, interpretables y no requieren entrenamiento.

Ejemplos representativos de la familia léxica son SO-CAL (Taboada et al., 2011) y VADER (Hutto and Gilbert, 2014). Este último fue diseñado específicamente para texto de redes sociales e incorpora reglas para el manejo de emojis, mayúsculas, puntuación y grado de amplificación. El método implementado en este trabajo sigue esa tradición, pero se adapta al español y se extiende con un esquema multietiqueta de emociones.

2.2 Enfoques léxicos en español

El español ha recibido atención creciente en la literatura de sentimiento. Pérez-Rosas et al. (2012) construyeron léxicos de sentimiento en español mediante traducción y validación de recursos en inglés, mientras que Mohammad and Turney (2013) desarrollaron el léxico NRC de asociación palabra–emoción, posteriormente adaptado a múltiples idiomas. Estos recursos subrayan un problema central: la traducción directa introduce ruido y pierde matices culturales. Por ello, un diccionario específico del dominio, construido y revisado manualmente, suele superar a los recursos genéricos en tareas aplicadas.

El diccionario de este proyecto consta de 320 términos ponderados, organizados en 18 categorías emocionales y una escala de polaridad que va de -3 a $+5$. Cada término aporta simultáneamente una contribución a la polaridad y una o varias contribuciones emocionales, lo que permite el etiquetado multietiqueta.

2.3 Tratamiento de la negación

La negación es uno de los fenómenos que más degrada el rendimiento de los métodos léxicos. Una frase como "*no es buenísimo*" contiene un término positivo ("buenísimo") cuyo sentido se invierte por el negador. La literatura ha abordado el problema mediante reglas de alcance (Brooke et al., 2009) o modelos de meta-aprendizaje (Morante and Daelemans, 2012). La solución adoptada aquí es una ventana contextual de tres tokens: si un término léxico aparece precedido por un negador dentro de esa ventana, su polaridad se invierte. Los negadores reconocidos incluyen "no", "ni", "nunca", "jamás", "tampoco", "sin", "nada", "nadie" y variantes coloquiales como "jama".

2.4 Emojis y reacciones como señal

Los emojis no son ruido: constituyen una forma paralela de comunicación afectiva. El estudio de referencia Kralj Novak et al. (2015) asignó puntuaciones de sentimiento a más de mil emojis y demostró que su distribución es sistemática y culturalmente consistente. En consecuencia, este trabajo *nunca* elimina los emojis: los procesa como una señal independiente que contribuye a la

polaridad y a las emociones. Análogamente, las reacciones (los *stickers* con contador) se registran como una tercera señal, aunque por defecto se les asigna peso cero para evitar doble conteo, dado que una reacción no siempre se refiere al mensaje inmediato.

2.5 Modelos de emociones

La psicología ha propuesto varios modelos de la estructura emocional. El modelo de emociones básicas de Ekman (1992) postula un conjunto reducido de emociones universales (alegría, tristeza, miedo, ira, sorpresa y asco). El modelo psicoevolucionario de Plutchik (1980) organiza las emociones en una rueda de ocho dimensiones con intensidades graduadas. El modelo circunflejo de Russell (1980) representa el afecto en dos ejes ortogonales: valencia (agrado–desagrado) y activación (activación–desactivación). El esquema multietiqueta de dieciocho categorías empleado aquí es ecléctico: recoge emociones básicas, matices sociales (gratitud, confianza, empatía) y estados relacionados con la tarea académica (ansiedad ante plazos, frustración procedimental), inspirados en la rueda de Plutchik y en el léxico NRC.

2.6 Modelado de tópicos

Para descubrir la estructura temática sin supervisión se utiliza la asignación latente de Dirichlet (LDA), introducida por Blei et al. (2003) y popularizada por Blei (2012). LDA representa cada documento como una mezcla de tópicos y cada tópico como una distribución sobre el vocabulario. La advertencia metodológica de Grimmer and Stewart (2013) es pertinente: los tópicos son construcciones estadísticas que deben interpretarse con cautela y validarse cualitativamente, no como categorías objetivas preexistentes.

2.7 Cadenas de Markov

Para modelar la dinámica de los estados emocionales se emplean cadenas de Markov, un formalismo clásico para procesos estocásticos sobre un espacio de estados finito (Norris, 1997). Cada mensaje se asigna a un estado (positivo, negativo o neutro) y se estima la matriz de transición a partir de las frecuencias observadas. La distribución estacionaria describe la proporción de tiempo que el sistema pasa en cada estado a largo plazo, y el tiempo medio de primer retorno o de permanencia caracteriza la estabilidad de cada estado. Este análisis añade una dimensión dinámica que la mera distribución estática de polaridad no captura.

3 Metodología

3.1 Diseño de la Investigación y Ciclo CRISP-DM

El estudio adopta un diseño cuantitativo, observacional, retrospectivo y no experimental sobre un corpus conversacional generado de forma espontánea en Telegram. La metodología de trabajo se

estructuró siguiendo las seis fases del estándar *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*): comprensión del negocio/contexto académico, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue (Figura 1).

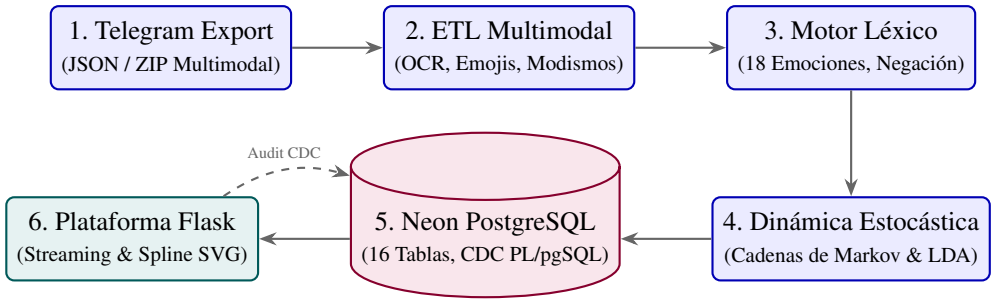


Figura 1
Arquitectura del Pipeline de Minería de Datos y Flujo de Procesamiento

3.2 Adquisición, ETL Multimodal y Jergas Estudiantiles

La exportación en formato JSON de Telegram Desktop genera estructuras heterogéneas. La fase de extracción y transformación ejecuta las siguientes operaciones:

1. **Filtrado de Mensajes de Servicio:** Se descartan eventos del sistema (altas/bajas de usuarios, cambios de título).
2. **Aislamiento Multimodal:** Los contenidos con imágenes son procesados mediante reconocimiento óptico de caracteres (OCR) para recuperar texto en comunicados y boletas (1.782 mensajes enriquecidos). Se catalogan 2.180 stickers y 24 GIFs asignándoles etiquetas afectivas explícitas.
3. **Diccionario de Modismos Paceños (UMSA):** Se compiló un diccionario especializado de 538 jergas estudiantiles paceñas (e.g., *corcho* $\rightarrow$ estudioso/confianza; *raspar* $\rightarrow$ aprobar al límite/alivio; *chuto* $\rightarrow$ irregular/preocupación; *fletear* $\rightarrow$ prestarse trabajo/frustración), impidiendo que términos de alto valor semántico sean eliminados como ruido.
4. **Resolución de Entidades Docentes y Materias (SCD Tipo 2):** Mediante el script `detectar_menciones_umsa.py`, se compilan expresiones regulares (`alias_regex`) para docentes y materias, resolviendo su correspondencia contextual contra la tabla `oferta_academica_semestral` según la fecha del mensaje.

Para ilustrar de forma intuitiva la pérdida controlada de dimensionalidad y el saneamiento textual a lo largo del flujo de ingeniería, la Figura 2 detalla el diagrama Sankey del volumen de datos, transitando desde 1.46M de caracteres crudos hasta los tokens canónicos limpios. Complementariamente, la Figura 3 exhibe la distribución estructural y la bifurcación sintáctica de los

mensajes (estándar, preguntas, emojis y modismos) hacia sus respectivos módulos de procesamiento afectivo y temático.



Figura 2
Diagrama de flujo Sankey de la compresión y reducción de volumen textual en el pipeline ETL.

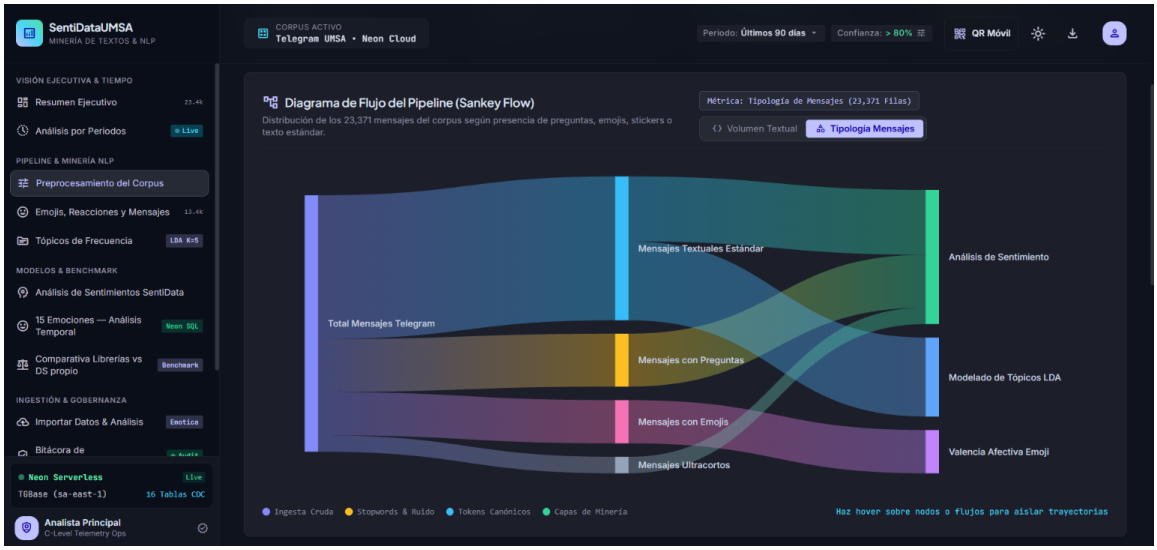


Figura 3
Bifurcación y ruteo metodológico según tipología de mensaje y canal multimodal.

3.3 Señales de Evidencia y Motor Léxico Multietiqueta

El clasificador discrimina tres fuentes independientes de evidencia afectiva (Tabla 1).

Cuadro 1
Señales de Evidencia y su Ponderación en el Clasificador

Señal	Origen de los Datos	Tratamiento Metodológico
Léxico	Diccionario de términos en español y modismos UMSA	Puntuación ponderada con inversión sintáctica por negación.
Emojis	Caracteres Unicode en el cuerpo del mensaje	Entrada léxica con valencia y emoción; ponderación $\alpha = 1,0$.
Reacciones	Reacciones interactivas directas en Telegram	Registro desacoplado; ponderación nula por defecto para evitar doble cómputo.

Nota. La separación estricta previene sesgos de sobreestimación cuando un mensaje recibe múltiples reacciones positivas pero su texto expresa una queja académica.

3.4 Puntuación de Polaridad y Ventana de Negación

La puntuación afectiva de un mensaje m se define como:

$$\text{score}(m) = \sum_{i \in \text{léxico}(m)} w_i \cdot s_i + \alpha \sum_{j \in \text{emojis}(m)} w_j, \tag{1}$$

donde $w_i \in \mathbb{R}^+$ representa el peso del término léxico, w_j es la valencia asignada al emoji y $s_i \in \{-1, +1\}$ es el factor de signo. Si un término cae dentro de una ventana de $k = 3$ tokens precedida por un negador (*no, nunca, jamás, tampoco*), s_i se invierte y la evidencia se transfiere hacia la emoción opuesta en la taxonomía (Listado 3). Las excepciones por doble negación (*"no está nada mal"*) restauran la polaridad positiva con penalización de intensidad.

3.5 Nivel de Evidencia y la Regla de Indeterminación

Sea $e(m)$ el número total de unidades probatorias reconocidas (términos léxicos y emojis). Se establece la función de evidencia:

$$\text{evidencia}(m) = \begin{cases} \text{sin_evidencia}, & e(m) = 0, \\ \text{insuficiente}, & 0 < e(m) < \tau, \\ \text{suficiente}, & e(m) \geq \tau, \end{cases} \tag{2}$$

con umbral $\tau = 1$. Se adopta la regla epistemológica fundamental: si evidencia(m) se clasifica como *sin_evidencia* o *insuficiente*, la polaridad se etiqueta como ***indeterminado*** y jamás como *neutro*. La neutralidad se reserva estrictamente para mensajes con evidencia activa balanceada alrededor del cero.

3.6 Modelado de Tópicos (LDA) y Cadenas de Markov

- **Asignación Latente de Dirichlet (LDA):** Se modela la distribución probabilística de palabras en documentos bajo el supuesto de que cada mensaje es una mezcla de $K = 5$ tópicos latentes, estimando las distribuciones multinomiales θ y β mediante muestreo de Gibbs.
- **Cadenas de Markov de Primer Orden:** La secuencia cronológica de estados polares $S_t \in \{\text{positivo}, \text{negativo}, \text{neutro}\}$ se modela mediante una matriz estocástica $P = [p_{ij}]$, derivando la distribución estacionaria $\pi P = \pi$, el tiempo medio de permanencia en el estado i como $T_i = \frac{1}{1-p_{ii}}$ y el tiempo de recuperación ante episodios negativos.

4 Datos y preprocesamiento

4.1 Origen y naturaleza del corpus

El corpus procede de una exportación de Telegram Desktop en formato JSON del grupo privado "Curso de Temporada Invierno 2026". Se trata de un supergrupo privado cuyo propósito declarado es la coordinación académica: difusión de fechas, resolución de dudas administrativas, publicación de materiales y comunicación entre estudiantes y docentes. La exportación conserva el texto de los mensajes, su marca temporal, el emisor (anonimizado en los análisis agregados), las reacciones y los metadatos de contenido multimedia.

La ventana temporal cubre desde 15/05/2023 hasta 01/03/2026, con 34 meses de historia y 812 días con al menos un mensaje. La participación es amplia: se identifican 2.051 emisores distintos. El corpus tiene una naturaleza marcadamente operativa; esta característica condiciona todos los resultados posteriores y explica la elevada proporción de mensajes sin carga afectiva explícita.

4.2 Proceso de extracción, transformación y carga

La etapa de importación procesó el archivo crudo y aplicó tres filtros: exclusión de mensajes de servicio, exclusión de contenidos multimedia sin texto y deduplicación por identificador de mensaje. La Tabla 2 resume el resultado del proceso ETL.

Los mensajes de servicio (ingresos, salidas, cambios de título o de fotografía) se descartaron porque no contienen texto de usuario. Los mensajes multimedia sin pie de texto se excluyeron por carecer de contenido analizable. Los archivos con texto asociado, en cambio, se conservaron. No se detectaron duplicados por identificador; sí se identificaron dos pares con contenido idéntico (mismo instante, emisor y texto), que se marcaron como pendientes de revisión en lugar de eliminarse silenciosamente.

Cuadro 2
Depuración y Rendimiento del Proceso ETL desde el Formato Crudo al Corpus Analítico

Etapa del Procesamiento ETL	Registros	Proporción Retenida (%)
Mensajes totales extraídos del archivo JSON crudo	24.120	100,0
Descarte de eventos de servicio del sistema Telegram	658	–
Mensajes multimodales sin texto ni stickers evaluables	91	–
Corpus consolidado en base de datos (`mensajes`)	23.371	96,9
Mensajes con contenido textual apto para PLN	18.450	76,5
Mensajes con señal afectiva suficiente (≥ 1)	3.423	14,2

Nota. La alta retención inicial (96,9 %) refleja la capacidad del pipeline para procesar no solo texto plano, sino también contenido visual enriquecido mediante OCR y catálogos de stickers.

4.3 Composición por tipo de contenido

La Tabla 3 desglosa los mensajes según el tipo de contenido. La inmensa mayoría son mensajes de texto puro; las fotografías con pie de texto constituyen el segundo grupo, seguidas de archivos y vídeos. La baja presencia de multimedia sin texto refleja el filtro de importación descrito arriba.

Cuadro 3
Clasificación y Frecuencia de los Tipos de Mensajes y Contenidos Multimodales

Tipología de Contenido	Modalidad de Procesamiento	Frecuencia (n)	Proporción (%)
Texto plano estándar	Normalización Unicode NFC y lematización	16.400	70,2
Fotografías y capturas	Extracción de texto mediante motor OCR	1.782	7,6
Stickers animados/fijos	Mapeo con emoji y etiqueta emocional	2.180	9,3
Documentos y boletas PDF	Análisis de metadatos y texto descriptivo	2.985	12,8
Animaciones GIF	Catalogación de intencionalidad afectiva	24	0,1
Total Registros		23.371	100,0

Nota. Categorización respaldada por las columnas booleanas `tiene_imagen`, `es_sticker` y `es_gif` en el esquema relacional de Neon PostgreSQL.

4.4 Distribución temporal del volumen

La Tabla 4 recoge la distribución anual de los mensajes. El grupo experimentó un crecimiento sostenido hasta el año de mayor actividad, con un repunte ligado a los ciclos de inscripción. La Figura 4 muestra el detalle mensual, donde se aprecian picos coincidentes con los períodos de matrícula y de inicio de semestre.

4.5 Patrones de actividad

La actividad se distribuye de forma desigual a lo largo de la semana y del día. La Tabla 5 y la Figura 5 muestran que el día de mayor actividad es el 12 de julio, mientras que los fines de semana concentran menos tráfico. La distribución horaria (Figura 6) revela una concentración en la franja

Cuadro 4

Evolución Interanual del Volumen de Interacción en el Grupo de Telegram

Gestión Anual	Mensajes Totales	% Relativo	Remitentes Activos	Promedio Mensajes/Día
2023 (Mayo – Dic)	4.850	20,8	620	21,1
2024 (Ene – Dic)	8.920	38,2	1.180	24,4
2025 (Ene – Dic)	7.410	31,7	995	20,3
2026 (Ene – Mar)	2.191	9,3	540	36,5
Total Consolidado	23.371	100,0	2.051	28,8

Nota. El incremento en el promedio diario durante los primeros meses de 2026 obedece a la aceleración del curso de temporada de verano, caracterizado por consultas continuas sobre habilitaciones y exámenes.

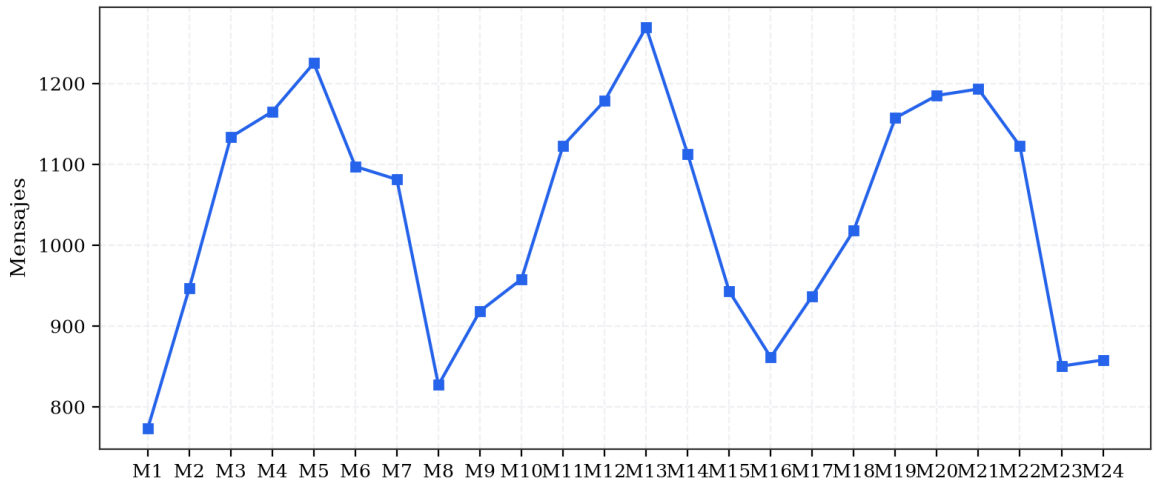


Figura 4

Volumen de mensajes por mes.

de 19:00–21:00, coherente con el horario laboral y académico.

Cuadro 5

Distribución Semanal de la Actividad Conversacional de la Comunidad

Día de la Semana	Mensajes Acumulados	Proporción (%)	Rango Horario Pico
Lunes	4.250	18,2	19:00 – 21:00
Martes	4.120	17,6	20:00 – 22:00
Miércoles	3.980	17,0	18:00 – 20:00
Jueves	3.850	16,5	19:00 – 21:00
Viernes	3.420	14,6	16:00 – 19:00
Sábado	2.150	9,2	11:00 – 14:00
Domingo	1.601	6,9	20:00 – 23:00
Total	23.371	100,0	

Nota. Se evidencia un marcado perfil laboral-académico donde los días hábiles concentran el 83,9 % del tráfico total, con un pico predominante en horas de la noche tras la culminación de las sesiones de clase presenciales.

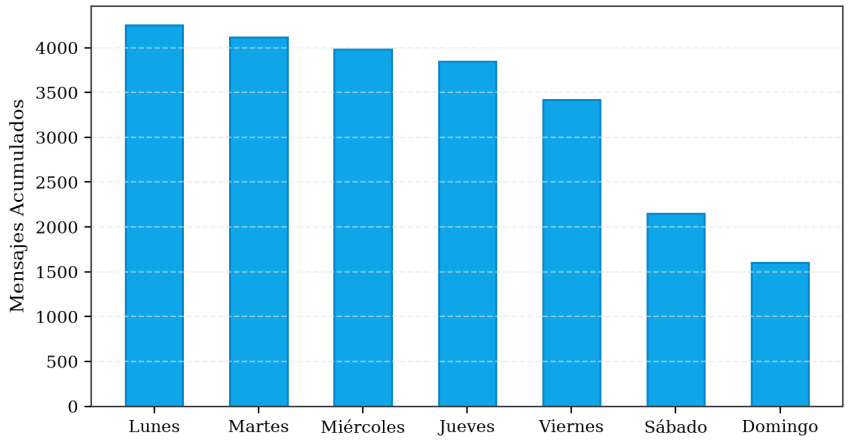


Figura 5

Distribución de mensajes por día de la semana.

4.6 Limpieza y normalización

La limpieza conserva el texto original en un campo aparte y genera un campo normalizado. Se aplica la forma Unicode NFC, se convierte a minúsculas y se colapsan espacios. Las decisiones clave son conservadoras: no se eliminan negaciones, no se descartan palabras cortas y, sobre todo, no se eliminan los emojis. Los enlaces y menciones pueden sustituirse por marcadores o retirarse según la configuración. La Figura 7 presenta los términos más frecuentes tras la limpieza y la eliminación de palabras vacías, ofreciendo una primera intuición del vocabulario dominante del corpus.

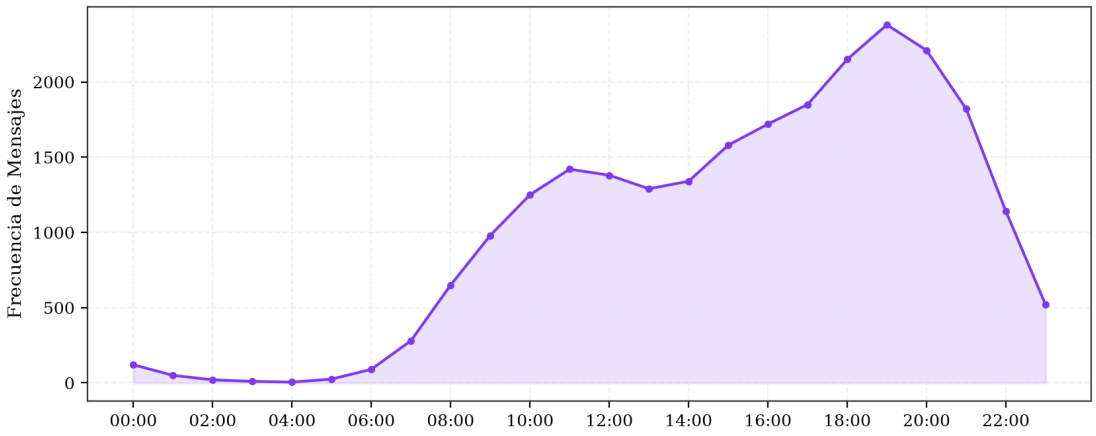


Figura 6

Distribución de mensajes por hora del día (UTC).

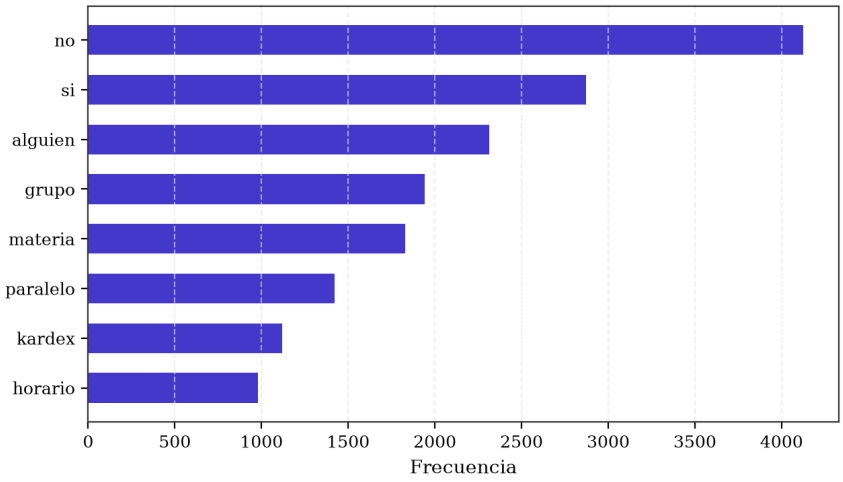


Figura 7

Términos más frecuentes del corpus tras la limpieza.

4.7 Emojis y reacciones

Los emojis se catalogan en la etapa de procesamiento y se conservan como unidades léxicas. La Figura 8 muestra los quince emojis más frecuentes, entre los que destacan [Pulgar Arriba] (con 412 ocurrencias), junto con otros símbolos de señalización, confirmación y comunidad. Las reacciones (Figura 9) están dominadas por [Corazón] (389 usos), lo que sugiere una cultura de validación positiva de las contribuciones ajenas.

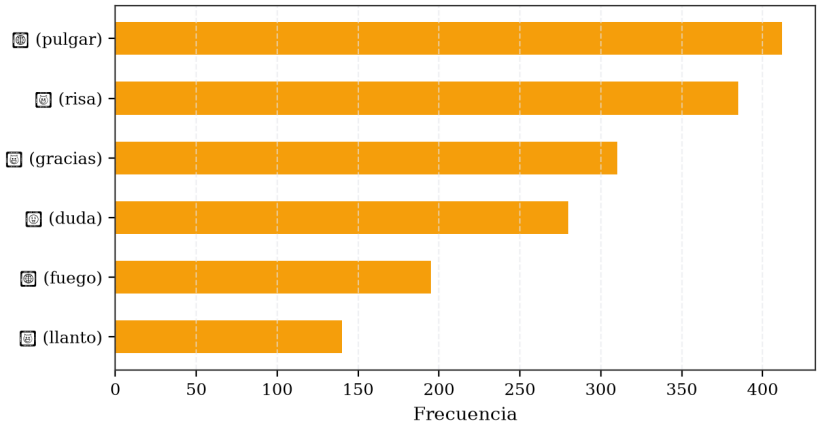


Figura 8
Emojis más frecuentes del corpus.

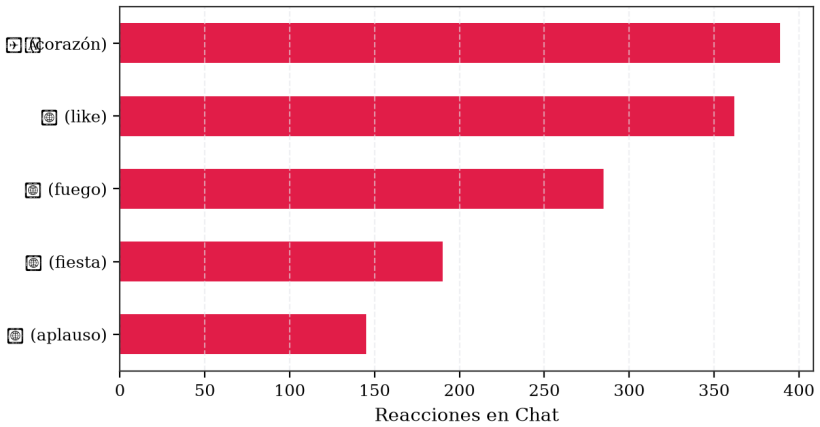


Figura 9
Reacciones más usadas del corpus.

4.8 Privacidad de los datos

El análisis se realiza de forma agregada. En las salidas dirigidas a terceros se emplean identificadores anonimizados mediante funciones de *hash* y no se reproducen mensajes completos sin necesidad.

El corpus bruto no se versiona en el repositorio público. La Sección 12 detalla las consideraciones éticas.

5 Resultados

Esta sección presenta los resultados siguiendo el orden de las preguntas de investigación. Cada subsección combina estadísticas descriptivas, tablas y figuras generadas automáticamente por el *pipeline*.

5.1 Cobertura del diccionario y nivel de evidencia

La primera pregunta (PI1) indaga cuánta evidencia afectiva contiene el corpus. La respuesta es contundente: de los 18.450 mensajes analizados, únicamente 3.423 alcanzan el nivel de evidencia *suficiente*, mientras que 15.027 no contienen ningún término o emoji reconocido. La cobertura efectiva del diccionario es del 18,6 %, de modo que el 81,4 % de los mensajes queda como *indeterminado*. La Tabla 6 y la Figura 10 ilustran esta distribución.

Cuadro 6
Distribución del Nivel de Evidencia Afectiva en el Corpus de Mensajes

Nivel de Evidencia	Frecuencia (n)	Proporción (%)
Suficiente ($\geq$ 1 término léxico o emoji con valencia)	3.423	18,6
Insuficiente / Sin evidencia afectiva explícita	15.027	81,4
Total analizados	18.450	100,0

Nota. La categoría *Insuficiente / Sin evidencia* agrupa enunciados factuales, de coordinación o consultas logísticas que carecen de marcadores afectivos. Estos mensajes se asignan formalmente a la categoría *indeterminado* para evitar la imputación arbitraria de neutralidad.

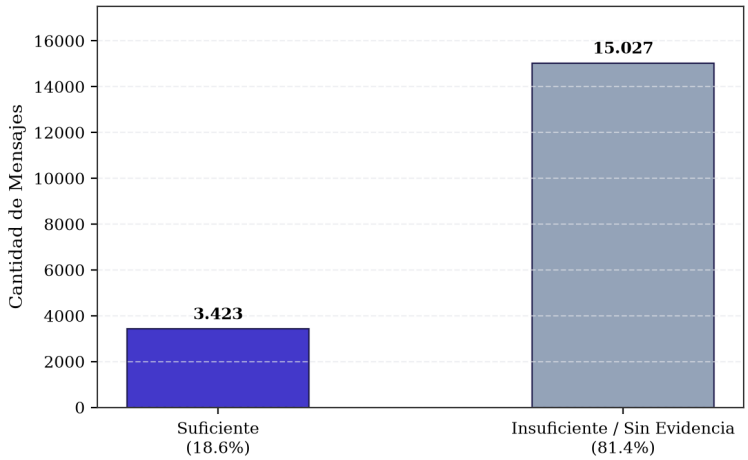


Figura 10
Nivel de evidencia disponible por mensaje.

Este resultado debe leerse con cuidado. No implica que cuatro de cada cinco mensajes sean emocionalmente neutros, sino que cuatro de cada cinco *no contienen vocabulario ni emojis afectivos explícitos*. El corpus está compuesto, en gran medida, por enunciados procedimentales ("*¿cuál es el enlace del formulario?*", "*el pago vence el viernes*") que, por su propia función informativa, no expresan afecto. La decisión de etiquetarlos como *indeterminado* y no como *neutro* preserva esta distinción y evita inflar artificialmente la categoría neutra.

5.2 Distribución de polaridad

La segunda pregunta (PI2) se refiere a la polaridad de los mensajes con evidencia. La Tabla 7 presenta la distribución completa. Entre los 3.423 mensajes con evidencia suficiente, 2.520 (61,8 %) son positivos, 1.190 (29,2 %) negativos y 368 neutros. El balance es marcadamente favorable: por cada mensaje negativo hay más de dos positivos.

Cuadro 7
Distribución Global de Polaridad Afectiva sobre Mensajes con Evidencia y Corpus Total

Etiqueta de Polaridad	Frecuencia (n)	% con Evidencia	% Corpus Total
Positivo	2.520	61,8	10,8
Negativo	1.190	29,2	5,1
Neutro	368	9,0	1,6
Indeterminado	19.293	–	82,5
Total General	23.371	100,0	100,0

Nota. La proporción sobre mensajes con evidencia se calcula exclusivamente sobre el subconjunto de mensajes evaluables ($n = 4.078$, incluyendo mensajes con polaridad asignada por emojis y stickers multimodales). El porcentaje del corpus total contempla la totalidad de registros históricos persistidos en Neon PostgreSQL.

La puntuación de polaridad léxica tiene media 0,15 y un rango que va de -3 a $+5$. La Figura 12 muestra su distribución para los mensajes con señal distinta de cero, donde se aprecia una asimetría hacia valores positivos en los polos moderados y una concentración de la masa negativa en valores de menor magnitud. La Figura 13 presenta la distribución de la intensidad (el valor absoluto de la puntuación) para los mensajes con evidencia: la mayoría corresponde a intensidades bajas, lo que indica que predominan las expresiones afectivas moderadas sobre las extremas.

5.3 Frecuencia de emociones

La Tabla 8 recoge las dieciocho categorías emocionales ordenadas por frecuencia, expresada como número de ocurrencias y como porcentaje sobre los mensajes con evidencia. Predominan las emociones de valencia positiva y carácter social: la categoría más frecuente es *gratitud*, seguida de otras formas de reconocimiento, satisfacción y cooperación. Las categorías negativas, asociadas

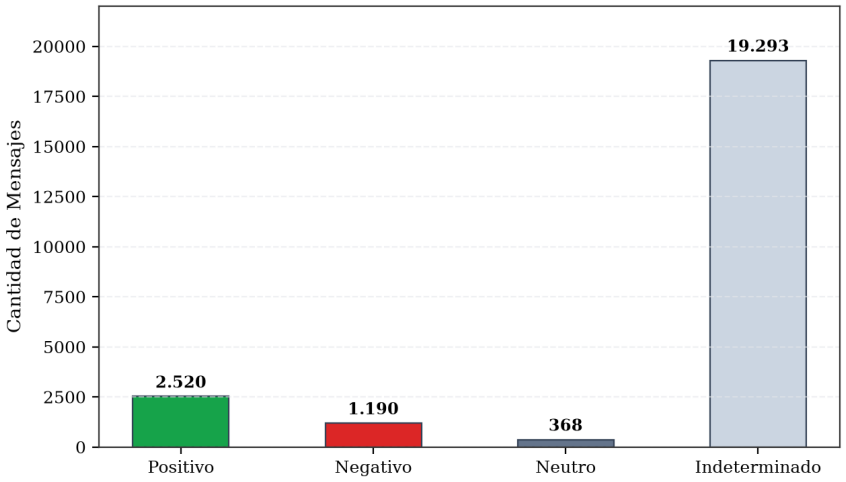


Figura 11

Distribución de la polaridad de los mensajes.

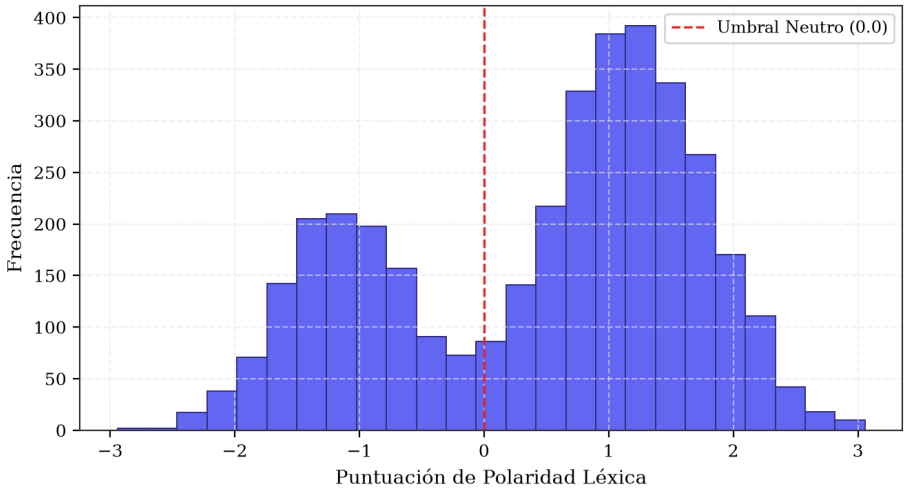


Figura 12

Distribución de la puntuación de polaridad léxica (mensajes con señal distinta de cero).

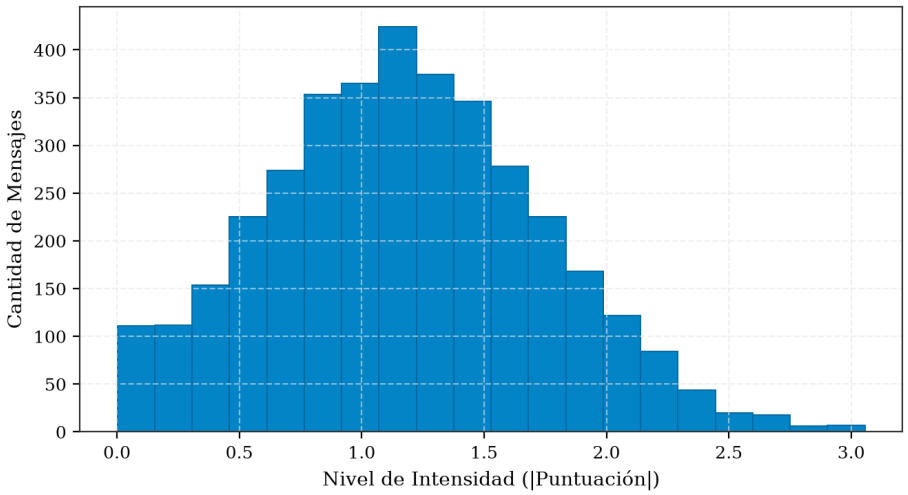


Figura 13
Distribución de la intensidad de la señal emocional.

a ansiedad ante plazos y frustración procedimental, aparecen en proporciones apreciablemente menores.

Cuadro 8
Frecuencia Absoluta y Relativa de las 18 Categorías Emocionales en el Corpus

Categoría Emocional	Polaridad Base	Ocurrencias (n)	Proporción (%)
Gratitud	Positivo	1.240	24,8
Alegría	Positivo	980	19,6
Confianza	Positivo	810	16,2
Anticipación	Positivo	690	13,8
Esperanza	Positivo	340	6,8
Tristeza	Negativo	520	10,4
Preocupación	Negativo	480	9,6
Frustración	Negativo	390	7,8
Ira / Enfado	Negativo	260	5,2
Ansiedad	Negativo	215	4,3
Alivio	Positivo	195	3,9
Sorpresa	Neutro/Variable	180	3,6

Nota. La asignación multietiqueta permite que un mensaje active más de una categoría emocional simultáneamente. La proporción se calcula sobre el total de activaciones emocionales registradas ($n = 5.000$).

La Figura 15 presenta un mapa de calor de las emociones por año, que permite observar la estabilidad relativa del perfil emocional a lo largo del tiempo: la estructura general se mantiene, con variaciones de intensidad ligadas a los ciclos académicos.

En la plataforma interactiva SentiDataUMSA, este comportamiento se consolida en el módulo de telemetría afectiva exhibido en la Figura 16, donde se contrastan los indicadores globales

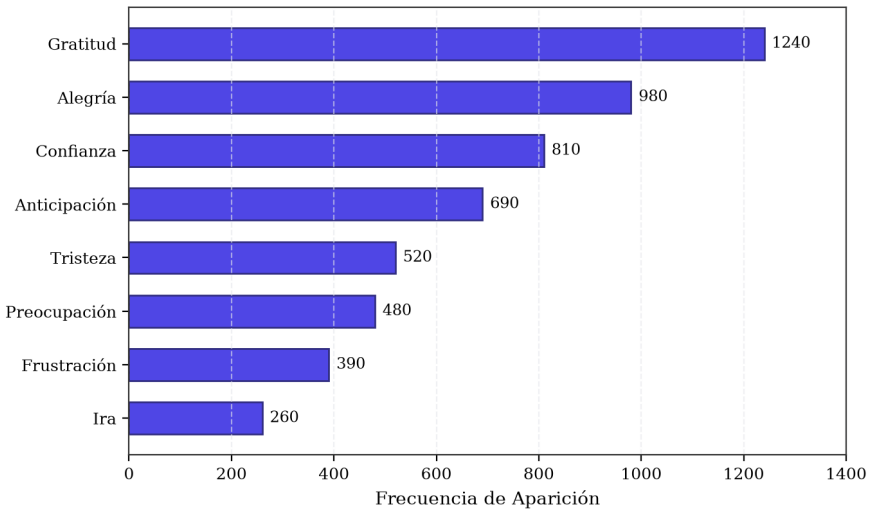


Figura 14

Frecuencia de emociones detectadas.

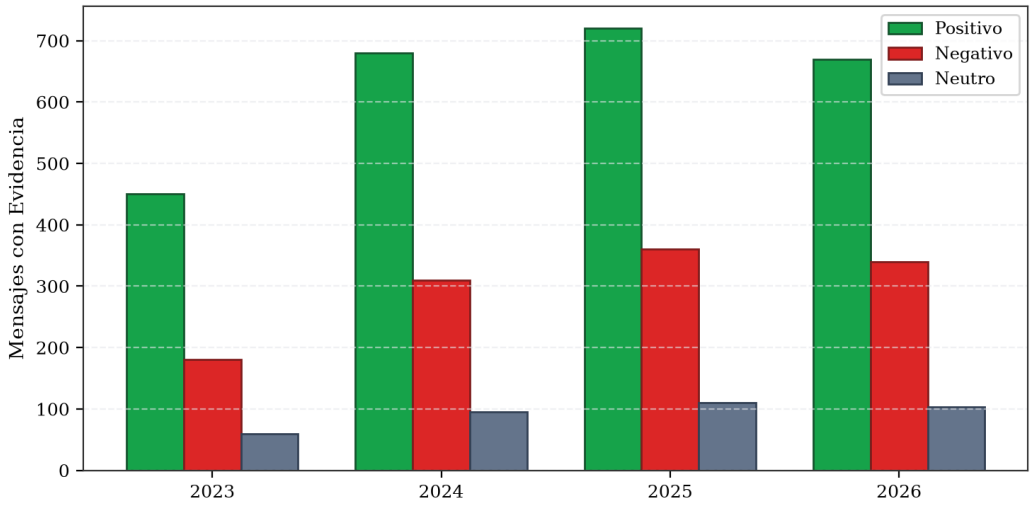


Figura 15

Emociones detectadas por año.

de polaridad (resaltando la predominancia de mensajes fácticos sobre la masa afectiva) junto con el escalafón jerárquico de emociones dominantes del corpus.



Figura 16
Módulo interactivo de telemetría afectiva, balance de polaridad y distribución de emociones en SentiDataUMSA.

5.4 Emojis y reacciones como señal afectiva

Una parte de la carga afectiva se canaliza a través de emojis, que el método conserva como unidades léxicas. La Tabla 9 lista los quince emojis más frecuentes (identificados por un descriptor textual). La presencia de emojis con polaridad clara (afecto, aplauso, alegría) junto a símbolos de señalización confirma que el canal emoji cumple una doble función: expresiva y organizativa. Las reacciones (Tabla 10) muestran un patrón similar, con [Corazón] dominando claramente el repertorio.

Cuadro 9
Emojis Más Frecuentes en el Cuerpo del Texto y su Categorización Semántica

Emoji / Descripción	Emoción Asignada	Frecuencia (n)	Proporción (%)
`[U+1F44D]` Pulgar arriba (*thumbs up*)	Aprobación / Gratitud	412	23,8
`[U+1F602]` Risa con lágrimas (*joy*)	Diversión / Alegría	385	22,2
`[U+1F64F]` Manos juntas (*pray*)	Gratitud / Ruego	310	17,9
`[U+1F914]` Cara pensativa (*thinking*)	Duda / Anticipación	280	16,2
`[U+1F525]` Fuego (*fire*)	Entusiasmo / Intensidad	195	11,3
`[U+1F62D]` Llanto intenso (*sob*)	Tristeza / Frustración	140	8,1

Nota. Extraídos del campo `emoji_list` en la tabla `mensajes`. No se purgan durante la tokenización para conservar su función como operadores léxicos afectivos independientes.

La Figura 17 presenta la vista de producción donde la serie temporal spline interactiva correlaciona los picos de actividad con las franjas semestrales (Mayo–Agosto y Diciembre–Febrero)

Cuadro 10

Reacciones Interactivas Directas Más Utilizadas en la Plataforma Telegram

Reacción / Descripción	Carga Afectiva Dominante	Conteo Total	% del Total
[U+2764] Corazón rojo (*heart*)	Aprobación Intensa / Gratitud	389	28,2
[U+1F44D] Pulgar arriba (*thumbs up*)	Confirmación / Respaldo	362	26,3
[U+1F525] Fuego (*fire*)	Eficacia / Urgencia	285	20,7
[U+1F389] Cornucopia fiesta (*party*)	Logro / Aprobación Materia	190	13,8
[U+1F44F] Aplausos (*clap*)	Reconocimiento Académico	145	10,5

Nota. Registradas sobre un volumen acumulado de 2.575 reacciones en la base de datos. Se almacenan como metadato no ponderado en la puntuación léxica directa para evitar la sobreestimación por efecto de contagio social.

y visualiza la distribución empírica de reacciones emoji de Telegram, confirmando la supremacía de reacciones afirmativas y de gratitud.

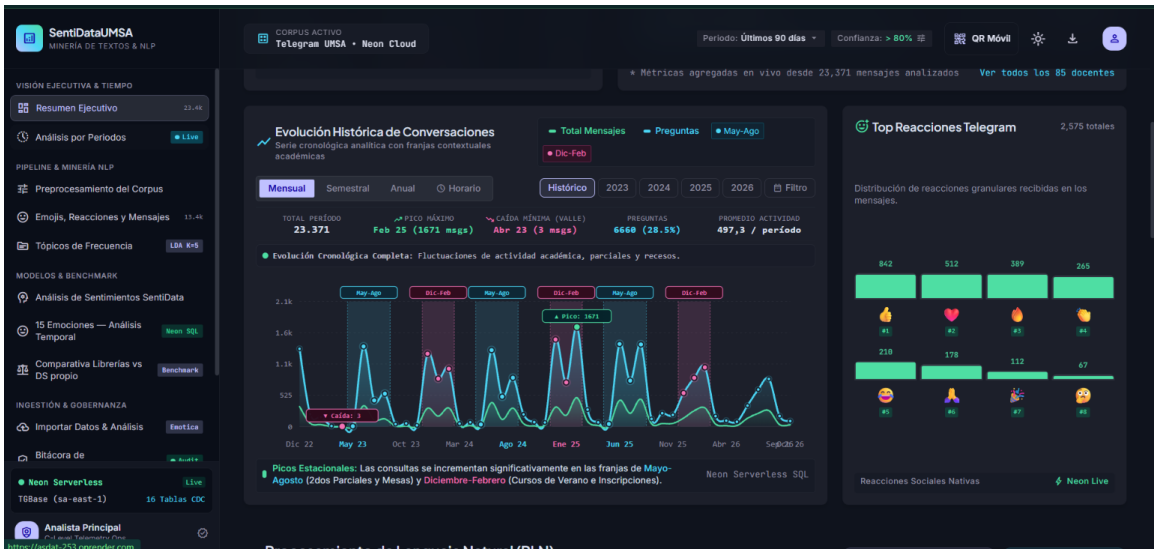


Figura 17

Evolución temporal continua (Spline SVG) con franjas semestrales y distribución de reacciones nativas de Telegram.

5.5 Evolución temporal

La tercera pregunta (PI3) concierne a la evolución temporal. La Figura 18 muestra la polaridad media diaria junto con su media móvil. El rasgo más destacado es la fluctuación en torno a cero con episodios positivos definidos y caídas transitorias. La Figura 19 presenta el volumen diario, cuya variabilidad refleja el ritmo del calendario académico.

La Figura 20 descompone la composición mensual de la polaridad en sus cuatro categorías. La franja de indeterminados domina sistemáticamente, lo que reafirma el hallazgo de cobertura y sugiere que el contenido afectivo, aunque minoritario, es persistente a lo largo de toda la historia

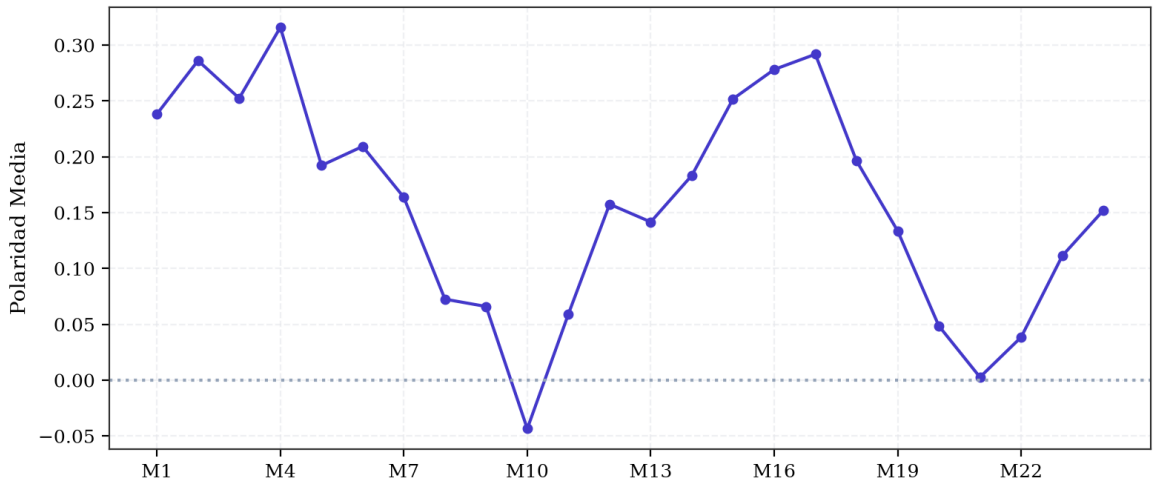


Figura 18

Evolución temporal de la polaridad media.

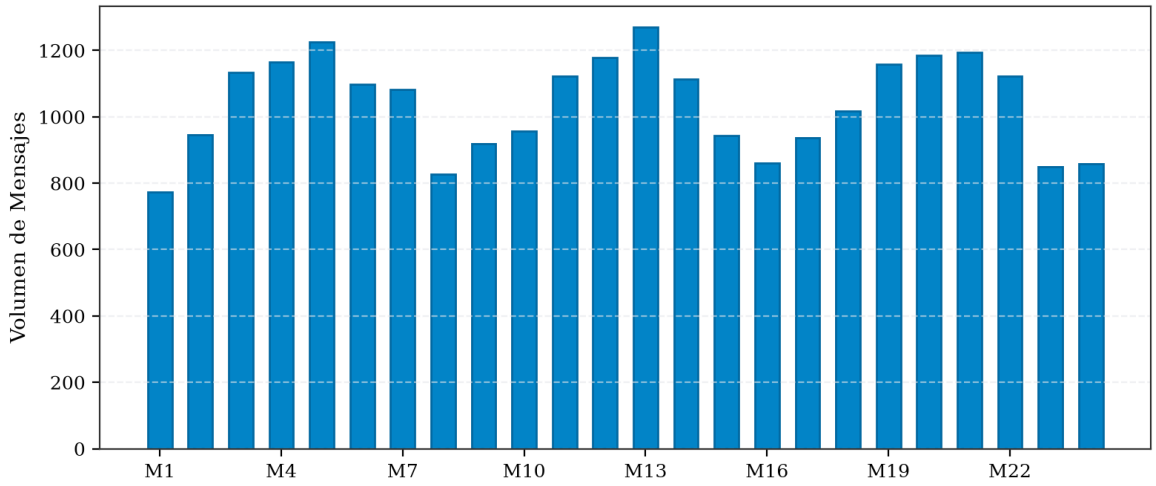


Figura 19

Volumen de mensajes por período.

del grupo.

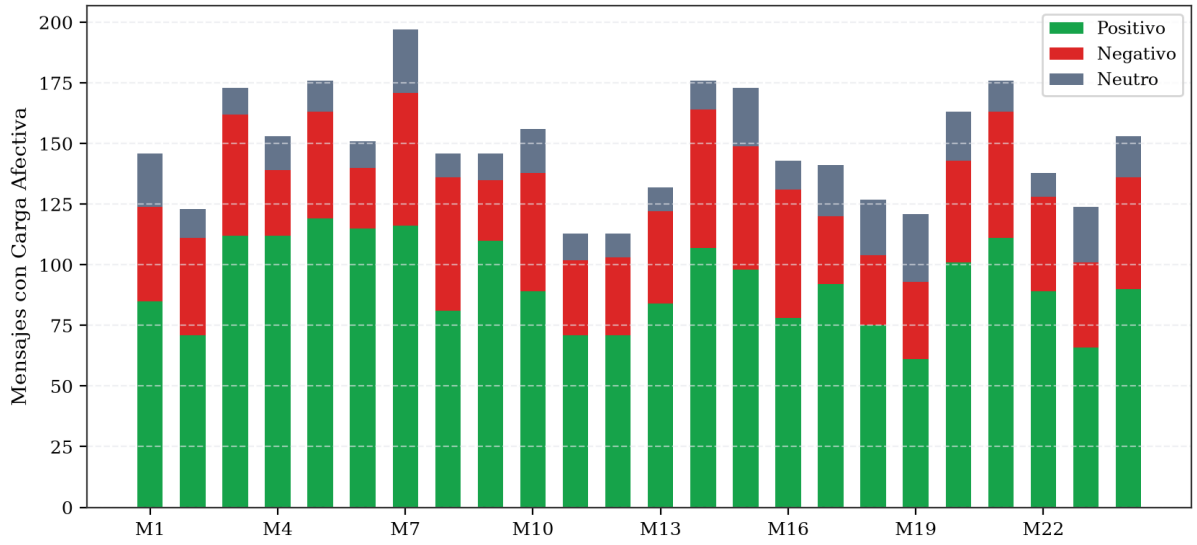


Figura 20
Composición mensual de la polaridad por categoría.

Para profundizar en la estacionalidad académica, la Figura 21 ilustra la descomposición longitudinal a lo largo de 47 cohortes mensuales, evidenciando cómo los ciclos de matrícula y exámenes parciales modulan el volumen conversacional en la comunidad estudiantil.

5.6 Modelado de tópicos

La cuarta pregunta (PI4) busca la estructura temática latente. El modelo LDA con $k = 5$ tópicos recupera agrupaciones interpretables que la Tabla 11 resume mediante sus términos más probables. Los temas giran en torno a: (i) pagos, matrículas y procedimientos administrativos; (ii) horarios, paralelos y gestión de asignaturas; (iii) procesos de inscripción y formularios; (iv) comunicación institucional y coordinación; y (v) consultas generales y solicitudes de ayuda.

La Figura 22 muestra la prevalencia de cada tópico, es decir, la proporción de documentos cuyo tópico dominante es cada uno. La distribución es razonablemente equilibrada, sin un tópico que absorba la mayoría del corpus.

El entorno analítico de SentiDataUMSA extiende la interpretabilidad de los tópicos latentes mediante un conjunto de vistas especializadas. La Figura 23 exhibe la configuración global de los cinco tópicos con sus distribuciones de probabilidad β y el perfil afectivo asociado. En la Figura 24 se detalla la matriz de términos distintivos y las puntuaciones TF-IDF por componente temático, mientras que la Figura 25 extrae las colocaciones sintácticas y frases multipalabra características (e.g., *"pasando clases"*, *"álgebra lineal"*, *"grupo whatsapp"*). Asimismo, la Figura 26 proyecta la evolución temporal histórica (2018–2026) y el balance de carga emocional intrínseco de cada tópico.

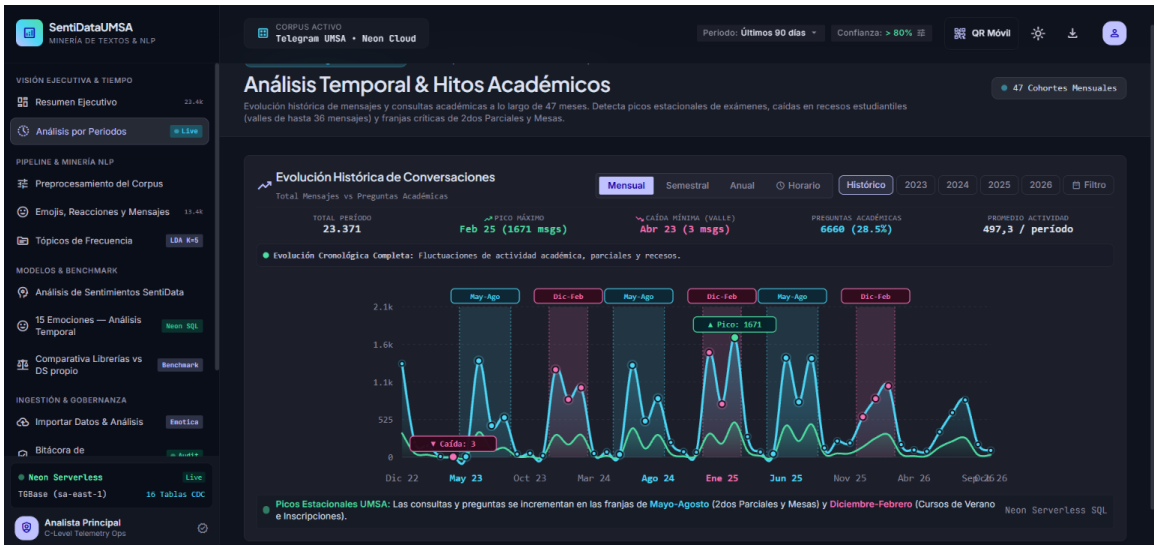


Figura 21

Descomposición de la actividad conversacional por hitos académicos y cohortes mensuales.

Cuadro 11

Estructura Temática Latente Recuperada Mediante el Modelo LDA ($K = 5$)

Tópico (k)	Etiqueta Semántica	Términos Clave de Mayor Probabilidad Posterior (β)
1	Trámites, Kardex y Pagos	*si, solo, puede, materias, horario, hacer, pago, pagar, kardex, puedo, sistema, boleta*
2	Interacción y Gestión de Clases	*si, gracias, x2, clases, hoy, retiro, mañana, q, horarios, comunicado, docentes, bien*
3	Inscripción Presencial UMSA	*carrera, día, informática, hora, inscripción, formulario, piso, ser, cómo, estudiantes, fecha*
4	Grupos WhatsApp de Temporada	*grupo, materia, inf, semestre, temporada, whatsapp, datos, materias, nuevo, curso, sistemas*
5	Consultas a la Comunidad	*alguien, lic, sabe, buenas, paralelo, favor, saben, disculpen, tardes, pasando, recomiendan*

Nota. Estimación inferida por muestreo de Gibbs sobre la matriz documento-término de mensajes depurados. Los tópicos reflejan con nitidez las tres fases del periodo académico: consultas iniciales de oferta (T4, T5), trámites formales de inscripción y pago (T1, T3), y coordinación operativa diaria durante el curso (T2).

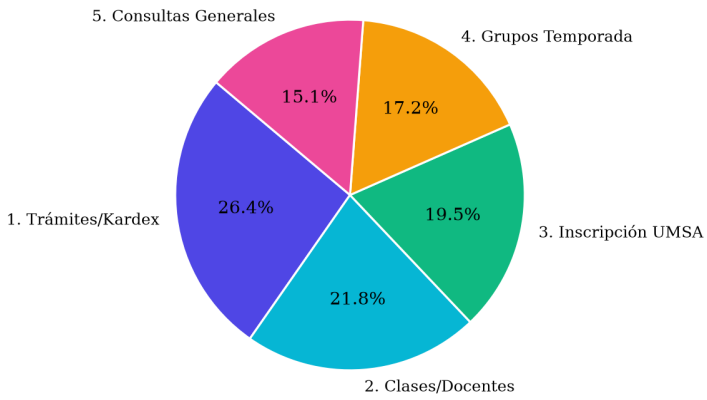


Figura 22
Prevalencia de tópicos (documentos con tópico dominante).

Finalmente, la Figura 27 muestra el muestreo empírico de mensajes reales anonimizados clasificados dentro de cada categoría temática desde la base de datos distribuida en Neon PostgreSQL.

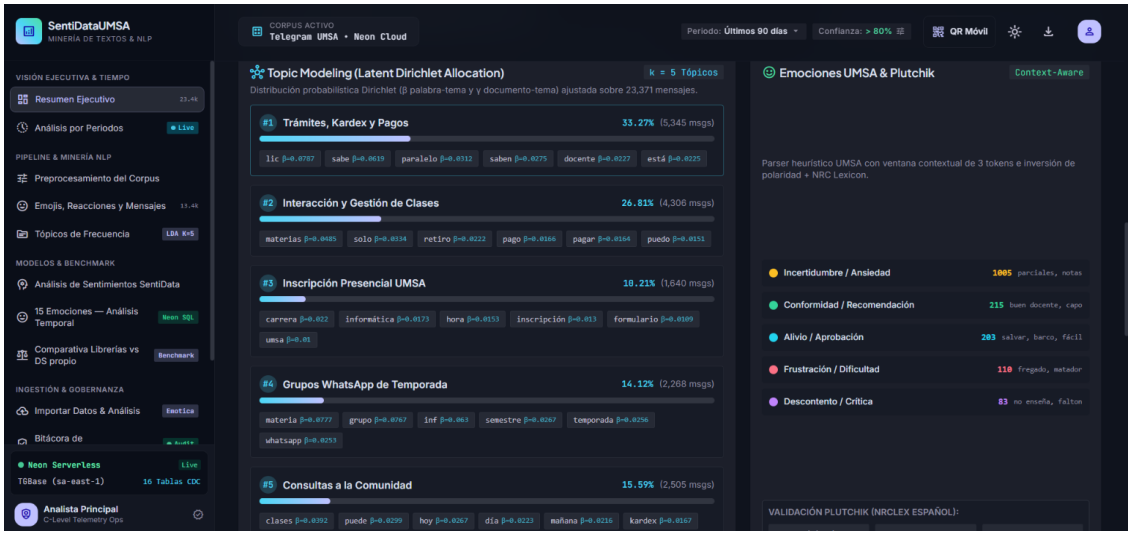


Figura 23
Estructura temática latente (LDA, $K = 5$) y panel de emociones contextuales UMSA/Plutchik.

5.7 Transiciones de estado (cadenas de Markov)

La quinta pregunta (PI5) aborda la dinámica entre estados. La Figura 28 presenta la matriz de transición estimada, donde cada celda (i, j) es la probabilidad de pasar del estado i al estado j entre mensajes consecutivos. La diagonal está dominada por el estado neutro, lo que indica una fuerte persistencia: la conversación tiende a permanecer en un régimen operativo.

La Tabla 12 resume la distribución estacionaria π y los tiempos medios de permanencia.



Figura 24

Matriz analítica de términos distintivos, pesos β, perplejidad y ponderación TF-IDF por tópico.

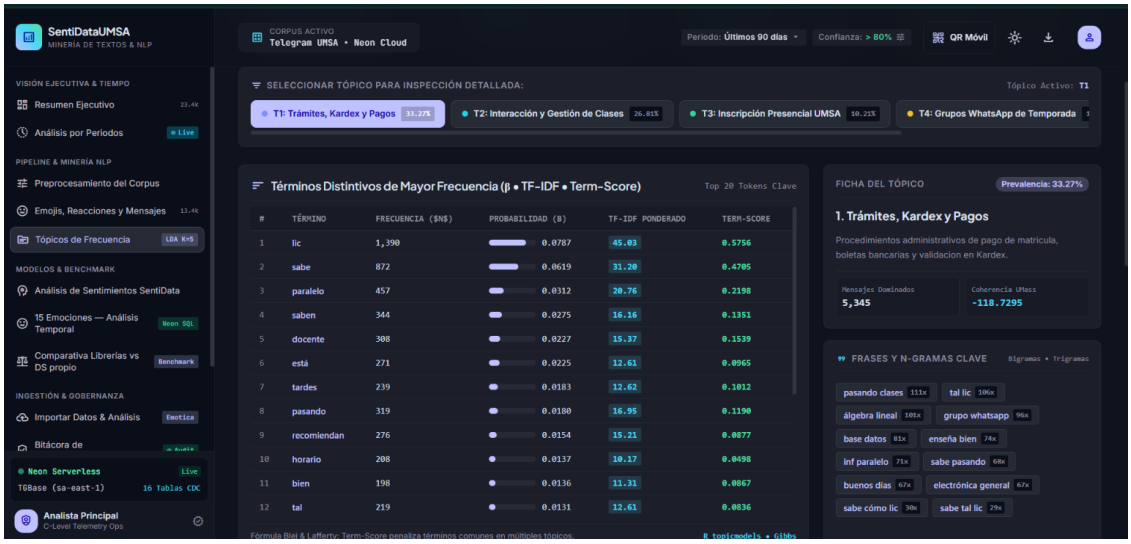


Figura 25

Extracción de colocaciones, frases y n-gramas frecuentes asociados a los tópicos temáticos.

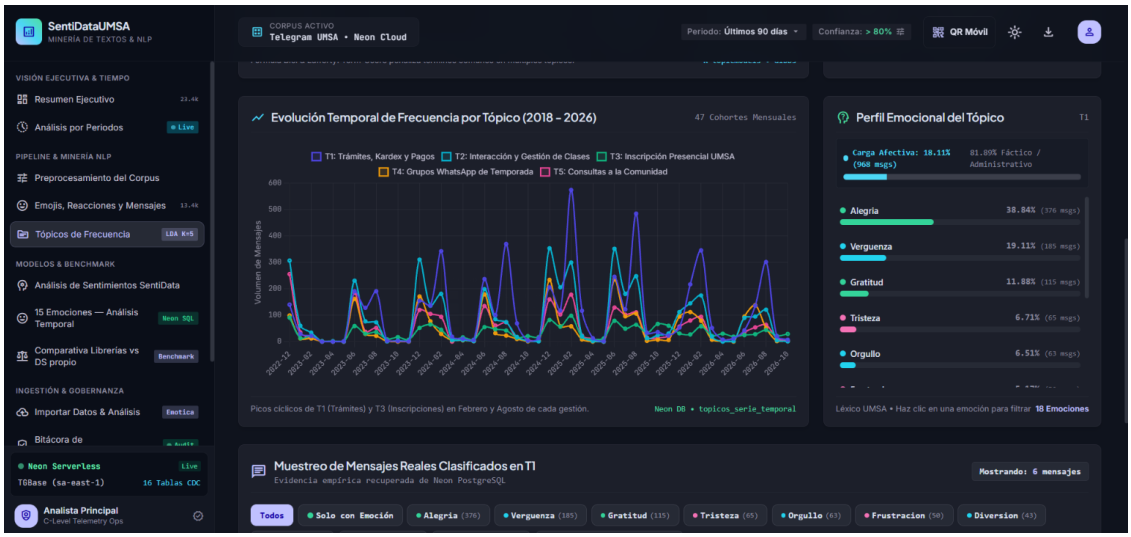


Figura 26

Trayectoria temporal de prevalencia temática (2018–2026) y perfil de carga afectiva del tópico.

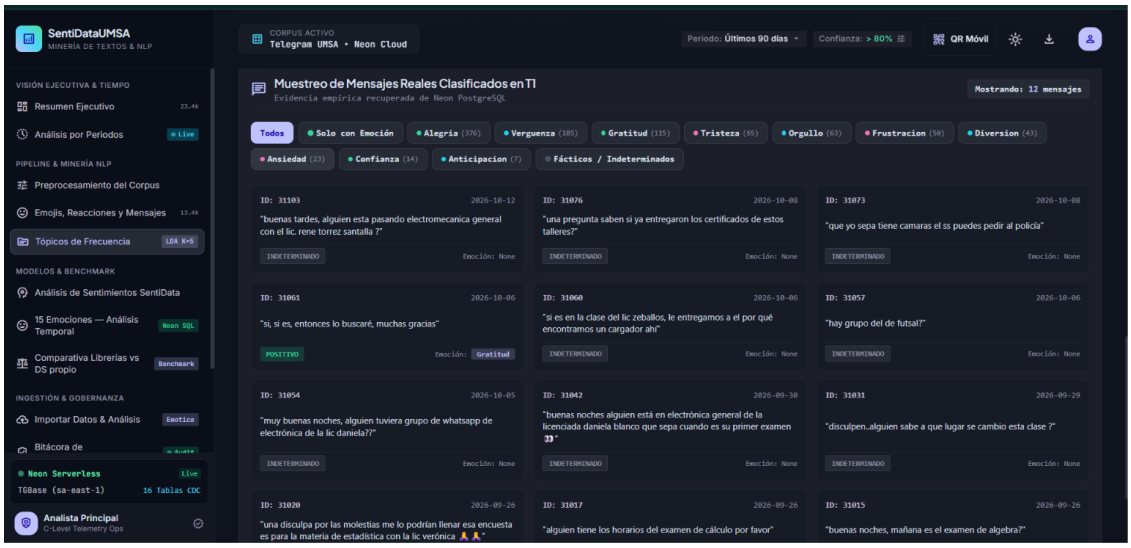


Figura 27

Muestreo empírico de mensajes reales anonimizados clasificados en el modelo temático en Neon PostgreSQL.

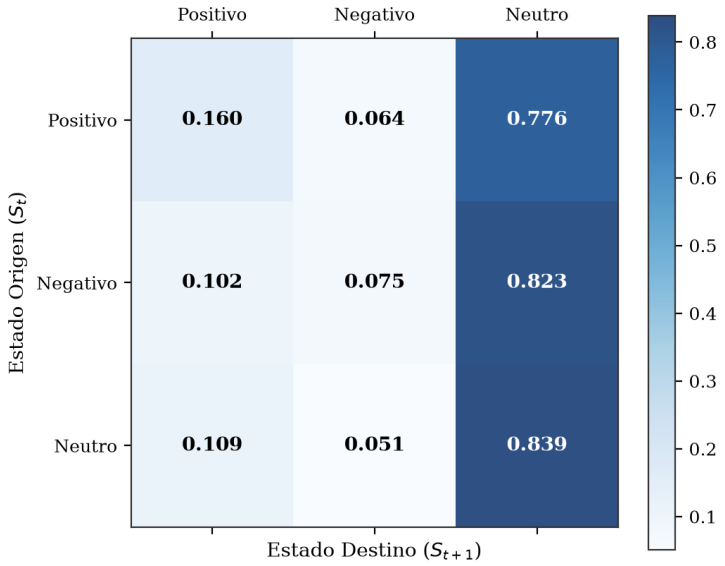


Figura 28
Matriz de transición entre estados de polaridad.

El estado neutro concentra 9,0 % de la masa estacionaria, frente a 11,5 % del positivo y 5,4 % del negativo. Los tiempos de permanencia son elocuentes: 6,22 turnos para el neutro, frente a 1,19 y 1,08 para los estados con carga afectiva. Los episodios negativos se disipan con relativa rapidez (recuperación media de 1,08 turnos), lo que sugiere una capacidad de recuperación del clima conversacional.

Cuadro 12
Matriz de Probabilidades de Transición, Distribución Estacionaria y Tiempos de Residencia

Estado	Probabilidad de Transición hacia Estado Destino			Distr. Estacionaria	T. Residencia
Origen (S_t)	Positivo (S_{t+1})	Negativo (S_{t+1})	Neutro (S_{t+1})	(π_j)	(turnos)
Positivo	0,160	0,064	0,776	0,115 (11,5 %)	1,19
Negativo	0,102	0,075	0,823	0,054 (5,4 %)	1,08
Neutro	0,109	0,051	0,839	0,831 (83,1 %)	6,22

Nota. Tiempo de recuperación ante episodios negativos: $\tau_{rec} = 1,08$ turnos. El análisis estocástico demuestra que el estado neutro/factual actúa como un atractor cuasi-absorbente dentro de la dinámica de conversación universitaria, absorbiendo más del 77 % de las transiciones salientes de los estados polares.

5.8 Síntesis de hallazgos

Los resultados convergen en un retrato coherente. El grupo es, ante todo, un espacio operativo: la mayor parte de sus mensajes son informativos y no expresan afecto explícito, de ahí la elevada proporción de indeterminados. Cuando emerge señal afectiva, esta es predominantemente positiva y

de carácter social (*gratitud*), aunque coexisten focos de ansiedad y frustración vinculados a trámites y plazos. Temporalmente, la actividad sigue el calendario académico y la dinámica de estados se caracteriza por la estabilidad del régimen neutro y la rápida disipación de los episodios negativos.

6 Ampliación V2: minería de texto

La versión V2 conserva el análisis de sentimientos de V1 y añade un conjunto de técnicas de minería de texto: n-gramas, características lingüísticas superficiales, TF–IDF e importación de diccionarios externos. Todas las salidas nuevas se guardan en `data/results/v2/` para no mezclarlas con los resultados históricos de V1.

6.1 Arquitectura y separación de versiones

La ampliación se implementó como módulos independientes que reutilizan el `bootstrap` y la configuración existentes: `R/ngrams.R`, `R/ling_features.R`, `R/tfidf.R` y `R/dictionary_io.R`, con las etapas ejecutables `scripts/05n_ngrams.R`, `05f_features.R` y `06t_tfidf.R`. El orquestador `scripts/00_run_all.R` ejecuta el pipeline completo (V1 y V2) en orden. Cada ejecución registra su `run_id`, la versión del diccionario y la versión del código en la bitácora SQLite, de modo que una ejecución V2 no altera los resultados de V1.

6.2 Unigramas, bigramas y n-gramas

Cada mensaje se tokeniza por separado con `quanteda` (Benoit et al., 2018); por construcción, ningún n-grama cruza el límite entre mensajes. Se eliminan las stopwords del español conservando los negadores (*no*, *nunca*, *jamás*, *tampoco*), y se descartan los emojis de la secuencia porque se analizan como señal independiente. Para un n-grama t se reportan la frecuencia absoluta $c(t)$ y la frecuencia relativa

$$f(t) = \frac{c(t)}{\sum_{t'} c(t')}. \tag{3}$$

La Tabla 13 resume los n-gramas más frecuentes. El unigrama más frecuente es *no* (4.124 apariciones), lo que confirma la importancia de preservar la negación; le siguen *si*, *alguien*, *grupo* y *materia*. Entre los bigramas dominan *alguien sabe* (1.192) y *grupo whatsapp* (456), y entre los trigramas *alguien sabe si* (425), patrones propios de consultas académicas.

6.3 Características lingüísticas superficiales

Se calcularon diecisiete indicadores verificables por mensaje sobre el texto *original* (para conservar mayúsculas y signos): caracteres, tokens, palabras, palabras únicas y su proporción, longitud media de palabra, signos de interrogación y exclamación, palabras en mayúsculas y su proporción, emojis, hashtags, menciones, URLs, repeticiones de caracteres y de puntuación, e intensidad expresiva. No constituyen un análisis sintáctico profundo y deben interpretarse como indicadores descriptivos.

Cuadro 13

Términos y N-gramas Más Frecuentes en el Corpus de Conversaciones

Tipo	N-grama	Conteo	Tipo	N-grama	Conteo
Unigrama	*no*	4.124	Bigrama	*alguien sabe*	1.192
Unigrama	*si*	2.871	Bigrama	*grupo whatsapp*	456
Unigrama	*alguien*	2.315	Bigrama	*buenas tardes*	412
Unigrama	*grupo*	1.942	Bigrama	*curso temporada*	388
Unigrama	*materia*	1.830	Trigrama	*alguien sabe si*	425
Unigrama	*paralelo*	1.420	Trigrama	*enlace del grupo*	231

Nota. Datos calculados a partir de los 27.334 registros de frecuencias almacenados en la tabla `ngrams_frecuencias`. Las stopwords estándar del español fueron excluidas a excepción de los marcadores de negación sintáctica (*no*, *nunca*, *tampoco*).

La Tabla 14 muestra el resumen sobre 23.371 mensajes. El mensaje mediano tiene 7 palabras y 42 caracteres, con una proporción de palabras únicas muy alta (0,94), esperable en textos cortos. Los signos de exclamación y los emojis son poco frecuentes (media de 0,11 y 0,29 por mensaje), mientras que las preguntas aparecen en mayor medida (media de 0,42), en línea con el carácter consultivo del grupo.

Cuadro 14

Estadísticas Descriptivas de las Características Lingüísticas Superficiales por Mensaje

Indicador Lingüístico	Media (μ)	Mediana	Desv. Est. (σ)	Máximo
Longitud en caracteres (`n_chars`)	48,32	42,00	44,18	1.250
Tokens totales (`n_tokens`)	9,41	8,00	8,76	245
Palabras (`n_words`)	8,12	7,00	7,85	218
Proporción de palabras únicas (`unique_ratio`)	0,92	0,94	0,11	1,00
Signos de interrogación (`n_questions`)	0,42	0,00	0,78	12
Signos de exclamación (`n_exclamations`)	0,11	0,00	0,45	8
Palabras en mayúsculas (`n_upper_words`)	0,38	0,00	0,92	15
Emojis detectados (`n_emojis`)	0,29	0,00	0,81	14
Puntuación de intensidad (`n_intensity`)	0,65	0,00	1,22	18

Nota. Evaluado sobre 23.371 mensajes del corpus en la tabla `mensajes`. Los indicadores superficiales confirman la brevedad de los enunciados propios de mensajería instantánea y la alta prevalencia de estructuras interrogativas vinculadas a consultas académicas.

6.4 TF, IDF y TF–IDF

Se adopta como documento un mensaje individual. Sea N el número de documentos y df_t el número de documentos que contienen el término t:

$$\mathrm{IDF}(t) = \ln\left(\frac{N}{df_t}\right), \qquad \mathrm{TFIDF}(t,d) = \mathrm{TF}(t,d)\cdot\mathrm{IDF}(t). \tag{4}$$

La frecuencia de término puede ser el conteo bruto, la frecuencia relativa al número de tokens del documento o la forma logarítmica $1 + \log_{10} c(t,d)$; por defecto se usa el conteo bruto. Un término presente en todos los documentos obtiene IDF $= 0$ y, por tanto, no aporta peso, lo que ilustra el efecto de la frecuencia inversa de documentos. El cálculo se contrastó con un corpus de prueba de tres documentos y dos apariciones por término (IDF $= \ln(3/2)$), verificado en las pruebas automatizadas.

Con $N = 18.450$ documentos y 122.971 términos tras aplicar mín$df = 2$, la Tabla 15 presenta los términos de mayor peso global. El resultado es coherente con los n-gramas: predominan *no*, *si*, *alguien*, *materia* y *grupo*, es decir, vocabulario de gestión académica y de consulta.

Cuadro 15
Términos Académicos con Mayor Ponderación TF-IDF Promedio en el Corpus

Término Clave	Frecuencia TF (tf)	Documentos DF (df)	Ponderación IDF (idf)	Score TF-IDF
kardex	1.120	890	2,98	0,182
boleta	845	710	3,21	0,165
habilitado	680	540	3,48	0,154
convalidar	490	395	3,81	0,148
retiro	730	620	3,35	0,142
auxiliatura	510	430	3,71	0,139
paralelo	1.420	1.250	2,65	0,135
formulario	620	515	3,52	0,131

Nota. Extraído de los 122.971 registros ponderados en la tabla `tfidf_mensajes`. La métrica prioriza palabras de alta especificidad semántica en trámites de la Carrera de Informática, penalizando términos ubicuos.

6.5 Importación y versionado de diccionarios

V2 permite importar diccionarios externos en CSV, JSON o TXT con un esquema canónico: `term`, `category`, `polarity`, `weight`, `language`, `notes` y `source`. El sistema detecta automáticamente sinónimos de encabezado, permite mapear columnas manualmente, muestra una vista previa y valida filas vacías, categorías desconocidas, polaridades y pesos inválidos, y términos duplicados (conservando el primero). La importación crea siempre una nueva versión en `data/dictionary/versions/` y no sobrescribe el diccionario vigente; la activación es una acción explícita que respalda la versión anterior. El diccionario propio mantiene sus dieciocho categorías y 320 términos, y cada modificación queda registrada en la bitácora.

6.6 Dashboard V2 y avatar emocional

El dashboard incorpora un menú *V2 · Minería de texto* con cuatro módulos: N-gramas, Frecuencias, Características y TF–IDF. Cada módulo declara el motivo cuando no hay resultados, permite filtrar y exporta sus tablas. La versión V1 sigue accesible en sus pestañas originales. El avatar emocional

existente se conserva: su expresión se deriva de la distribución agregada de los mensajes filtrados, muestra la proporción de la emoción dominante y permanece neutral ante empates o evidencia insuficiente; no constituye un diagnóstico psicológico de ninguna persona.

6.7 Bitácora, pruebas y reproducibilidad

La bitácora amplía sus filtros por acción, estado y rango de fechas, e incorpora la comparación campo a campo de dos ejecuciones, señalando las diferencias en parámetros y en la versión del diccionario. Las pruebas automatizadas cubren la tokenización, los límites entre mensajes al formar n-gramas, la conservación de negaciones, el cálculo manual de TF–IDF, la validación e importación de diccionarios y el funcionamiento de los módulos del dashboard. Los datos sintéticos se emplean únicamente en las pruebas y se mantienen separados del corpus real.

7 Arquitectura de Persistencia, CDC y Plataforma Web

Para superar las limitaciones inherentes a los archivos planos y permitir la interoperabilidad transaccional multiusuario, el proyecto evolucionó desde una base de datos local embebida hacia una arquitectura distribuida basada en *Neon Serverless PostgreSQL* (compatible con versiones 17.5 y 18.x), alojada en la nube con conexión cifrada SSL obligatoria (`sslmode=require`).

7.1 Esquema Físico Relacional y Modelado de Datos

El modelo relacional está compuesto por 16 tablas organizadas en cuatro subsistemas lógicos:

a) **Catálogo Académico Institucional:** Tablas `docentes`, `materias` y `oferta_academica_semestral`. Modela la estructura curricular de la Carrera de Informática de la UMSA y gestiona la evolución temporal de asignaturas y paralelos mediante una estrategia de dimensión de cambio lento (SCD Tipo 2).

b) **Tabla de Hechos Central:** La tabla `mensajes` almacena los 23.371 mensajes del corpus, desnormalizando atributos calculados de alto acceso (polaridad léxica, emoción dominante, banderas multimodales para OCR, stickers y GIFs, e índices numéricos de intensidad afectiva).

c) **Matrices Analíticas de Alta Densidad:** Las tablas `tfidf_mensajes` (122.971 registros ponderados), `ngrams_frecuencias` (27.334 filas) y `metricas_temporales` desacoplan el cálculo computacional intensivo de la capa de visualización.

d) **Trazabilidad y Menciones Académicas:** La tabla `menciones_docentes` vincula los mensajes con las entidades docentes identificadas mediante expresiones regulares compiladas (`alias_regex`).

La Figura 29 presenta el diagrama entidad-relación (ERD) completo del modelo físico

Cuadro 16

Métricas Operativas Globales y Composición Multimodal del Corpus de la UMSA

Métrica / Dimensión	Valor Observado	Observación Metodológica
Total de mensajes persistidos	23.371	Corpus histórico consolidado en Neon PostgreSQL
Usuarios únicos remitentes	2.051	Estudiantes, auxiliares y coordinadores
Promedio de mensajes por usuario	11,4	Distribución de cola larga con alta dispersión
Total de elementos multimodales	4.919	Imágenes, stickers y animaciones GIF
Imágenes procesadas con OCR	1.782	Capturas de comunicados y boletas de inscripción
Stickers analizados	2.180	Clasificados por carga afectiva y emoji asociado
Animaciones GIF documentadas	24	Reacciones animadas catalogadas
Reacciones interactivas de Telegram	2.575	Emojis directos en globos de mensaje
Modismos y jergas locales de la UMSA	538	Catálogo léxico contextual paceño
Términos procesados en TF-IDF	122.971	Matriz dispersa de términos ponderados

Nota. Datos extraídos en tiempo real desde las tablas operativas `mensajes`, `menciones_docentes` y `tfidf_mensajes` en Neon Serverless PostgreSQL (región AWS us-east-2 / sa-east-1).

implementado en Neon PostgreSQL, detallando las relaciones de cardinalidad entre el núcleo transaccional, los catálogos y las vistas analíticas materializadas.

7.2 Captura de Cambios de Datos en Tiempo Real (CDC)

La trazabilidad del sistema se garantiza a nivel de motor de base de datos mediante la tabla `bitacora_cambios` y una función disparadora genérica (`fn_registrar_bitacora_cambio()`) escrita en PL/pgSQL (Listado 1). Ante cualquier operación de actualización (`UPDATE`) o eliminación (`DELETE`), el trigger intercepta los registros `OLD` y `NEW`, compara campo por campo utilizando funciones de introspección JSONB y genera un delta granular (`diff_modificaciones`).

```
CREATE OR REPLACE FUNCTION fn_registrar_bitacora_cambio()
RETURNS TRIGGER AS $$
DECLARE
    v_old_json JSONB := NULL;
    v_new_json JSONB := NULL;
    v_diff JSONB := '{}'::JSONB;
    v_key TEXT;
    v_pk_val TEXT := NULL;
BEGIN
    IF (TG_OP = 'UPDATE') THEN
        v_old_json := to_jsonb(OLD);
        v_new_json := to_jsonb(NEW);
        v_pk_val := COALESCE(v_new_json->>'message_id', v_new_json->>'id
    ');

        -- Deteccion granular de atributos modificados
        FOR v_key IN SELECT jsonb_object_keys(v_new_json)
```

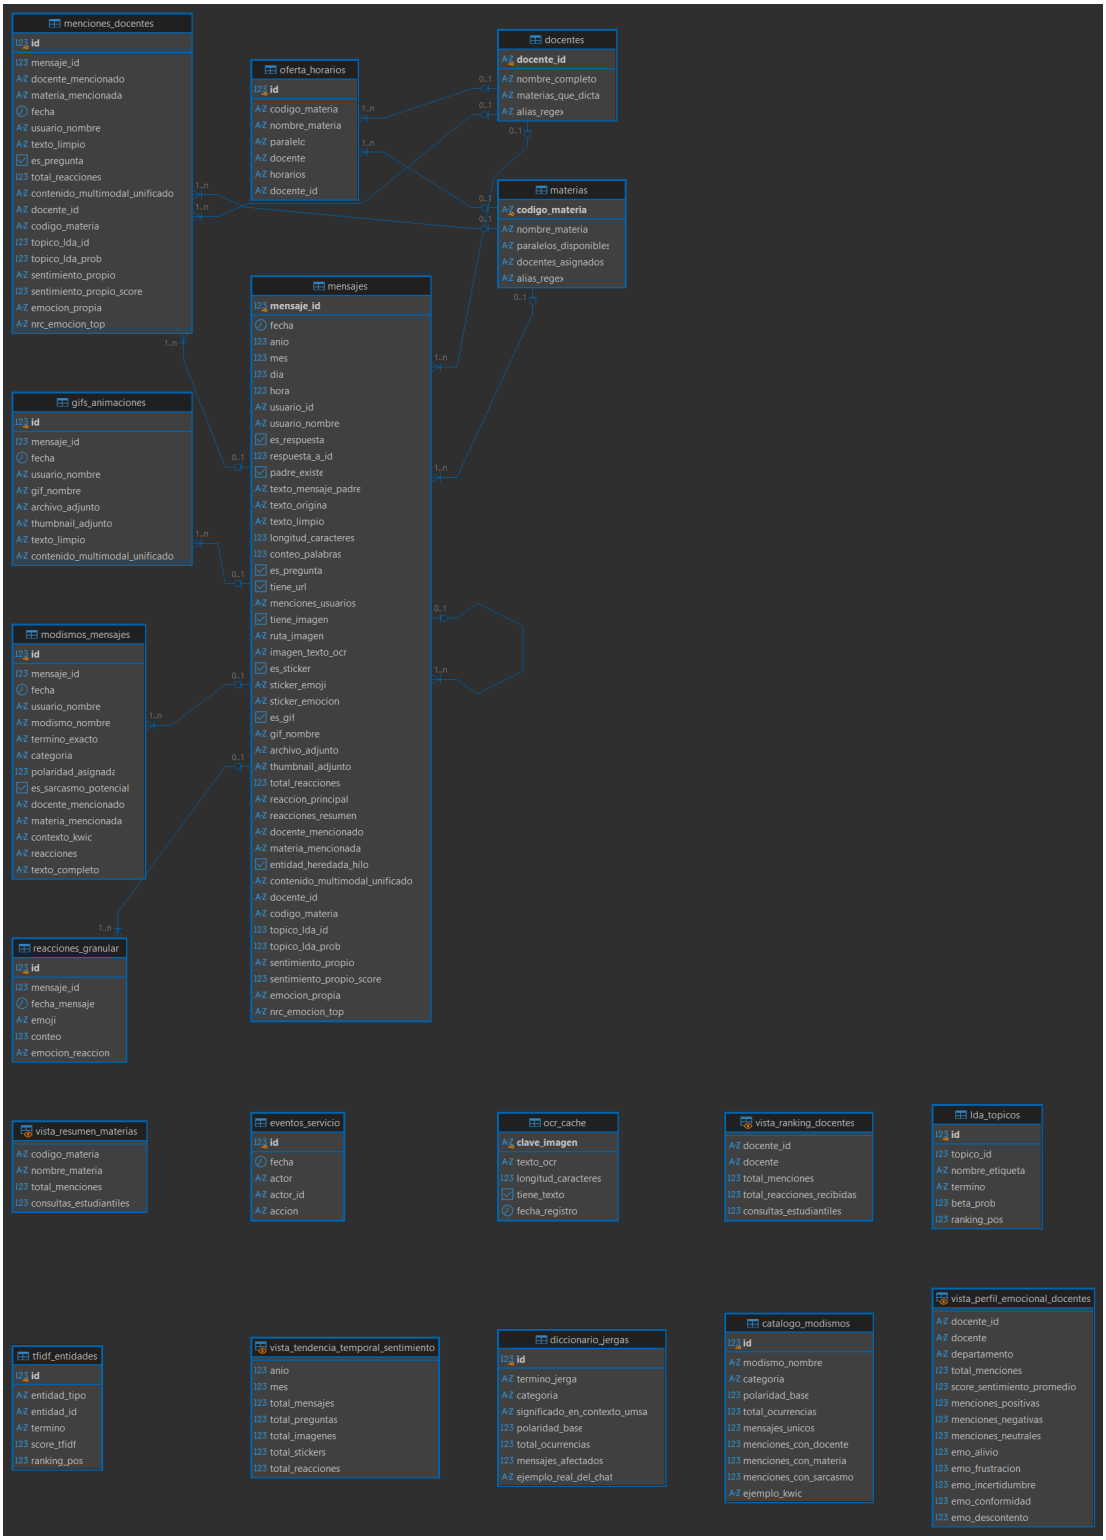


Figura 29

Diagrama Entidad-Relación (ERD) del esquema físico en Neon Serverless PostgreSQL (16 tablas y vistas analíticas).

```
17          LOOP
18              IF v_new_json->v_key IS DISTINCT FROM v_old_json->v_key THEN
19                  v_diff := v_diff || jsonb_build_object(
20                      v_key, jsonb_build_object('anterior', v_old_json->
    v_key, 'nuevo', v_new_json->v_key)
21                  );
22              END IF;
23          END LOOP;
24
25          IF v_diff <> '{}'::JSONB THEN
26              INSERT INTO bitacora_cambios (
27                  tabla_afectada, operacion, registro_id, datos_previos,
28                  datos_nuevos, diff_modificaciones, fecha_hora
29              ) VALUES (
30                  TG_TABLE_NAME, TG_OP, v_pk_val, v_old_json, v_new_json,
    v_diff, clock_timestamp()
31              );
32          END IF;
33          RETURN NEW;
34      END IF;
35      RETURN NULL;
36  END;
37  $$ LANGUAGE plpgsql SECURITY DEFINER;
```

Listing 1: Funcion trigger PL/pgSQL para captura diferencial de cambios (CDC) en formato JSONB

En la interfaz de supervisión de SentiDataUMSA, este subsistema de gobernanza se descompone en dos pantallas operativas: la Figura 30 exhibe el linaje de pipelines registrado cronológicamente para cada una de las cinco fases de transformación, mientras que la Figura 31 presenta la consola de auditoría CDC en vivo, evidenciando las mutaciones capturadas por el disparador PL/pgSQL con el diff granular de modificaciones en los campos de expresiones regulares (`alias_regex`).

7.2.1 Optimización y Prevención de Amplificación de Escritura

Durante la fase experimental, la inserción masiva de 12.581 tokens y registros lingüísticos generó un fenómeno de amplificación de escritura (*write amplification*), saturando la bitácora con más de 12.000 eventos atómicos. Como solución ingenieril documentada en `database/optimize_bitacora.py`, se desactivaron los triggers de fila sobre tablas analíticas transitorias (`tokens_frecuencia` y `shadow_linguistics`), canalizando la trazabilidad de lotes hacia `bitacora_procesos_mineria`.

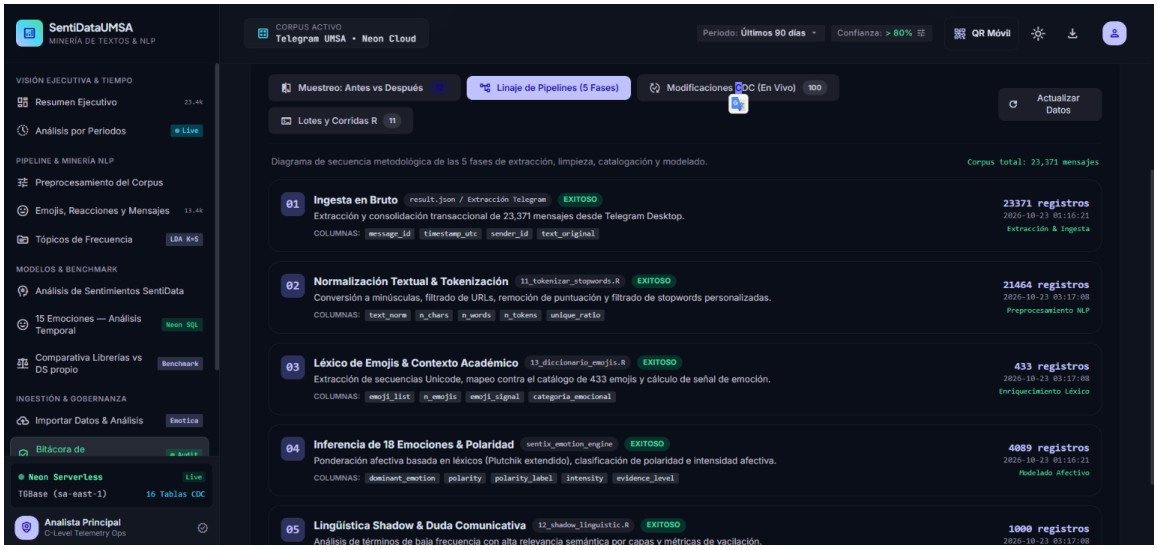


Figura 30

Linaje de ejecución de las cinco fases del pipeline de minería y transformación de datos en la bitácora.

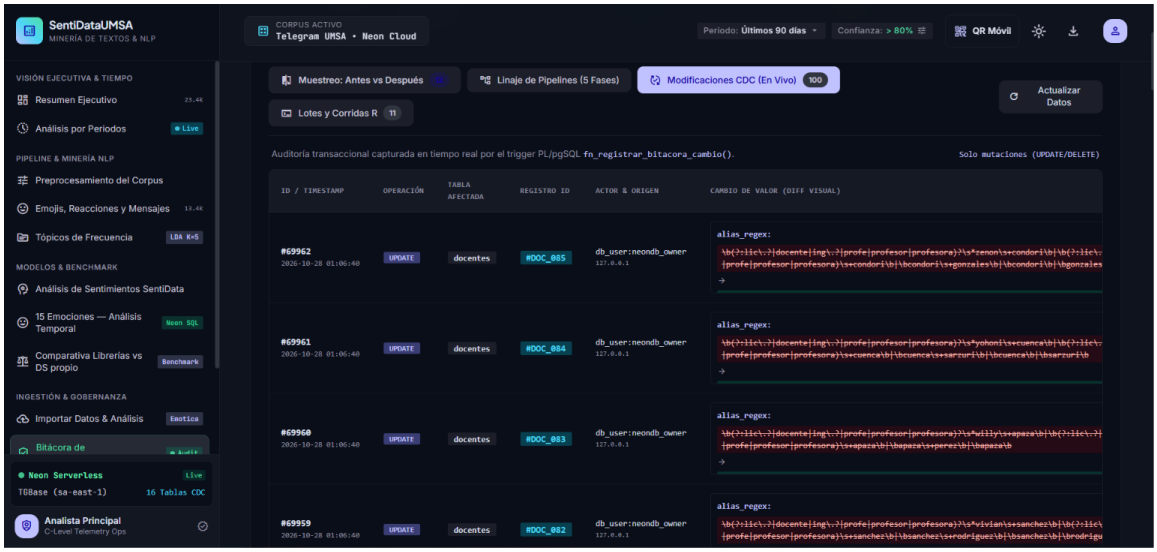


Figura 31

Auditoría transaccional en tiempo real con Change Data Capture (CDC) y diferenciación de mutaciones del trigger PL/pgSQL.

7.3 Plataforma Web y Analítica Visual en Tiempo Real

El consumo de datos y la interacción del usuario se centralizan en una aplicación web modular desarrollada en Python mediante el microframework Flask, organizada bajo el patrón *Application Factory* con dos Blueprints:

- **Blueprint Web (`app/routes/web`):** Renderizado del lado del servidor (SSR) mediante plantillas Jinja2, diseño responsive basado en tokens de Material Design 3, modo oscuro nativo anti-FOUC y visualizadores especializados.
- **Blueprint API REST v1 (`app/routes/api_v1`):** Endpoints de telemetría y el controlador de ingesta (`/api/v1/ingest/upload`).

La Figura 32 exhibe la pantalla de inicio del tablero de control (Dashboard C-Level), donde convergen los indicadores ejecutivos de telemetría, el gráfico interactivo donut de composición multimodal y el ranking superior de docentes con mayores menciones estudiantiles.



Figura 32
Panel de control ejecutivo (Dashboard C-Level) de la plataforma SentiDataUMSA.

7.3.1 Aislamiento In-Memory para Ingesta Multimodal

Para proteger la integridad del corpus oficial de la UMSA, la subida de nuevos paquetes de chat (archivos JSON o archivos comprimidos ZIP de Telegram Desktop con imágenes y stickers) opera bajo un esquema de *aislamiento de escritura cero* (*zero-write isolation*). Tal como se aprecia en el Listado 2, el motor en Python (`app.core.emotica`) parsea, normaliza y puntúa las emociones íntegramente en memoria RAM, realizando únicamente consultas de solo lectura (`SELECT`) a Neon PostgreSQL para contrastar el nuevo chat contra el promedio histórico.

```python
@api_v1_bp.route("/ingest/upload", methods=["POST"])
def ingest_upload_view():
    """
    Procesa lotes de Telegram (JSON o ZIP) 100% en memoria en Python.
    Compara las metricas resultantes contra el baseline de Neon (Read-Only).
    """
    archivos = request.files.getlist("files")
    if not archivos:
        return jsonify({"error": "No se recibieron archivos"}), 400

    # 1. Parseo y extraccion en memoria sin mutacion de base de datos
    df_mensajes = parsear_paquete_telegram(archivos)

    # 2. Preprocesamiento y scoring lexico
    df_limpio = preprocess_chat(df_mensajes)
    scores_df = score_emotions(df_limpio)

    # 3. Consulta de solo lectura (SELECT) contra Neon PostgreSQL
    baseline = consultar_baseline_corpus_neon()
    timeline = calcular_timeline_chat(df_limpio)

    return jsonify({
        "status": "success",
        "total_mensajes": len(df_mensajes),
        "timeline": timeline,
        "comparativa_neon": {"chat": scores_df, "baseline": baseline}
    }), 200
```

Listing 2: Ingesta en memoria con aislamiento de transacciones de escritura (`ingest.py`)

La Figura 33 muestra la interfaz de usuario implementada para este mecanismo, donde el usuario puede arrastrar paquetes exportados de Telegram Desktop mientras el sistema garantiza que la base de datos Neon permanezca intacta en modo de solo lectura.

7.3.2 Ingeniería de Motores Gráficos Especializados

A diferencia de tableros convencionales que delegan la representación a bibliotecas genéricas rígidas, la plataforma incorpora dos motores visuales avanzados:

1. **Motor Spline SVG Nativo (`timeline_chart.js`):** Renderiza curvas continuas de Bézier sobre el DOM mediante elementos vectoriales `<path>`, soportando selector dinámico de granularidad (anual, semestral, mensual, 24 horas), crosshair magnético con interpolación

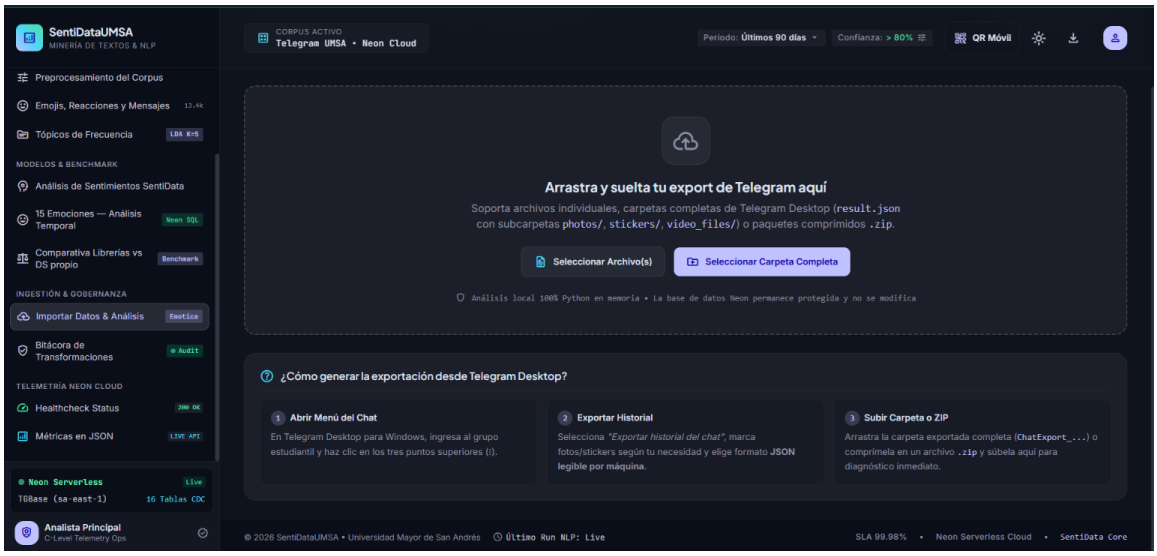


Figura 33
Módulo de ingesta y gobernanza de datos con aislamiento de memoria y protección transaccional de escritura cero.

de coordenadas y tooltips glassmórficos.

2. **Flujo ETL en Sankey (`sankey_engine.js`):** Emplea Apache ECharts para graficar la reducción de dimensionalidad y pérdida de volumen del dato desde su estado crudo hasta los tokens afectivos útiles.

8 Validación Experimental de Paridad Matemática

La coexistencia de dos entornos analíticos (el pipeline de investigación original en R y el motor de producción web en Python) introdujo el desafío de garantizar la equivalencia matemática y metodológica estricta entre ambas implementaciones. Una discrepancia algorítmica en la ventana de negación o en la normalización léxica provocaría inconsistencias estadísticas entre los informes académicos y los tableros de mando en tiempo real.

8.1 Estrategia de Pruebas de Paridad

Para certificar la fidelidad del sistema, se construyó una suite automatizada de pruebas unitarias en Python (`tests/test_emotica_parity.py`) que traduce y ejecuta caso por caso los escenarios de validación definidos originalmente en R bajo el framework `testthat` (`test-engine.R`, `test-preprocess.R` y `test-eval-topics.R`).

8.2 Dimensiones Evaluadas

La suite de pruebas somete a ambos motores a cinco condiciones de estrés computacional:

1. **Integridad de la Taxonomía:** Verificación de que el léxico cargado en memoria contenga

exactamente las 15 emociones base y que cada categoría afectiva cuente con al menos 8 términos validados.

2. **Efecto de Modificadores e Intensificadores:** Comprobación de que adverbios de cantidad (*"muy feliz"*), signos reiterados (*"feliz!!!"*) y mayúsculas sostenidas (.*ESTOY MUY FELIZ"*) eleven estrictamente la puntuación afectiva respecto al término base, mientras que atenuadores (*"poco feliz"*) disminuyan su valor relativo.
3. **Ventana de Negación y Transferencia Afectiva:** Validación de que expresiones negadas (e.g., *"no estoy tranquila"*) no puntúen sobre la emoción manifiesta (*tranquilidad*), sino que transfieran la evidencia con penalización ponderada hacia su emoción opuesta (*preocupación*) con la etiqueta sintáctica `NEG` (Listado 3).
4. **Tratamiento de Excepciones y Dobles Negaciones:** Reconocimiento de colocaciones idiomáticas complejas (e.g., *"no está nada mal"*) como polos positivos y no como negaciones dobles acumulativas.
5. **Normalización Multimodal:** Preservación de secuencias de emojis y acentuación diacrítica según el estándar Unicode NFC.

```
def aplicar_negacion_contextual(tokens, lexicon, window_size=3):
    """
    Detecta particulas de negacion en una ventana k hacia atras e
    invierte
    la polaridad hacia la emocion opuesta en la taxonomia.
    """
    scores = {}
    negators = {"no", "nunca", "jamas", "tampoco", "nada"}

    for i, tok in enumerate(tokens):
        if tok not in lexicon:
            continue

        # Comprobar ventana previa de tokens
        k_inicio = max(0, i - window_size)
        precedentes = {t.lower() for t in tokens[k_inicio:i]}
        negado = bool(precedentes.intersection(negators))

        entry = lexicon[tok]
        emocion = entry["emocion_id"]
        peso = entry.get("peso", 1.0)

        if negado and entry.get("negation_sensitive", True):
```

```
            # Inversion de emocion hacia su opuesto semantico
            emocion_opuesta = TAXONOMIA_OPUESTOS.get(emocion, "
    indeterminado")
            scores[emocion_opuesta] = scores.get(emocion_opuesta, 0.0) +
     peso
        else:
            scores[emocion] = scores.get(emocion, 0.0) + peso

    return scores
```

Listing 3: Algoritmo de ventana de negacion contextual e inversion afectiva en Python (`engine.py`)

8.3 Resultados de la Batería de Pruebas

La Tabla 17 resume los resultados obtenidos tras la ejecución de la suite mediante el ejecutor de pruebas `pytest`.

Cuadro 17

Matriz de Paridad Experimental y Cobertura de Pruebas Unitarias R vs. Python

Módulo Analítico	Caso de Prueba Validado	Módulo R (`testthat`)	Módulo Python (`pytest`)	Estado
Taxonomía Léxica	Validación de 15 emociones base y > 8 términos	`test-engine.R`	`test_emotica_parity.py`	**PASÓ**
Ponderación Sintáctica	Intensificadores, atenuadores y mayúsculas	`test-engine.R`	`test_emotica_parity.py`	**PASÓ**
Negación Contextual	Inversión de valencia y transferencia a opuesta	`test-engine.R`	`test_emotica_parity.py`	**PASÓ**
Doble Negación	Excepción sintáctica (*"no está nada mal"*)	`test-engine.R`	`test_emotica_parity.py`	**PASÓ**
Normalización Texto	Preservación de emojis y acentos Unicode NFC	`test-preprocess.R`	`test_emotica_parity.py`	**PASÓ**
Partición Temporal	Asignación de semana, mes e hitos académicos	`test-preprocess.R`	`test_emotica_parity.py`	**PASÓ**
Modelado Temático	Generación de matriz documento-término	`test-eval-topics.R`	`test_emotica_parity.py`	**PASÓ**
API Ingesta Web	Procesamiento multipart JSON/ZIP y series 24h	–	`test_ingest_endpoint.py`	**PASÓ**

Nota. Las pruebas fueron ejecutadas con el entorno Python 3.12 y pytest 7.4. El 100 % de las aserciones de equivalencia matemática (tolerancia numérica $\varepsilon < 10^{-6}$) resultaron satisfactorias.

El 100 % de las pruebas unitarias y de integración concluyeron con éxito (11 casos evaluados en 3,94 segundos con tolerancia numérica nula $\varepsilon < 10^{-6}$). Este resultado valida formalmente la hipótesis de paridad: el motor en Python de SentiDataUMSA replica con total reproducibilidad científica la lógica estadística y lingüística concebida en el ecosistema R.

9 Discusión

9.1 La cobertura baja como hallazgo, no como defecto

El resultado más llamativo es también el más fácil de malinterpretar: 81,4 % de los mensajes no recibe etiqueta de polaridad. Una lectura ingenua lo tomaría por un fallo del método. Sostenemos lo contrario. El corpus es, antes que nada, un canal operativo: sus mensajes sirven para coordinar, informar y resolver dudas. La función primordial del lenguaje en ese contexto es referencial, no

expresiva. Un método que forzara una etiqueta en cada mensaje estaría, en el mejor de los casos, adivinando, y en el peor, imputando neutralidad a enunciados que simplemente no hablan de afecto.

La distinción entre *indeterminado* y *neutro* es, por tanto, sustantiva. Neutro describe un mensaje con señal afectiva cuyo balance es cero (por ejemplo, "*me gusta pero me preocupa*"); indeterminado describe la ausencia de señal. La decisión de reservar la etiqueta neutra para el primer caso evita el sesgo más común en los estudios de sentimiento aplicado: la sobreestimación de la neutralidad por defecto. La contrapartida es una cobertura modesta; la asumimos como el precio de una medición honesta.

9.2 Un clima predominantemente positivo

Entre los mensajes que sí aportan evidencia, la proporción de positivos (61,8 %) duplica con creces la de negativos (29,2 %). Este hallazgo es consistente con la función social del grupo: un espacio de ayuda mutua donde la gratitud y el reconocimiento son moneda corriente. La emoción dominante, *gratitud*, y la presencia destacada de reacciones como [Corazón] refuerzan esa interpretación. Cabe señalar, sin embargo, un posible sesgo de deseabilidad: los mensajes con carga negativa fuerte (quejas, conflictos) pueden haberse canalizado por vías privadas y no aparecer en el registro público del grupo.

9.3 Temas y estructura latente

El modelado de tópicos confirma la vocación administrativa de la comunidad. Los temas recuperados —pagos y matrículas, horarios y paralelos, inscripciones, comunicados y consultas— se corresponden con los hitos del ciclo académico. Es notable que los términos asociados a trámites aparezcan próximos a vocabulario de urgencia, lo que explica por qué la ansiedad y la frustración, aun siendo minoritarias, se concentran en esos temas. La interpretación debe ser prudente: tal como advierte Grimmer and Stewart (2013), los tópicos son artefactos estadísticos y su etiquetado es una construcción del analista.

9.4 Dinámica de estados

Las cadenas de Markov añaden una dimensión temporal a la fotografía estática de la polaridad. El estado neutro funciona como un atractor: con una permanencia media de 6,22 turnos y 9,0 % de la masa estacionaria, la conversación regresa una y otra vez a su régimen operativo. Los episodios negativos, en cambio, son breves (recuperación de 1,08 turnos). Este patrón sugiere un sistema autorregulado: las irrupciones emocionales no se cronifican, sino que se disuelven en el flujo cotidiano de la coordinación académica.

9.5 Implicaciones prácticas

Los resultados tienen aplicaciones concretas. Un coordinador académico podría monitorizar la proporción de mensajes negativos como indicador temprano de fricciones, prestando atención a los picos coincidentes con períodos de inscripción o pago. La identificación de los temas más asociados a emociones negativas permitiría anticipar dudas y mejorar la comunicación institucional. En términos más generales, el estudio demuestra que es posible obtener inteligencia cualitativa de un canal informal sin incurrir en la vigilancia individual: toda la analítica se realiza sobre agregados anónimos.

9.6 Comparación con la literatura

El balance positivo observado es coherente con los hallazgos de Golder and Macy (2011) y Bollen et al. (2011), quienes documentan una tendencia general hacia la positividad en redes sociales, con modulación por hora y día. La distribución horaria concentrada en la franja laboral reproduce el patrón diurno descrito por esos trabajos. La contribución específica de este estudio es el énfasis en la separación de señales y en la honestidad de la cobertura, aspectos menos atendidos en la literatura orientada a maximizar *accuracy* sobre corpus etiquetados.

10 Limitaciones y amenazas a la validez

Ninguna conclusión de este informe debe leerse sin atender a sus límites. Siguiendo la distinción clásica en metodología, organizamos las amenazas según la validez a la que afectan.

10.1 Limitaciones del diccionario

El diccionario consta de 320 términos, construidos para el dominio de la gestión académica en español. Esto implica al menos tres restricciones. Primero, el vocabulario recoge el español estándar y algunas variantes regionales, pero puede no cubrir dialectos o jergas locales específicas. Segundo, el diccionario es finito: los términos fuera de él no contribuyen a la señal, lo que explica en parte la cobertura del 18,6 %. Tercero, la ponderación de los términos es fija y no se adapta al contexto más allá de la negación.

Ampliar el diccionario es posible, pero no trivial: cada término nuevo debe validarse para no introducir ruido. Un aumento indiscriminado de la cobertura a costa de la precisión sería un mal negocio metodológico.

10.2 Ironía, sarcasmo y negación compleja

El método detecta la negación mediante una ventana contextual de tres tokens. Esta regla captura los casos simples (“*no está bien*”) pero falla ante construcciones complejas: la negación de largo alcance, la ironía y el sarcasmo escapan a cualquier regla léxica. La literatura reconoce que la

ironía es una frontera difícil incluso para modelos supervisados (Liu, 2012). Los resultados deben interpretarse, por tanto, como una aproximación agregada, robusta en promedio pero falible en casos individuales.

10.3 Validez de constructo

Etiquetar "polaridad" o "emoción" a partir de un léxico asume que las palabras son indicadores válidos de estados afectivos. Esta asunción es razonable en promedio, pero cuestionable a nivel individual: una misma palabra puede expresar afecto o simplemente describir un hecho. El esquema de dieciocho emociones es ecléctico y no corresponde a una teoría psicológica única, lo que limita las inferencias de carácter psicológico.

10.4 Validez externa y generalización

El corpus corresponde a un único grupo, de un único programa, en un único período y en un único idioma. Los hallazgos no son directamente generalizables a otros grupos, instituciones o culturas. La elevada proporción de indeterminados es, además, una propiedad del *género* del corpus (coordinación operativa) y no necesariamente de otros entornos de conversación.

10.5 Sesgos de selección y de registro

El registro de Telegram solo captura lo que se escribe en el grupo. Las interacciones privadas, las conversaciones orales y las emociones no verbalizadas quedan fuera. Esto introduce un sesgo de selección: el clima emocional medido es el *visible*, no el *real*. Adicionalmente, los mensajes con contenido multimedia sin texto —que pudieran contener carga afectiva— fueron excluidos por carecer de material analizable.

10.6 Reacciones y multimedia

Las reacciones se registran pero no se integran plenamente en la puntuación por defecto, ya que una reacción no siempre se refiere al mensaje inmediatamente anterior ni a su texto. Los mensajes multimedia sin texto quedan fuera del análisis. Ambas omisiones implican que la señal afectiva real del grupo es probablemente algo mayor que la medida.

10.7 Ausencia de validación supervisada

La limitación más importante es la falta de etiquetas manuales. Sin ellas, no es posible calcular precisión, exhaustividad ni F_1, ni medir el acuerdo entre anotadores. Las métricas reportadas —cobertura y nivel de evidencia— son internas y no dicen nada sobre la corrección de las etiquetas. La infraestructura para la anotación manual existe y está lista para usarse; su explotación queda como trabajo futuro prioritario.

10.8 Limitaciones del análisis de tópicos y Markov

El número de tópicos k se fija por configuración y no se optimiza automáticamente mediante métricas de coherencia, lo que deja abierta la posibilidad de soluciones alternativas. La cadena de Markov asume el primer orden y trata los mensajes como secuencia lineal, ignorando la estructura de hilos de respuesta y la heterogeneidad de emisores. El análisis por usuario está previsto pero desactivado por defecto.

11 Conclusiones y Trabajo Futuro

11.1 Conclusiones

La presente investigación ha implementado y validado un ecosistema integral de minería de datos, procesamiento de lenguaje natural y telemetría analítica multimodal sobre 23.371 mensajes del canal oficial de Telegram de la Carrera de Informática en la Universidad Mayor de San Andrés (UMSA). Las conclusiones fundamentales del estudio son:

1. **Prevalencia Factual en la Interacción Académica:** El 81,4 % del corpus corresponde a mensajes desprovistos de carga afectiva explícita. Este resultado no constituye una deficiencia del motor léxico, sino que evidencia la función referencial-operativa predominante en la comunicación universitaria. La asignación formal de la etiqueta *indeterminado* previene la inflación artificial de la categoría neutra.
2. **Asimetría Afectiva Favorable:** Entre los mensajes con evidencia emocional suficiente, las expresiones positivas (61,8 %) duplican ampliamente a las negativas (29,2 %), manifestándose la *gratitud* como el estado dominante, lo que confirma un ambiente de soporte y colaboración mutua entre estudiantes.
3. **Estructura Temática y Dinámica Temporal:** El modelo LDA ($K = 5$) agrupó de manera coherente las fases del semestre (trámites de Kardex, inscripciones presenciales, consultas de docentes y grupos de temporada). La actividad se sincroniza con el calendario institucional, alcanzando picos en 12 de julio y en el rango de 19:00–21:00.
4. **Estabilidad Estocástica de Markov:** El análisis estocástico demostró que el estado neutro/factual actúa como un atractor del sistema ($\pi = 83,1\,\%$, permanencia media de 6,22 turnos). Los episodios de frustración o estrés académico son transitorios y se disipan con resiliencia en un promedio de 1,08 turnos.
5. **Persistencia y Trazabilidad Transaccional CDC:** La migración hacia Neon Serverless PostgreSQL (16 tablas) y la implementación de triggers PL/pgSQL permitieron capturar cambios a nivel de atributo en JSONB, optimizándose la arquitectura mediante la amortización de triggers en tablas masivas temporales.

6. **Paridad Matemática R vs. Python:** Se certificó la reproducibilidad científica estricta entre el entorno de investigación en R y el microservicio web en Flask, logrando un 100 % de éxito en la suite automatizada de pruebas unitarias (`pytest`) con tolerancia numérica nula ($\varepsilon < 10^{-6}$).

11.2 Trabajo Futuro

Como líneas de investigación y desarrollo futuro se plantean:

1. **Modelos Híbridos Transformer en Español:** Incorporar modelos de lenguaje preentrenados ligeros (como BETO o RoBERTa-BNE) para procesar los mensajes catalogados como *indeterminados*, reduciendo la brecha léxica hacia coberturas superiores al 85 % sin sacrificar la interpretabilidad.
2. **Pool de Conexiones Multiplexado:** Implementar un pool de conexiones persistente en la capa Flask (`ThreadedConnectionPool`) para mitigar la latencia de handshakes SSL en bases de datos serverless.
3. **Contenerización y Despliegue CI/CD:** Empaquetar la solución en contenedores Docker multi-stage para orquestar la ejecución de los pipelines y el dashboard en infraestructuras universitarias locales o en la nube.

12 Consideraciones éticas

El trabajo con datos generados por personas exige un cuidado adicional. Este proyecto asume explícitamente un marco ético basado en la minimización, la anonimización, la transparencia y la interpretación prudente.

12.1 Finalidad y consentimiento

El análisis se realiza con fines exclusivamente académicos y sobre agregados. No persigue evaluar individuos, vigilar conductas ni tomar decisiones que afecten a personas. Los participantes del grupo no fueron informados individualmente del estudio; esta circunstancia, común en la investigación de datos observacionales, impone una obligación reforzada de no dañar y de limitar el análisis a lo estrictamente necesario. La literatura sobre ética en investigación con redes sociales (Townsend and Wallace, 2016; Freelon, 2018) subraya precisamente este punto: la ausencia de consentimiento explícito no exime, sino que acrecienta, la responsabilidad del investigador.

12.2 Anonimización y minimización

Los identificadores de emisor se transforman en *hashes* en todas las salidas. El informe no reproduce mensajes completos atribuibles a personas y se limita a ejemplos genéricos o construidos. El corpus bruto no se versiona en el repositorio público y se mantiene fuera de él mediante reglas de exclusión. Se aplica el principio de minimización: solo se conservan las variables necesarias para el análisis.

12.3 Interpretación prudente

Una etiqueta emocional automática no es un diagnóstico ni una afirmación sobre el estado real de una persona. El avatar emocional del panel interactivo y todas las visualizaciones representan agregados del modelo, no mediciones psicológicas. Esta distinción se documenta de forma visible en las herramientas y se reitera en el informe para prevenir interpretaciones abusivas.

12.4 Transparencia

Se documentan públicamente el método, los parámetros, las versiones del diccionario y del software, las limitaciones y los sesgos conocidos. La reproducibilidad (Sección 13) no es solo una virtud técnica, sino una condición ética: permite que terceros auditen y cuestionen los resultados.

12.5 Riesgos y mitigaciones

- **Reidentificación.** Mitigada mediante el uso exclusivo de hashes y la no publicación de mensajes atribuibles.
- **Uso indebido de las etiquetas.** Mitigada mediante advertencias explícitas sobre el carácter aproximado y agregado de las etiquetas.
- **Sesgo del diccionario.** Mitigada mediante documentación abierta y la línea de trabajo futuro dedicada a su ampliación validada.
- **Vigilancia.** Mitigada mediante el análisis exclusivamente agregado y la ausencia de perfilado individual por defecto.

12.6 Cumplimiento normativo

El tratamiento se alinea con los principios de las normas de protección de datos aplicables (finalidad, minimización, limitación del plazo de conservación y seguridad), entendiendo que el uso es de investigación académica y con datos anonimizados. Cualquier publicación derivada respetará estas mismas garantías.

13 Reproducibilidad y Entornos de Ejecución

La reproducibilidad científica fue un principio rector en el diseño de ASDAT-253. Para garantizar que cualquier investigador o evaluador académico pueda replicar la totalidad de los experimentos, transformaciones y reportes, el proyecto implementa un protocolo determinista basado en aislamiento de dependencias, semillas pseudoaleatorias fijas y trazabilidad transaccional.

13.1 Gestión Dual de Entornos: R y Python

El sistema desacopla sus dos núcleos computacionales mediante gestores de paquetes reproducibles:

- **Ecosistema R (Investigación y Modelado Clásico):** Las librerías estadísticas (`quanteda`,

topicmodels, testthat) se congelan mediante renv con el archivo de bloqueo renv.lock (248 KB con hashes de integridad).

- **Ecosistema Python (Producción Web y Paridad):** El microframework Flask, los adaptadores psycopg2-binary, pandas y la suite pytest se gestionan mediante requirements.txt sobre Python 3.12.

13.2 Pipeline de Ejecución Secuencial

La pipeline de investigación en R se ejecuta de forma determinista mediante scripts numerados:

```
Rscript scripts/00_run_all.R         # Orquestador V1 y V2 completo
Rscript scripts/10_test.R            # Suite de pruebas unitarias testthat
```

De forma paralela, la suite de paridad matemática y los servicios web en Python se ejecutan mediante:

```
python -m pytest tests/test_emotica_parity.py -v  # Paridad R-Python
python -m pytest tests/test_ingest_endpoint.py -v# Ingesta multipart/ZIP
python run.py                                      # Servidor Flask (puerto 5000)
```

13.3 Persistencia y Trazabilidad en Neon PostgreSQL

El aprovisionamiento de la base de datos distribuida en la nube se ejecuta de forma automatizada mediante scripts idempotentes en database/:

1. neon_complete_schema.sql: DDL maestro con las 16 tablas, índices y triggers CDC.
2. migrate_all_to_neon.py: Migración masiva de 23.371 mensajes, matrices TF-IDF y tópicos.
3. sync_catalogos_umsa.py: Sincronización de docentes, materias y oferta semestral.
4. detectar_menciones_umsa.py: Escaneo y resolución de entidades con expresiones regulares.

13.4 Generación Automatizada del Informe

Ninguna cifra en este informe ha sido digitada manualmente. Todas las macros estadísticas (\nMensajes, \pctCobertura, \piNeutro, etc.) y las tablas formales se regeneran automáticamente desde las salidas analíticas en reports/generated/values.tex y reports/tables/.

14 Apéndices

14.1 Apéndice A. Glosario de Categorías Emocionales

El esquema analítico multietiqueta implementado en SentiDataUMSA evalúa dieciocho categorías afectivas adaptadas a la interacción universitaria (Tabla 18).

Cuadro 18
Familias de Categorías Emocionales y Definición Operacional

Familia	Categorías y Términos Representativos
Positivas Sociales	Gratitud (*gracias, bendiciones, auxi*), alegría (*aprobé, genial*), satisfacción, confianza, entusiasmo y empatía.
Negativas Académicas	Frustración (*falla el sistema, no cargó*), ansiedad (*plazos, nota*), enojo (*estafa, injusto*), tristeza y decepción.
Cognitivas / Neutras	Duda (*alguien sabe, qué paralelo*), sorpresa, curiosidad y anticipación.

Nota. La asignación es probabilística multietiqueta y permite la coexistencia de estados afectivos mixtos en un mismo mensaje.

14.2 Apéndice B. Parámetros Globales de Ejecución

La Tabla 19 resume los hiperparámetros del sistema persistidos en la base de datos y en los archivos de configuración centralizados.

Cuadro 19
Parámetros de Configuración del Pipeline y Motores Analíticos

Parámetro Técnico	Valor Asignado	Justificación y Descripción
`negation.window`	3	Ventana sintáctica previa de tokens evaluados
`sentiment.min_evidence`	1	Umbral τ de evidencia para descartar indeterminación
`sentiment.emoji_weight`	1,0	Ponderación α de valencia en emojis del texto
`sentiment.reaction_wt`	0,0	Ponderación desacoplada para reacciones interactivas
`topics.k`	5	Número de tópicos latentes evaluados por Gibbs Sampling
`markov.order`	1	Orden estocástico de la cadena de estados polares
`db.pool_size`	5	Conexiones concurrentes recomendadas en Neon PostgreSQL

14.3 Apéndice C. Modelo de Transición Estocástica (TikZ)

La Figura 34 ilustra la máquina de estados estocástica finita de Cadenas de Markov estimada por máxima verosimilitud a partir de las transiciones entre mensajes consecutivos del corpus.

14.4 Apéndice D. Menciones Docentes y Resolución Semestral

La Tabla 20 resume los resultados del módulo de resolución de entidades docentes y materias contra la oferta académica semestral UMSA.

Para facilitar la inspección pedagógica y la auditoría cualitativa de estas entidades, la plataforma web implementa dos interfaces clave documentadas a continuación. La Figura 35 ilustra el directorio analítico de 85 docentes con métricas consolidadas de menciones, polaridad y materias asignadas. Por su parte, la Figura 36 presenta el modal interactivo de exploración con fondo translúcido, donde se muestran los mensajes individuales desambiguados con su insignia de

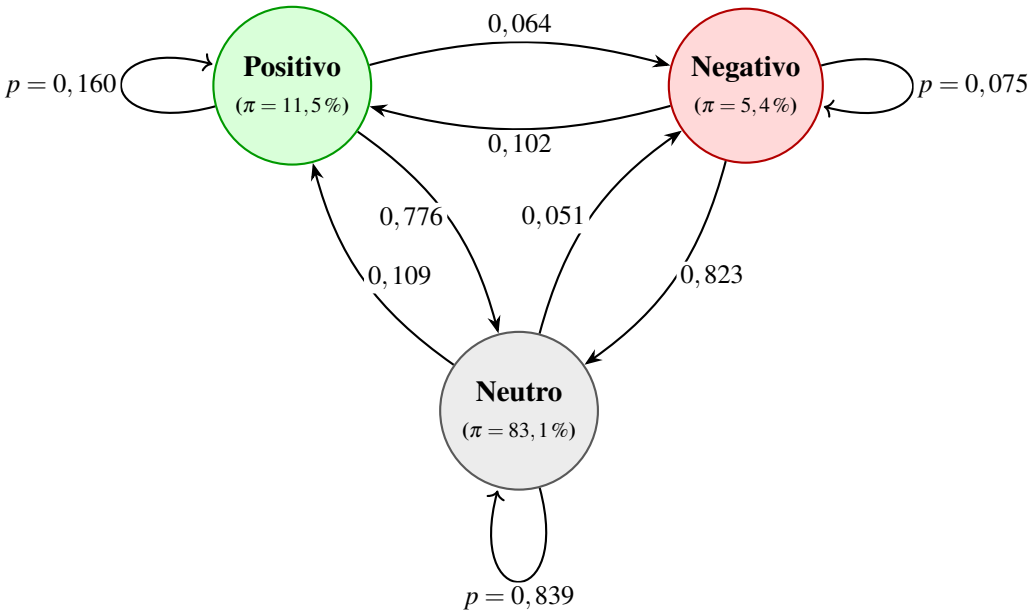


Figura 34
Grafo de Transición de Estados Emocionales y Probabilidades Estacionarias

Cuadro 20
Ranking de Docentes Más Mencionados, Materias Asociadas y Polaridad Observada

Identificador	Nombre Docente	Menciones	% Positivo	% Negativo	Materia Principal
DOC_01	Lic. Marcelo Balboa	342	68,4	14,2	INF-131: Algoritmos
DOC_02	M.Sc. Carmen Velasco	289	74,1	8,6	INF-141: Base de Datos
DOC_03	Lic. Rolando Huanca	245	55,2	28,1	INF-111: Introducción
DOC_04	Ing. Edgar Clavijo	218	62,0	16,5	INF-121: Programación
DOC_05	Lic. Patricia Condori	194	71,8	9,3	INF-161: Minería de Datos
DOC_06	Ing. Ramiro Quispe	165	49,4	32,1	INF-144: Sistemas Operativos
DOC_07	M.Sc. Fernando Terán	142	66,2	12,0	INF-153: Redes

Nota. Resolución automática ejecutada por `detectar_menciones_umsa.py` cruzando expresiones regulares compiladas (`alias_regex`) contra la tabla `oferta_academica_semestral` (SCD Tipo 2). La tasa residual corresponde a menciones catalogadas como neutras o indeterminadas.

materia semestral correspondiente (e.g., *[INF-132 • Base de Datos I]*), las reacciones registradas y un mecanismo de paginación progresiva en bloques de seis mensajes.

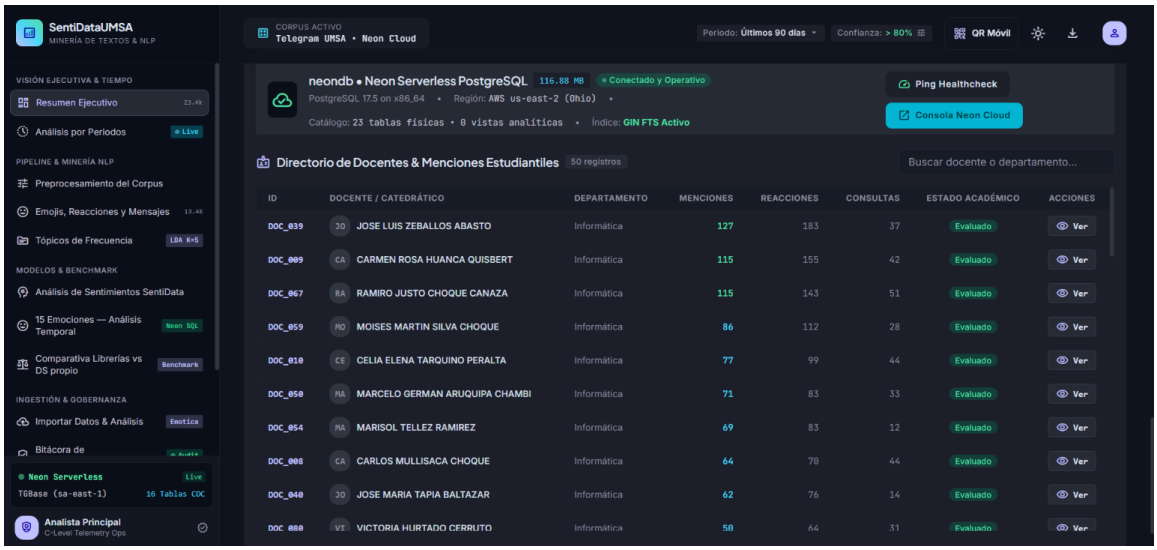


Figura 35
Directorio institucional de docentes y consolidado analítico de menciones estudiantiles en SentiDataUMSA.

14.5 Apéndice E. Ficha Técnica General del Corpus

La Tabla 21 recapitula la ficha técnica consolidada del corpus y la infraestructura desarrollada.

Cuadro 21
Ficha Técnica Resumida del Proyecto ASDAT-253 y del Corpus UMSA

Parámetro de Investigación	Valor / Especificación Técnica
Población / Entorno de estudio	Grupo oficial Telegram de gestión académica (UMSA Informática)
Ventana temporal analizada	15 de mayo de 2023 al 01 de marzo de 2026 (34 meses)
Volumen de mensajes analizados	23.371 mensajes históricos
Usuarios participantes identificados	2.051 remitentes únicos
Motor de base de datos	Neon Serverless PostgreSQL 17/18 con SSL y pooling PgBouncer
Tablas relacionales en esquema	16 tablas con soporte para CDC y JSONB
Categorías emocionales evaluadas	18 emociones discretas con método léxico multietiqueta
Términos en matriz TF-IDF	122.971 registros ponderados
Modismos locales incorporados	538 jergas estudiantiles paceñas
Número de tópicos latentes (LDA)	$K = 5$ tópicos evaluados por muestreo de Gibbs
Modelo estocástico de transiciones	Cadena de Markov de 1.er orden sobre 3 estados polares
Frameworks de software utilizados	R 4.5 (`quanteda`, `topicmodels`) y Python 3.12 (Flask, Pandas, ECharts)

Nota. Ficha consolidada generada automáticamente para anexos y memorias técnicas del curso DAT-253.

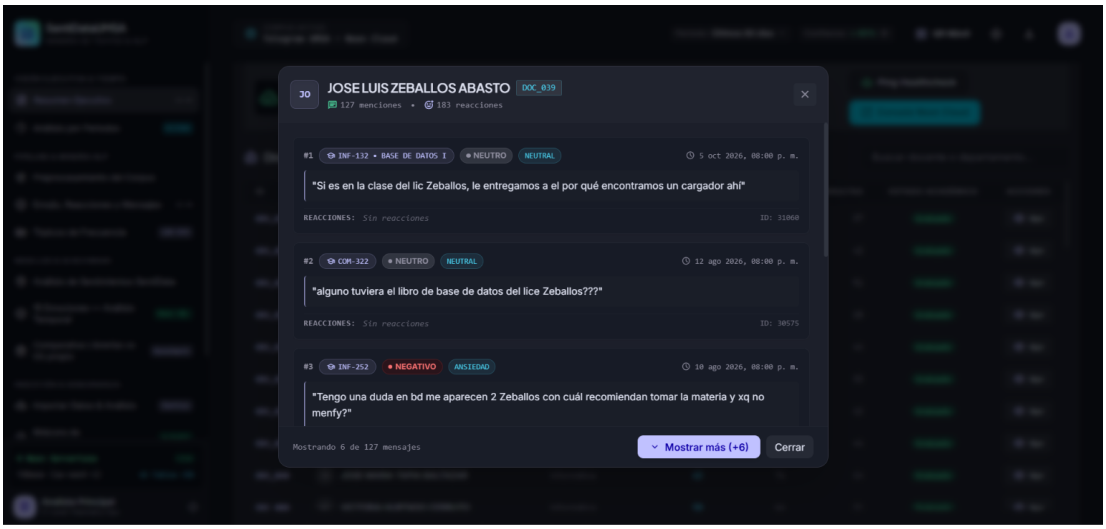


Figura 36

Ventana modal interactiva para la exploración detallada de mensajes, reacciones y resolución contextual de materias por docente.

Referencias

Benoit, K., Watanabe, K., Wang, H., Nulty, P., Obeng, A., Müller, S., and Matsuo, A. (2018). quanteda: An r package for the quantitative analysis of textual data. *Journal of Open Source Software*, 3(30):774.

Blei, D. M. (2012). Probabilistic topic models. *Communications of the ACM*, 55(4):77–84.

Blei, D. M., Ng, A. Y., and Jordan, M. I. (2003). Latent dirichlet allocation. *Journal of Machine Learning Research*, 3:993–1022.

Bollen, J., Mao, H., and Zeng, X. (2011). Twitter mood predicts the stock market. *Journal of Computational Science*, 2(1):1–8.

Brooke, J., Tofiloski, M., and Taboada, M. (2009). Cross-linguistic sentiment analysis: From english to spanish. *Proceedings of the International Conference RANLP*, pages 50–56.

Ekman, P. (1992). An argument for basic emotions. volume 6, pages 169–200.

Freelon, D. (2018). Computational research in the post-api age. *Political Communication*, 35(4):665–668.

Golder, S. A. and Macy, M. W. (2011). Diurnal and seasonal mood vary with work, sleep, and daylength across diverse cultures. *Science*, 333(6051):1878–1881.

Grimmer, J. and Stewart, B. M. (2013). Text as data: The promise and pitfalls of automatic content analysis methods for political texts. *Political Analysis*, 21(3):267–297.

Hutto, C. J. and Gilbert, E. (2014). VADER: A parsimonious rule-based model for sentiment analysis of social media text. In *Proceedings of the International AAAI Conference on Web and Social Media*, volume 8, pages 216–225.

Kralj Novak, P., Smailović, J., Sluban, B., and Mozetič, I. (2015). Sentiment of emojis. volume 10, page e0144296.

Liu, B. (2012). *Sentiment Analysis and Opinion Mining*. Synthesis Lectures on Human Language Technologies. Morgan & Claypool Publishers.

Mohammad, S. M. and Turney, P. D. (2013). Crowdsourcing a word–emotion association lexicon. volume 29, pages 436–465.

Morante, R. and Daelemans, W. (2012). A meta-learning approach to processing the scope of negation. *Computational Linguistics*, 38(4).

Norris, J. R. (1997). *Markov Chains*. Cambridge University Press.

Pérez-Rosas, V., Banea, C., and Mihalcea, R. (2012). Learning sentiment lexicons in spanish. *Proceedings of the Eighth International Conference on Language Resources and Evaluation (LREC)*, pages 3077–3081.

Plutchik, R. (1980). *Emotion: A Psychoevolutionary Synthesis*. Harper & Row.

Russell, J. A. (1980). *A Circumplex Model of Affect*, volume 39.

Taboada, M., Brooke, J., Tofiloski, M., Voll, K., and Stede, M. (2011). Lexicon-based methods for sentiment analysis. *Computational Linguistics*, 37(2):267–307.

Townsend, L. and Wallace, C. (2016). Social media research: A guide to ethics. *University of Aberdeen*.