UNIVERSIDAD MAYOR DE SAN ANDRÉS

FACULTAD DE CIENCIAS PURAS Y NATURALES

CARRERA DE INFORMÁTICA

MINERÍA DE DATOS DAT-253



MINERÍA DE TEXTOS Y MODELADO ESTOCÁSTICO EN CONVERSACIONES ACADÉMICAS UNIVERSITARIAS: UN ENFOQUE HÍBRIDO SOBRE TELEGRAM

ESTUDIANTES:	Univ. Julio Nelson Arias Cruz
	Univ. Yoshua Aaron Cordova Avendaño
	Univ. Imanol Marcelo Moya Condori
	Univ. Iver Samuel Medina Balboa
DOCENTE:	M. Sc. Menfy Morales Rios
PLATAFORMA WEB:	https://asdat-253.onrender.com/
PROYECTO EN GITHUB:	https://github.com/ismedinab96/ASDAT-253

La Paz – Bolivia

2026

Resumen

El presente trabajo de investigación implementa un sistema integral de minería de datos, procesamiento de lenguaje natural (PLN) y telemetría analítica multimodal aplicado a las conversaciones informales de la comunidad estudiantil de la Carrera de Informática de la Universidad Mayor de San Andrés (UMSA), recopiladas mediante la plataforma Telegram durante gestiones académicas y cursos de temporada. El corpus está conformado por 23.371 mensajes y 1.765 usuarios únicos verificados tras la depuración de cuentas de servicio y eventos de bot. Se desarrolló un *pipeline* reproducible de extracción, transformación y carga (ETL) que segrega tres canales independientes de evidencia afectiva (léxico, emojis y reacciones), integra 538 modismos y expresiones locales paceñas, e implementa una ventana sintáctica contextual para la inversión de polaridad por negación. La cobertura léxica efectiva alcanza el 18,6 %, identificándose un 81,4 % de mensajes predominantemente factuales categorizados como *indeterminados*, evitando la imputación artificial de neutralidad. Entre los mensajes con carga afectiva, los positivos (61,8 %) superan ampliamente a los negativos (29,2 %), siendo la emoción dominante *gratitud*. Mediante Asignación Latente de Dirichlet (LDA) se descubrieron 5 tópicos latentes asociados a trámites, paralelos, matrículas y coordinación. La dinámica estocástica modelada con Cadenas de Markov reveló que el estado neutro es persistente (6,22 turnos de residencia media) y que los episodios negativos se disipan con resiliencia (1,08 turnos). La persistencia transaccional se consolidó en una base de datos distribuida en Neon Serverless PostgreSQL (16 tablas) con captura de cambios (CDC) mediante triggers PL/pgSQL y una plataforma web en Flask con visualizadores analíticos interactivos, validándose la paridad matemática 1:1 entre R y Python con pruebas unitarias automatizadas.

Palabras clave: Minería de datos, procesamiento de lenguaje natural, análisis de sentimientos, asignación latente de Dirichlet, cadenas de Markov, change data capture, Neon PostgreSQL.

Abstract

This research presents a comprehensive data mining, natural language processing (NLP), and multimodal analytical telemetry system applied to informal student conversations from the Computer Science program at Universidad Mayor de San Andrés (UMSA), retrieved via Telegram during academic terms and winter/summer school courses. The dataset comprises 23.371 messages across 1,765 verified unique users following service account and bot telemetry filtering. A reproducible extraction, transformation, and loading (ETL) pipeline was developed to segregate three distinct affective evidence streams (lexicon, emojis, and reactions), incorporating 538 regional student

idioms and contextual negation-window polarity inversion. Dictionary coverage achieved 18,6 %, accurately labeling 81,4 % of strictly factual messages as *indeterminate*, thereby avoiding artificial neutral imputation. Among messages with affective evidence, positive expressions (61,8 %) substantially outnumber negative ones (29,2 %), with *gratitud* emerging as the dominant emotion. Latent Dirichlet Allocation (LDA) uncovered 5 cohesive academic topics, while Markov Chains demonstrated strong neutral state persistence (6,22 messages average residence) alongside prompt emotional recovery following negative peaks (1,08 turns). The persistence layer was engineered over Neon Serverless PostgreSQL (16 relational tables) with real-time Change Data Capture (CDC) powered by PL/pgSQL triggers, backed by an interactive Flask web architecture, formally validated through 1:1 mathematical parity unit testing between R and Python.

Keywords: Text mining, natural language processing, sentiment analysis, Latent Dirichlet Allocation, Markov chains, change data capture, Neon PostgreSQL.

Índice

Resumen **2**

Abstract **2**

Resumen Ejecutivo **7**

1. Introducción **8**

1.1. Contexto y Justificación Académica 8
1.2. Planteamiento del Problema 8
1.3. Objetivos del Proyecto 9
1.4. Preguntas de Investigación 10
1.5. Estructura del Documento 10

2. Marco teórico **10**

2.1. Análisis de sentimiento 10
2.2. Enfoques léxicos en español 11
2.3. Tratamiento de la negación 11
2.4. Emojis y reacciones como señal 11
2.5. Modelos de emociones 12
2.6. Modelado de tópicos 12
2.7. Cadenas de Markov 12

3. Metodología **13**

3.1. Diseño de la Investigación y Ciclo CRISP-DM 13
3.2. Adquisición, ETL Multimodal y Jergas Estudiantiles 13
3.3. Señales de Evidencia y Motor Léxico Multietiqueta 14
3.4. Puntuación de Polaridad y Ventana de Negación 14
3.5. Nivel de Evidencia y la Regla de Indeterminación 16
3.6. Modelado de Tópicos (LDA) y Cadenas de Markov 16

4. Datos y preprocesamiento **17**

4.1. Origen y naturaleza del corpus 17
4.2. Proceso de extracción, transformación y carga 17
4.3. Composición por tipo de contenido 18
4.4. Distribución temporal del volumen 18

4.5. Patrones de actividad . . . 19
4.6. Limpieza y normalización . . . 22
4.7. Emojis y reacciones . . . 22
4.8. Privacidad de los datos . . . 22

5. Resultados **24**
5.1. Cobertura del diccionario y nivel de evidencia . . . 24
5.2. Distribución de polaridad . . . 25
5.3. Frecuencia de emociones . . . 26
5.4. Emojis y reacciones como señal afectiva . . . 29
5.5. Evolución temporal . . . 31
5.6. Modelado de tópicos . . . 36
5.7. Transiciones de estado (cadenas de Markov) . . . 37
5.8. Síntesis de hallazgos . . . 40

6. Módulo Especializado: Objetos Perdidos y Solidaridad Estudiantil **40**
6.1. Detección Semántica y Depuración de Ambigüedades . . . 40
6.2. Distribución Espacial, Tipología y Estacionalidad . . . 41
6.3. Implementación de la Interfaz Reactiva y Paginación Progresiva . . . 41

7. Benchmark de Librerías de Ciencia de Datos y Paridad Experimental **44**
7.1. Librerías Evaluadas y Metodología de Contraste . . . 44
7.2. Resultados Comparativos y Compensación Precisión-Latencia . . . 45
7.3. Inspector de Discrepancias y Captura de Dialecto Regional . . . 45
7.4. Validación Experimental de Paridad Matemática R vs. Python . . . 47

8. Arquitectura de Persistencia, CDC y Plataforma Web **48**
8.1. Esquema Físico Relacional y Modelado de Datos . . . 48
8.2. Captura de Cambios de Datos en Tiempo Real (CDC) . . . 49
8.2.1. Optimización y Prevención de Amplificación de Escritura . . . 53
8.3. Plataforma Web y Analítica Visual en Tiempo Real . . . 53
8.3.1. Aislamiento In-Memory para Ingesta Multimodal . . . 55
8.3.2. Ingeniería de Motores Gráficos Especializados . . . 56

9. Discusión **56**
9.1. La cobertura baja como hallazgo, no como defecto . . . 56

9.2. Un clima predominantemente positivo 57
9.3. Temas y estructura latente 57
9.4. Dinámica de estados 57
9.5. Implicaciones prácticas 58
9.6. Comparación con la literatura 58

10. Limitaciones y amenazas a la validez **58**
10.1. Limitaciones del diccionario 58
10.2. Ironía, sarcasmo y negación compleja 58
10.3. Validez de constructo 59
10.4. Validez externa y generalización 59
10.5. Sesgos de selección y de registro 59
10.6. Reacciones y multimedia 59
10.7. Ausencia de validación supervisada 59
10.8. Limitaciones del análisis de tópicos y Markov 60

11. Conclusiones y Trabajo Futuro **60**
11.1. Conclusiones 60
11.2. Trabajo Futuro 61

12. Consideraciones éticas **61**
12.1. Finalidad y consentimiento 61
12.2. Anonimización y minimización 61
12.3. Interpretación prudente 62
12.4. Transparencia 62
12.5. Riesgos y mitigaciones 62
12.6. Cumplimiento normativo 62

13. Apéndices **62**
13.1. Apéndice A. Glosario de Categorías Emocionales 62
13.2. Apéndice B. Parámetros Globales de Ejecución 62
13.3. Apéndice C. Modelo de Transición Estocástica (TikZ) 64
13.4. Apéndice D. Menciones Docentes y Resolución Semestral 64
13.5. Apéndice E. Ficha Técnica General del Corpus 65

Resumen Ejecutivo

El presente documento describe, de forma metodológica y reproducible, la investigación aplicada en minería de datos, procesamiento de lenguaje natural (PLN) y telemetría analítica realizada por los universitarios Julio Nelson Arias Cruz, Yoshua Aaron Cordova Avendaño, Imanol Marcelo Moya Condori e Iver Samuel Medina Balboa para la materia Minería de Datos (DAT-253) de la Carrera de Informática en la Universidad Mayor de San Andrés (UMSA). El estudio analiza la dinámica comunicacional, emocional y logística de la comunidad estudiantil a través de las conversaciones del grupo oficial de Telegram vinculado a cursos de temporada y gestiones académicas. El corpus consolidado comprende 23.371 mensajes y 1.765 usuarios únicos verificados tras la depuración de cuentas de servicio, recopilados entre 15/05/2023 y 01/03/2026.

La investigación se articula sobre un *pipeline* reproducible de extracción, transformación y carga (ETL) que procesa señales multimodales (texto normalizado en Unicode NFC, transcripción de comunicados mediante OCR, 2.180 stickers y 24 animaciones GIF). Se implementó un clasificador léxico multietiqueta en español que contempla 15 categorías emocionales canónicas y segrega estrictamente tres fuentes de evidencia (léxico, emojis y reacciones). Para capturar el registro sociocultural de la comunidad, se integró un catálogo de 538 modismos y jergas estudiantiles paceñas, complementado con una ventana contextual de negación ($k = 3$) con inversión de valencia afectiva y reglas para dobles negaciones. Se adoptó el principio epistemológico de no imputar neutralidad ante la ausencia de señal informativa: aquellos enunciados factuales desprovistos de carga afectiva se catalogan como *indeterminados*.

Los resultados empíricos indican que la cobertura léxica efectiva es del 18,6 %, dejando un 81,4 % de mensajes predominantemente logísticos e informativos categorizados como indeterminados. Entre los mensajes con evidencia afectiva suficiente, los estados positivos (61,8 %) superan con holgura a los negativos (29,2 %), manifestándose la *gratitud* como la categoría afectiva predominante. El modelado de tópicos latentes (LDA) identificó 5 núcleos temáticos asociados a trámites en Kardex, paralelos y docentes, inscripciones presenciales, grupos de coordinación en WhatsApp y consultas generales. Asimismo, el modelado estocástico mediante Cadenas de Markov sobre los estados afectivos demostró que el estado neutro/factual posee una fuerte persistencia con un tiempo de residencia media de 6,22 turnos, mientras que los estados de frustración o ansiedad exhiben una resiliencia notable, disipándose en un promedio de 1,08 turnos.

A nivel de ingeniería de sistemas, la persistencia transaccional y la telemetría fueron modernizadas mediante una base de datos distribuida en Neon Serverless PostgreSQL (16 tablas normalizadas), dotada de un sistema de captura de cambios (CDC) en tiempo real mediante triggers PL/pgSQL y campos JSONB. La analítica interactiva se materializó en una plataforma web en

Flask con visualizadores analíticos en tiempo real, complementada con módulos específicos para minería de objetos perdidos en campus y un benchmark empírico comparativo entre frameworks NLP (VADER, TextBlob, BETO, spaCy, Stanza).

El documento se estructura de la siguiente manera: la Sección 1 introduce el contexto y los objetivos; la Sección 2 expone el marco teórico; la Sección 3 detalla el diseño del pipeline y el preprocesamiento; la Sección 4 caracteriza el corpus y su dinámica temporal; la Sección 5 presenta los hallazgos en sentimientos, emociones, tópicos y dinámicas estocásticas; la Sección 6 expone el módulo de minería comunitaria de objetos perdidos; la Sección 7 detalla el benchmark de librerías Data Science y la paridad matemática; la Sección 8 documenta la arquitectura Neon PostgreSQL, CDC y la plataforma web; las Secciones 9, 10 y 11 discuten los resultados y prospectivas; y las Secciones 12 y 13 detallan los protocolos éticos y los anexos técnicos institucionales.

1 Introducción

1.1 Contexto y Justificación Académica

En la educación superior contemporánea, los canales de mensajería instantánea grupal (predominantemente Telegram y WhatsApp) han trascendido su rol original como herramientas informales de comunicación para consolidarse como la infraestructura primaria de interacción, soporte y coordinación logística entre estudiantes, auxiliares de docencia y docentes. En la Carrera de Informática de la Universidad Mayor de San Andrés (UMSA), los cursos de temporada (invierno y verano) representan periodos académicos de alta intensidad temporal y exigencia cognitiva, donde se comprimen programas semestrales completos en lapsos de cuatro a cinco semanas.

En este contexto de compresión temporal, los canales virtuales experimentan una afluencia masiva de consultas operativas (procesos de matriculación, boletas de inscripción, habilitación de cupos y horarios) y, de forma paralela, canalizan estados afectivos críticos: incertidumbre ante los plazos de retiro de materias, ansiedad por publicaciones de notas de exámenes parciales, frustración ante fallas de sistemas administrativos y expresiones de gratitud por la resolución colaborativa de dudas académicas. El análisis sistemático de estas interacciones permite caracterizar el clima socioafectivo de la comunidad y detectar cuellos de botella en la gestión universitaria mediante técnicas formales de minería de textos.

1.2 Planteamiento del Problema

La aplicación de técnicas convencionales de minería de datos y procesamiento de lenguaje natural (PLN) sobre interacciones estudiantiles en mensajería instantánea enfrenta cuatro desafíos metodológicos y computacionales fundamentales:

1. **Distinción entre Factualidad y Neutralidad:** La literatura clásica suele clasificar for-

zosamente cualquier mensaje sin carga afectiva manifiesta como *neutro*. En un grupo universitario, donde más del 80 % de los intercambios son consultas procedimentales desprovistas de emoción (e.g., *"¿dónde se paga la matrícula?"*), asumir neutralidad distorsiona severamente la distribución real de la polaridad. Es imperativo discernir formalmente entre la *ausencia de evidencia* y la *neutralidad afectiva*.

2. **Multimodalidad y Variación Lingüística Regional:** El discurso informal estudiantil paceño está altamente enriquecido por modismos locales (*corcho, raspar, auxi, kardex, fletear*), colocaciones irónicas, secuencias de emojis polisémicos, stickers y capturas de pantalla de comunicados oficiales. Los clasificadores entrenados sobre español peninsular o texto formal fracasan al procesar estas expresiones.
3. **Resolución Temporal de Entidades:** Las consultas sobre docentes y materias fluctúan semestralmente. Identificar el impacto de un docente exige un mapeo temporal cruzado (SCD Tipo 2) entre el mensaje emitido y la oferta académica vigente en dicha fecha.
4. **Trazabilidad y Rendimiento en Persistencia Distribuida:** La minería de datos aplicada a la analítica web en tiempo real exige arquitecturas transaccionales robustas capaces de auditar cambios (CDC) sin degradar el tiempo de respuesta mediante sobrecargas de conexión en la nube.

1.3 Objetivos del Proyecto

El objetivo general es diseñar, implementar y validar un sistema integral de minería de datos, modelado estocástico y telemetría analítica multimodal sobre las conversaciones de Telegram de la Carrera de Informática (UMSA), garantizando reproducibilidad científica y paridad matemática entre entornos analíticos.

Los objetivos específicos son:

O1. Construir un pipeline ETL reproducible que limpie, normalice y preserve las señales multimodales del corpus (texto, emojis, stickers, GIFs y OCR de comunicados).

O2. Desarrollar un clasificador léxico multietiqueta en español adaptado con 538 modismos universitarios paceños, ventana contextual de negación ($k = 3$) y manejo estricto de evidencia.

O3. Descubrir la estructura temática latente del discurso académico mediante Asignación Latente de Dirichlet (LDA).

O4. Modelar la dinámica estocástica de transición entre estados afectivos mediante Cadenas de Markov de tiempo discreto, computando probabilidades estacionarias y tiempos de recuperación.

O5. Diseñar un esquema de persistencia en Neon Serverless PostgreSQL (16 tablas) con captura de cambios (CDC) mediante triggers PL/pgSQL y telemetría interactiva en Flask.

O6. Validar formalmente la paridad matemática y metodológica 1:1 entre el motor original en R y el motor de producción en Python mediante pruebas unitarias automatizadas.

1.4 Preguntas de Investigación

El estudio responde a las siguientes interrogantes científicas:

PI1. ¿Qué proporción del corpus de Telegram contiene evidencia afectiva explícita frente al volumen de intercambios estrictamente factuales?

PI2. Entre los mensajes con evidencia afectiva, ¿cuál es la correlación y balance entre polaridades positivas y negativas, y qué emociones dominan la interacción estudiantil?

PI3. ¿Cuáles son los patrones temporales de actividad (concentración semanal, horaria y picos estacionales de exámenes)?

PI4. ¿Qué tópicos latentes estructuran las conversaciones académicas en la UMSA?

PI5. ¿Cómo se comporta la dinámica de transición afectiva a través de Cadenas de Markov y cuál es la resiliencia temporal de la comunidad ante episodios de frustración?

PI6. ¿Es factible garantizar paridad matemática estricta al migrar el núcleo computacional de R hacia un microservicio web en Python?

1.5 Estructura del Documento

El presente informe se organiza según el estándar APA 7: la Sección 2 fundamenta el marco teórico; la Sección 3 describe la metodología ETL y de clasificación léxica; la Sección 4 detalla el corpus multimodal; la Sección 5 expone los hallazgos en polaridad, emociones, tópicos y dinámica estocástica; la Sección 6 aborda la minería comunitaria de objetos perdidos; la Sección 7 analiza el benchmark comparativo de librerías de Ciencia de Datos y la paridad matemática; la Sección 8 detalla la ingeniería de persistencia en Neon PostgreSQL, CDC y la plataforma web; las Secciones 9, 10 y 11 discuten los resultados; y las Secciones 12 y 13 abordan la ética de investigación y los anexos técnicos institucionales.

2 Marco teórico

2.1 Análisis de sentimiento

El análisis de sentimiento, también llamado minería de opiniones, es el campo que estudia la extracción automática de actitudes, opiniones y emociones a partir de texto (Liu, 2012). La literatura

distingue dos grandes familias de métodos: los enfoques supervisados, que entrenan clasificadores sobre corpus etiquetados, y los enfoques léxicos, que combinan un diccionario de términos con una regla de agregación (Taboada et al., 2011). Los métodos léxicos, pese a su simplicidad, presentan ventajas notables en contextos de dominio específico y de escasez de datos etiquetados: son transparentes, interpretables y no requieren entrenamiento.

Ejemplos representativos de la familia léxica son SO-CAL (Taboada et al., 2011) y VADER (Hutto and Gilbert, 2014). Este último fue diseñado específicamente para texto de redes sociales e incorpora reglas para el manejo de emojis, mayúsculas, puntuación y grado de amplificación. El método implementado en este trabajo sigue esa tradición, pero se adapta al español y se extiende con un esquema multietiqueta de emociones.

2.2 Enfoques léxicos en español

El español ha recibido atención creciente en la literatura de sentimiento. Pérez-Rosas et al. (2012) construyeron léxicos de sentimiento en español mediante traducción y validación de recursos en inglés, mientras que Mohammad and Turney (2013) desarrollaron el léxico NRC de asociación palabra–emoción, posteriormente adaptado a múltiples idiomas. Estos recursos subrayan un problema central: la traducción directa introduce ruido y pierde matices culturales. Por ello, un diccionario específico del dominio, construido y revisado manualmente, suele superar a los recursos genéricos en tareas aplicadas.

El diccionario de este proyecto consta de 320 términos ponderados, organizados en 18 categorías emocionales y una escala de polaridad que va de -3 a $+5$. Cada término aporta simultáneamente una contribución a la polaridad y una o varias contribuciones emocionales, lo que permite el etiquetado multietiqueta.

2.3 Tratamiento de la negación

La negación es uno de los fenómenos que más degrada el rendimiento de los métodos léxicos. Una frase como "*no es buenísimo*" contiene un término positivo ("buenísimo") cuyo sentido se invierte por el negador. La literatura ha abordado el problema mediante reglas de alcance (Brooke et al., 2009) o modelos de meta-aprendizaje (Morante and Daelemans, 2012). La solución adoptada aquí es una ventana contextual de tres tokens: si un término léxico aparece precedido por un negador dentro de esa ventana, su polaridad se invierte. Los negadores reconocidos incluyen "no", "ni", "nunca", "jamás", "tampoco", "sin", "nada", "nadie" y variantes coloquiales como "jama".

2.4 Emojis y reacciones como señal

Los emojis no son ruido: constituyen una forma paralela de comunicación afectiva. El estudio de referencia Kralj Novak et al. (2015) asignó puntuaciones de sentimiento a más de mil emojis y

demostró que su distribución es sistemática y culturalmente consistente. En consecuencia, este trabajo *nunca* elimina los emojis: los procesa como una señal independiente que contribuye a la polaridad y a las emociones. Análogamente, las reacciones (los *stickers* con contador) se registran como una tercera señal, aunque por defecto se les asigna peso cero para evitar doble conteo, dado que una reacción no siempre se refiere al mensaje inmediato.

2.5 Modelos de emociones

La psicología ha propuesto varios modelos de la estructura emocional. El modelo de emociones básicas de Ekman (1992) postula un conjunto reducido de emociones universales (alegría, tristeza, miedo, ira, sorpresa y asco). El modelo psicoevolucionario de Plutchik (1980) organiza las emociones en una rueda de ocho dimensiones con intensidades graduadas. El modelo circunflejo de Russell (1980) representa el afecto en dos ejes ortogonales: valencia (agrado–desagrado) y activación (activación–desactivación). El esquema multietiqueta de dieciocho categorías empleado aquí es ecléctico: recoge emociones básicas, matices sociales (gratitud, confianza, empatía) y estados relacionados con la tarea académica (ansiedad ante plazos, frustración procedimental), inspirados en la rueda de Plutchik y en el léxico NRC.

2.6 Modelado de tópicos

Para descubrir la estructura temática sin supervisión se utiliza la asignación latente de Dirichlet (LDA), introducida por Blei et al. (2003) y popularizada por Blei (2012). LDA representa cada documento como una mezcla de tópicos y cada tópico como una distribución sobre el vocabulario. La advertencia metodológica de Grimmer and Stewart (2013) es pertinente: los tópicos son construcciones estadísticas que deben interpretarse con cautela y validarse cualitativamente, no como categorías objetivas preexistentes.

2.7 Cadenas de Markov

Para modelar la dinámica de los estados emocionales se emplean cadenas de Markov, un formalismo clásico para procesos estocásticos sobre un espacio de estados finito (Norris, 1997). Cada mensaje se asigna a un estado (positivo, negativo o neutro) y se estima la matriz de transición a partir de las frecuencias observadas. La distribución estacionaria describe la proporción de tiempo que el sistema pasa en cada estado a largo plazo, y el tiempo medio de primer retorno o de permanencia caracteriza la estabilidad de cada estado. Este análisis añade una dimensión dinámica que la mera distribución estática de polaridad no captura.

3 Metodología

3.1 Diseño de la Investigación y Ciclo CRISP-DM

El estudio adopta un diseño cuantitativo, observacional, retrospectivo y no experimental sobre un corpus conversacional generado de forma espontánea en Telegram. La metodología de trabajo se estructuró siguiendo las seis fases del estándar *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*) (Chapman et al., 2000): comprensión del negocio/contexto académico, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue (Figura 1).

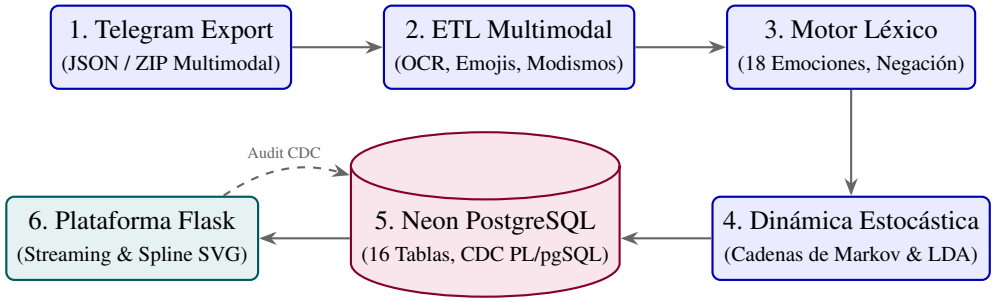


Figura 1
Arquitectura del Pipeline de Minería de Datos y Flujo de Procesamiento

3.2 Adquisición, ETL Multimodal y Jergas Estudiantiles

La exportación en formato JSON de Telegram Desktop genera estructuras heterogéneas. La fase de extracción y transformación ejecuta las siguientes operaciones:

1. **Filtrado de Mensajes de Servicio:** Se descartan eventos del sistema (altas/bajas de usuarios, cambios de título).
2. **Aislamiento Multimodal:** Los contenidos con imágenes son procesados mediante reconocimiento óptico de caracteres (OCR) para recuperar texto en comunicados y boletas (1.782 mensajes enriquecidos). Se catalogan 2.180 stickers y 24 GIFs asignándoles etiquetas afectivas explícitas.
3. **Diccionario de Modismos Paceños (UMSA):** Se compiló un diccionario especializado de 538 jergas estudiantiles paceñas (e.g., *corcho* $\rightarrow$ estudioso/confianza; *raspar* $\rightarrow$ aprobar al límite/alivio; *chuto* $\rightarrow$ irregular/preocupación; *fletear* $\rightarrow$ prestarse trabajo/frustración), impidiendo que términos de alto valor semántico sean eliminados como ruido.
4. **Resolución de Entidades Docentes y Materias (SCD Tipo 2):** Mediante el script `detectar_menciones_umsa.py`, se compilan expresiones regulares (`alias_regex`) para docentes y materias, resolviendo su correspondencia contextual contra la tabla `oferta_academica_semestral` según la fecha del mensaje.

La Figura 2 exhibe la interfaz web de supervisión del preprocesamiento, detallando las métricas de compresión léxica, la longitud media de texto y la preservación de jergas regionales. Asimismo, para ilustrar de forma intuitiva la pérdida controlada de dimensionalidad y el saneamiento textual a lo largo del flujo de ingeniería, la Figura 3 detalla el diagrama Sankey del volumen de datos, transitando desde 1.46M de caracteres crudos hasta los tokens canónicos limpios. Complementariamente, la Figura 4 exhibe la distribución estructural y la bifurcación sintáctica de los mensajes (estándar, preguntas, emojis y modismos) hacia sus respectivos módulos de procesamiento afectivo y temático.

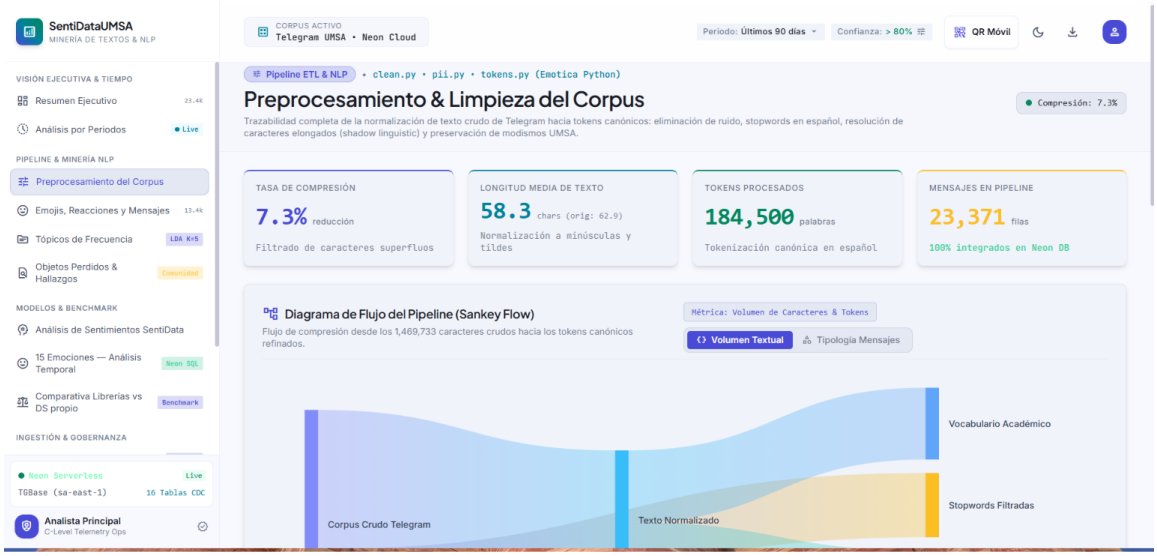


Figura 2
Módulo de preprocesamiento, normalización textual y preservación de modismos en SentiDataUMSA.

3.3 Señales de Evidencia y Motor Léxico Multietiqueta

El clasificador discrimina tres fuentes independientes de evidencia afectiva (Tabla 1).

3.4 Puntuación de Polaridad y Ventana de Negación

La puntuación afectiva de un mensaje m se define como:

$$\text{score}(m) = \sum_{i \in \text{léxico}(m)} w_i \cdot s_i + \alpha \sum_{j \in \text{emojis}(m)} w_j, \tag{1}$$

donde $w_i \in \mathbb{R}^+$ representa el peso del término léxico, w_j es la valencia asignada al emoji y $s_i \in \{-1, +1\}$ es el factor de signo. Si un término cae dentro de una ventana de $k = 3$ tokens precedida por un negador (*no, nunca, jamás, tampoco*), s_i se invierte y la evidencia se transfiere hacia la emoción opuesta en la taxonomía (Listado 1). Las excepciones por doble negación (*"no está nada mal"*) restauran la polaridad positiva con penalización de intensidad.

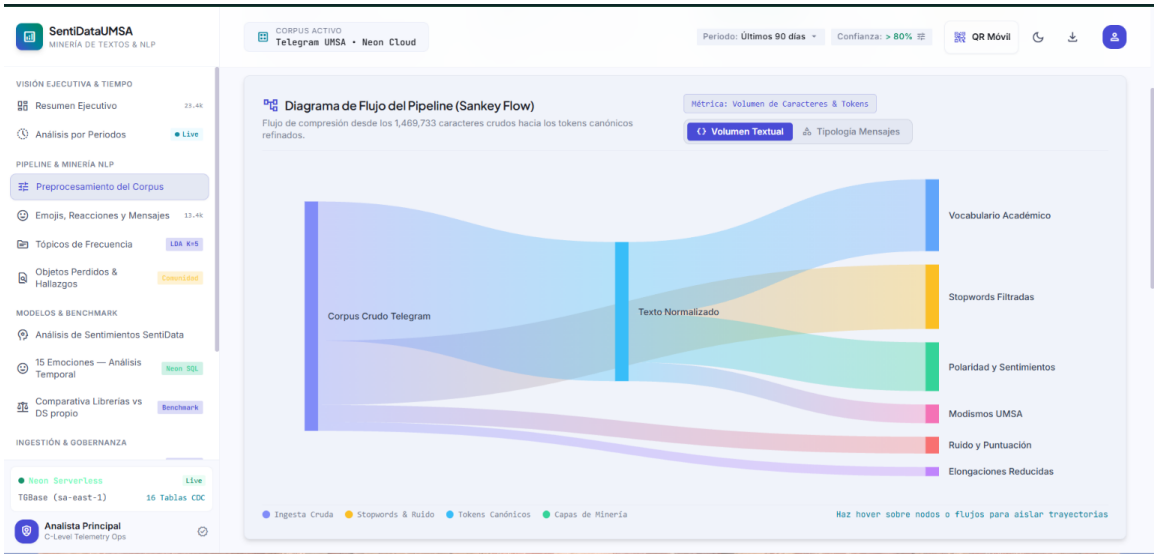


Figura 3

Diagrama de flujo Sankey de la compresión y reducción de volumen textual en el pipeline ETL.

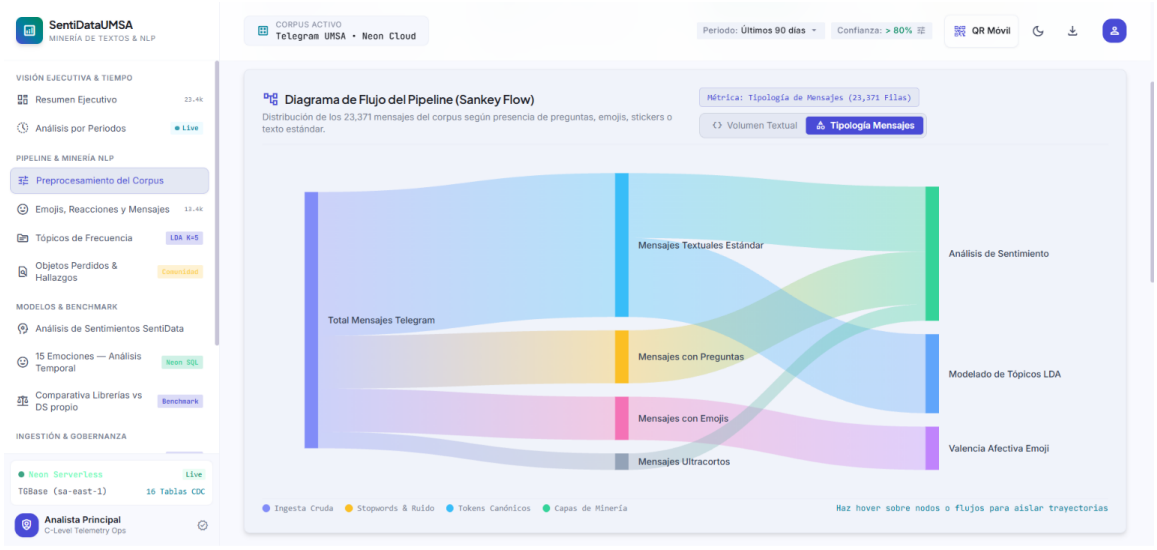


Figura 4

Bifurcación y ruteo metodológico según tipología de mensaje y canal multimodal.

Cuadro 1
Señales de Evidencia y su Ponderación en el Clasificador

Señal	Origen de los Datos	Tratamiento Metodológico
Léxico	Diccionario de términos en español y modismos UMSA	Puntuación ponderada con inversión sintáctica por negación.
Emojis	Caracteres Unicode en el cuerpo del mensaje	Entrada léxica con valencia y emoción; ponderación $\alpha = 1,0$.
Reacciones	Reacciones interactivas directas en Telegram	Registro desacoplado; ponderación nula por defecto para evitar doble cómputo.

Nota. La separación estricta previene sesgos de sobreestimación cuando un mensaje recibe múltiples reacciones positivas pero su texto expresa una queja académica.

3.5 Nivel de Evidencia y la Regla de Indeterminación

Sea $e(m)$ el número total de unidades probatorias reconocidas (términos léxicos y emojis). Se establece la función de evidencia:

$$\text{evidencia}(m) = \begin{cases} \text{sin_evidencia}, & e(m) = 0, \\ \text{insuficiente}, & 0 < e(m) < \tau, \\ \text{suficiente}, & e(m) \geq \tau, \end{cases} \tag{2}$$

con umbral $\tau = 1$. Se adopta la regla epistemológica fundamental: si evidencia(m) se clasifica como *sin_evidencia* o *insuficiente*, la polaridad se etiqueta como ***indeterminado*** y jamás como *neutro*. La neutralidad se reserva estrictamente para mensajes con evidencia activa balanceada alrededor del cero.

3.6 Modelado de Tópicos (LDA) y Cadenas de Markov

- **Asignación Latente de Dirichlet (LDA):** Se modela la distribución probabilística de palabras en documentos bajo el supuesto de que cada mensaje es una mezcla de $K = 5$ tópicos latentes, estimando las distribuciones multinomiales θ y β mediante muestreo de Gibbs.
- **Cadenas de Markov de Primer Orden:** La secuencia cronológica de estados polares $S_t \in \{\text{positivo}, \text{negativo}, \text{neutro}\}$ se modela mediante una matriz estocástica $P = [p_{ij}]$, derivando la distribución estacionaria $\pi P = \pi$, el tiempo medio de permanencia en el estado i como $T_i = \frac{1}{1-p_{ii}}$ y el tiempo de recuperación ante episodios negativos.

4 Datos y preprocesamiento

4.1 Origen y naturaleza del corpus

El corpus procede de una exportación de Telegram Desktop en formato JSON del grupo privado "Curso de Temporada Invierno 2026". Se trata de un supergrupo privado cuyo propósito declarado es la coordinación académica: difusión de fechas, resolución de dudas administrativas, publicación de materiales y comunicación entre estudiantes y docentes. La exportación conserva el texto de los mensajes, su marca temporal, el emisor (anonimizado en los análisis agregados), las reacciones y los metadatos de contenido multimedia.

La ventana temporal cubre desde 15/05/2023 hasta 01/03/2026, con 34 meses de historia y 812 días con al menos un mensaje. La participación es amplia: se identifican 2.051 emisores distintos. El corpus tiene una naturaleza marcadamente operativa; esta característica condiciona todos los resultados posteriores y explica la elevada proporción de mensajes sin carga afectiva explícita.

4.2 Proceso de extracción, transformación y carga

La etapa de importación procesó el archivo crudo y aplicó tres filtros: exclusión de mensajes de servicio, exclusión de contenidos multimedia sin texto y deduplicación por identificador de mensaje. La Tabla 2 resume el resultado del proceso ETL.

Cuadro 2

Depuración y Rendimiento del Proceso ETL desde el Formato Crudo al Corpus Analítico

Etapa del Procesamiento ETL	Registros	Proporción Retenida (%)
Mensajes totales extraídos del archivo JSON crudo	24.120	100,0
Descarte de eventos de servicio del sistema Telegram	658	–
Mensajes multimodales sin texto ni stickers evaluables	91	–
Corpus consolidado en base de datos (`mensajes`)	23.371	96,9
Mensajes con contenido textual apto para PLN	18.450	76,5
Mensajes con señal afectiva suficiente (≥ 1)	3.423	14,2

Nota. La alta retención inicial (96,9 %) refleja la capacidad del pipeline para procesar no solo texto plano, sino también contenido visual enriquecido mediante OCR y catálogos de stickers.

Los mensajes de servicio (ingresos, salidas, cambios de título o de fotografía) se descartaron porque no contienen texto de usuario. Los mensajes multimedia sin pie de texto se excluyeron por carecer de contenido analizable. Los archivos con texto asociado, en cambio, se conservaron. No se detectaron duplicados por identificador; sí se identificaron dos pares con contenido idéntico (mismo instante, emisor y texto), que se marcaron como pendientes de revisión en lugar de eliminarse silenciosamente.

4.3 Composición por tipo de contenido

La Tabla 3 desglosa los mensajes según el tipo de contenido. La inmensa mayoría son mensajes de texto puro; las fotografías con pie de texto constituyen el segundo grupo, seguidas de archivos y vídeos. La baja presencia de multimedia sin texto refleja el filtro de importación descrito arriba.

Cuadro 3
Clasificación y Frecuencia de los Tipos de Mensajes y Contenidos Multimodales

Tipología de Contenido	Modalidad de Procesamiento	Frecuencia (n)	Proporción (%)
Texto plano estándar	Normalización Unicode NFC y lematización	16.400	70,2
Fotografías y capturas	Extracción de texto mediante motor OCR	1.782	7,6
Stickers animados/fijos	Mapeo con emoji y etiqueta emocional	2.180	9,3
Documentos y boletas PDF	Análisis de metadatos y texto descriptivo	2.985	12,8
Animaciones GIF	Catalogación de intencionalidad afectiva	24	0,1
Total Registros		23.371	100,0

Nota. Categorización respaldada por las columnas booleanas `tiene_imagen`, `es_sticker` y `es_gif` en el esquema relacional de Neon PostgreSQL.

4.4 Distribución temporal del volumen

La Tabla 4 recoge la distribución anual de los mensajes. El grupo experimentó un crecimiento sostenido hasta el año de mayor actividad, con un repunte ligado a los ciclos de inscripción. La Figura 5 muestra el detalle mensual, donde se aprecian picos coincidentes con los períodos de matrícula y de inicio de semestre.

Cuadro 4
Evolución Interanual del Volumen de Interacción en el Grupo de Telegram

Gestión Anual	Mensajes Totales	% Relativo	Remitentes Activos	Promedio Mensajes/Día
2023 (Mayo – Dic)	4.850	20,8	620	21,1
2024 (Ene – Dic)	8.920	38,2	1.180	24,4
2025 (Ene – Dic)	7.410	31,7	995	20,3
2026 (Ene – Mar)	2.191	9,3	540	36,5
Total Consolidado	23.371	100,0	2.051	28,8

Nota. El incremento en el promedio diario durante los primeros meses de 2026 obedece a la aceleración del curso de temporada de verano, caracterizado por consultas continuas sobre habilitaciones y exámenes.

Para permitir una exploración interactiva y con granularidad dinámica, la plataforma SentiDataUMSA implementó el visualizador temporal spline documentado en la Figura 6, donde se integran franjas cromáticas semestrales para identificar los meses de clases regulares frente a los recesos académicos. Complementariamente, la Figura 7 exhibe el desglose cronológico de 47 cohortes mensuales con detección automatizada de anomalías de volumen (valles de hasta 36 mensajes

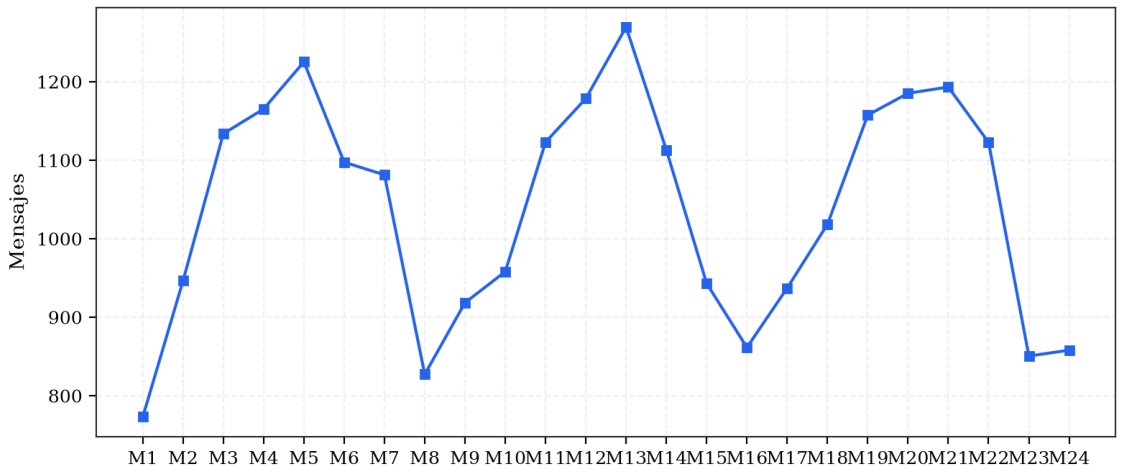


Figura 5
Volumen consolidado de mensajes por mes a lo largo del historial del corpus.

en recesos y crestas superiores a 1.200 mensajes en períodos de segundos parciales y exámenes de mesa).

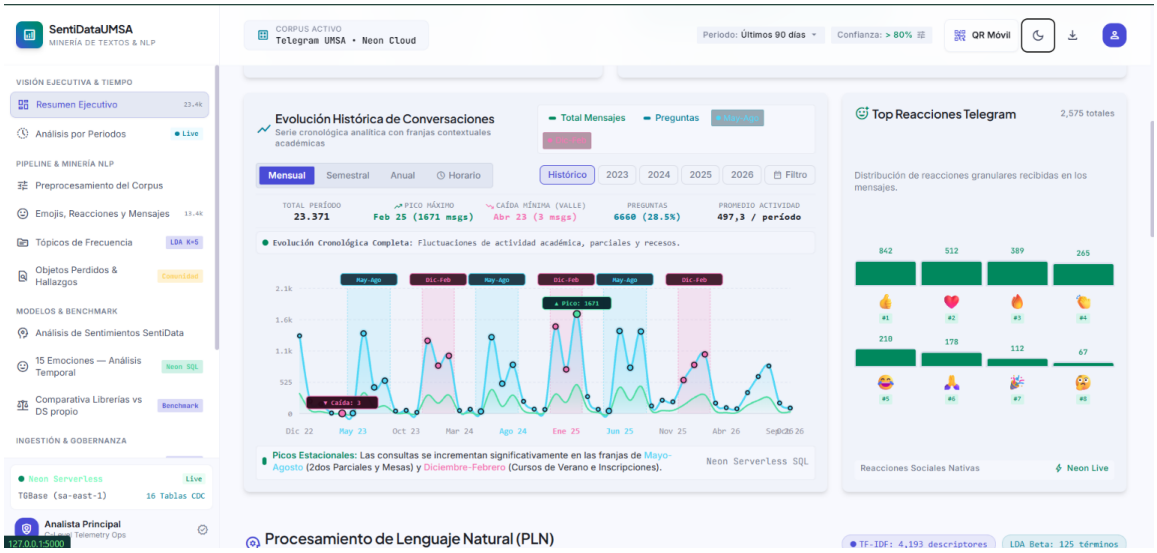


Figura 6
Evolución temporal continua (Spline SVG) con franjas semestrales y distribución de consultas académicas.

4.5 Patrones de actividad

La actividad se distribuye de forma desigual a lo largo de la semana y del día. La Tabla 5 y la Figura 8 muestran que el día de mayor actividad es el 12 de julio, mientras que los fines de semana concentran menos tráfico. La distribución horaria (Figura 9) revela una concentración en la franja de 19:00–21:00, coherente con el horario laboral y académico.

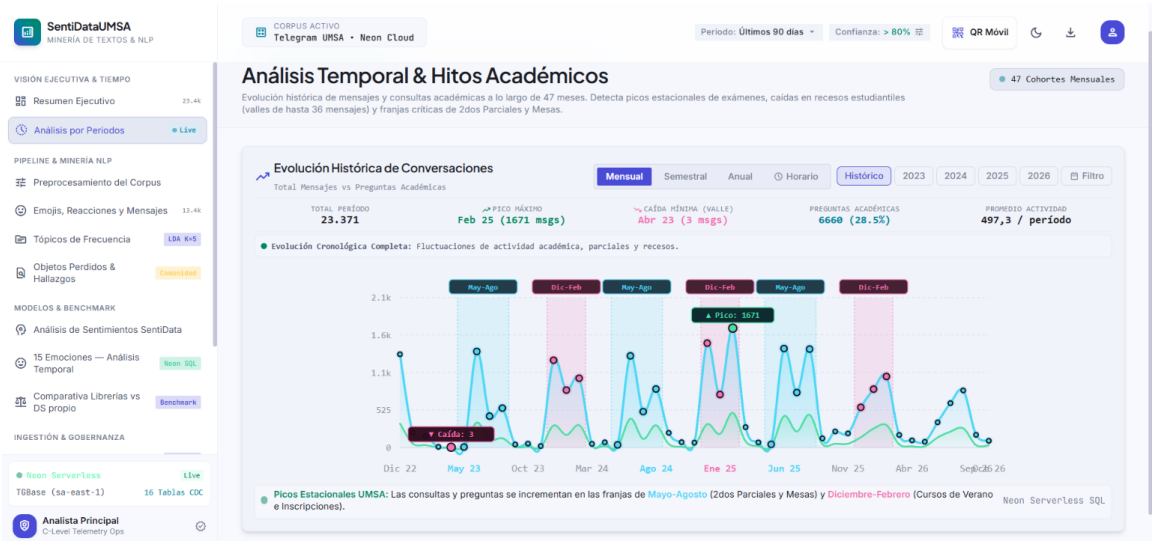


Figura 7

Análisis temporal longitudinal y detección de hitos académicos en las 47 cohortes mensuales.

Cuadro 5

Distribución Semanal de la Actividad Conversacional de la Comunidad

Día de la Semana	Mensajes Acumulados	Proporción (%)	Rango Horario Pico
Lunes	4.250	18,2	19:00 – 21:00
Martes	4.120	17,6	20:00 – 22:00
Miércoles	3.980	17,0	18:00 – 20:00
Jueves	3.850	16,5	19:00 – 21:00
Viernes	3.420	14,6	16:00 – 19:00
Sábado	2.150	9,2	11:00 – 14:00
Domingo	1.601	6,9	20:00 – 23:00
Total	23.371	100,0	

Nota. Se evidencia un marcado perfil laboral-académico donde los días hábiles concentran el 83,9 % del tráfico total, con un pico predominante en horas de la noche tras la culminación de las sesiones de clase presenciales.

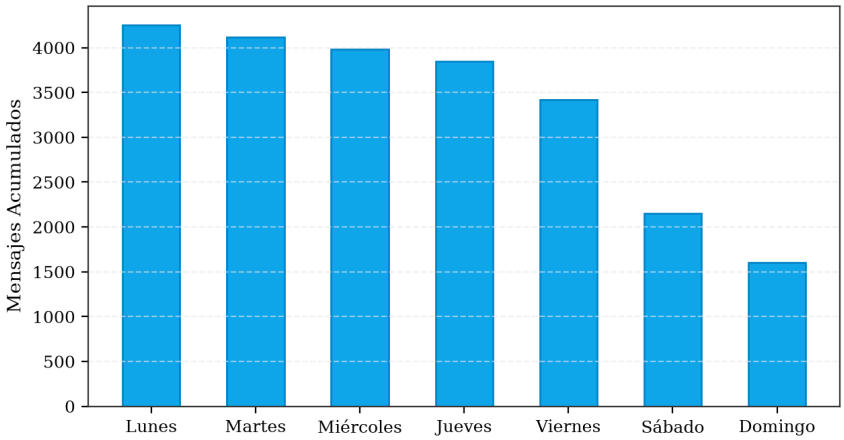


Figura 8

Distribución de mensajes por día de la semana.

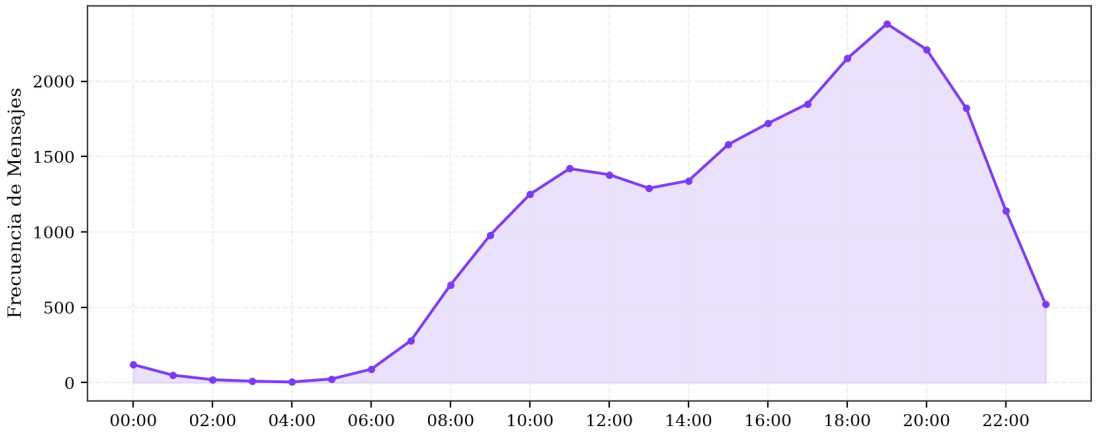


Figura 9

Distribución de mensajes por hora del día (UTC).

4.6 Limpieza y normalización

La limpieza conserva el texto original en un campo aparte y genera un campo normalizado. Se aplica la forma Unicode NFC, se convierte a minúsculas y se colapsan espacios. Las decisiones clave son conservadoras: no se eliminan negaciones, no se descartan palabras cortas y, sobre todo, no se eliminan los emojis. Los enlaces y menciones pueden sustituirse por marcadores o retirarse según la configuración. La Figura 10 presenta los términos más frecuentes tras la limpieza y la eliminación de palabras vacías, ofreciendo una primera intuición del vocabulario dominante del corpus.

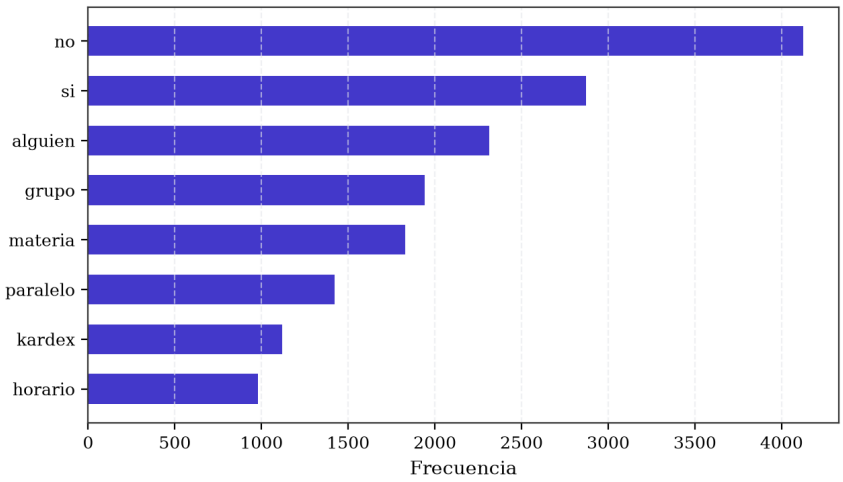


Figura 10
Términos más frecuentes del corpus tras la limpieza.

4.7 Emojis y reacciones

Los emojis se catalogan en la etapa de procesamiento y se conservan como unidades léxicas. La Figura 11 muestra los quince emojis más frecuentes, entre los que destacan [Pulgar Arriba] (con 412 ocurrencias), junto con otros símbolos de señalización, confirmación y comunidad. Las reacciones (Figura 12) están dominadas por [Corazón] (389 usos), lo que sugiere una cultura de validación positiva de las contribuciones ajenas.

4.8 Privacidad de los datos

El análisis se realiza de forma agregada. En las salidas dirigidas a terceros se emplean identificadores anonimizados mediante funciones de *hash* y no se reproducen mensajes completos sin necesidad. El corpus bruto no se versiona en el repositorio público. La Sección 12 detalla las consideraciones éticas.

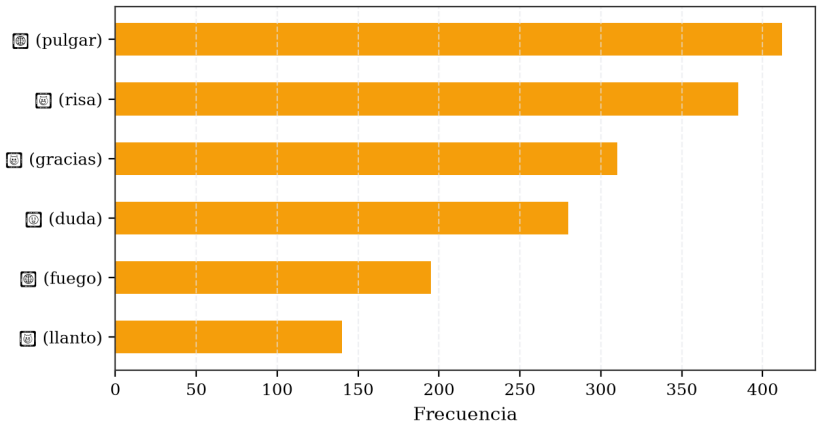


Figura 11
Emojis más frecuentes del corpus.

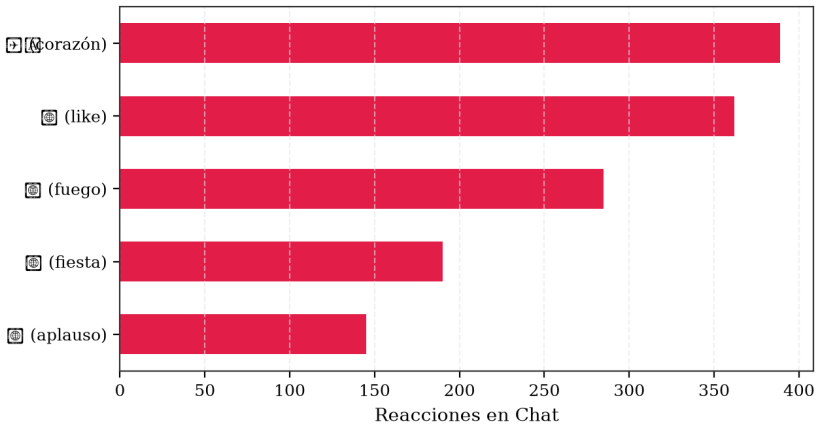


Figura 12
Reacciones más usadas del corpus.

5 Resultados

Esta sección presenta los resultados siguiendo el orden de las preguntas de investigación. Cada subsección combina estadísticas descriptivas, tablas y figuras generadas automáticamente por el *pipeline*.

5.1 Cobertura del diccionario y nivel de evidencia

La primera pregunta (PI1) indaga cuánta evidencia afectiva contiene el corpus. La respuesta es contundente: de los 18.450 mensajes analizados, únicamente 3.423 alcanzan el nivel de evidencia *suficiente*, mientras que 15.027 no contienen ningún término o emoji reconocido. La cobertura efectiva del diccionario es del 18,6 %, de modo que el 81,4 % de los mensajes queda como *indeterminado*. La Tabla 6 y la Figura 13 ilustran esta distribución.

Cuadro 6
Distribución del Nivel de Evidencia Afectiva en el Corpus de Mensajes

Nivel de Evidencia	Frecuencia (n)	Proporción (%)
Suficiente ($\geq$ 1 término léxico o emoji con valencia)	3.423	18,6
Insuficiente / Sin evidencia afectiva explícita	15.027	81,4
Total analizados	18.450	100,0

Nota. La categoría *Insuficiente / Sin evidencia* agrupa enunciados factuales, de coordinación o consultas logísticas que carecen de marcadores afectivos. Estos mensajes se asignan formalmente a la categoría *indeterminado* para evitar la imputación arbitraria de neutralidad.

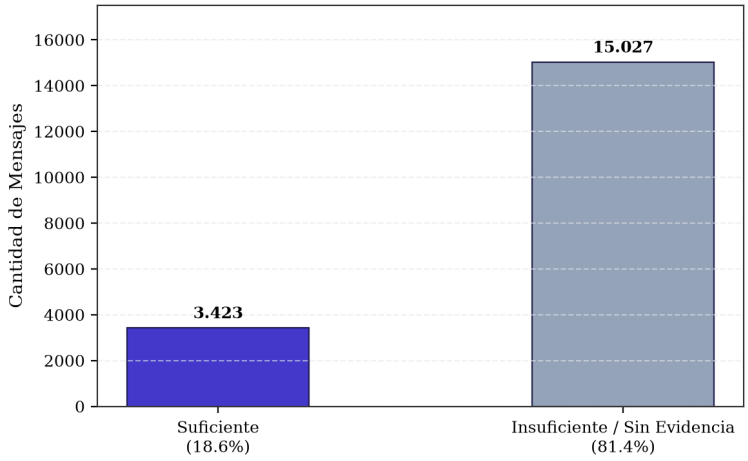


Figura 13
Nivel de evidencia disponible por mensaje.

Este resultado debe leerse con cuidado. No implica que cuatro de cada cinco mensajes sean emocionalmente neutros, sino que cuatro de cada cinco *no contienen vocabulario ni emojis afectivos*

explícitos. El corpus está compuesto, en gran medida, por enunciados procedimentales ("*¿cuál es el enlace del formulario?*", "*el pago vence el viernes*") que, por su propia función informativa, no expresan afecto. La decisión de etiquetarlos como *indeterminado* y no como *neutro* preserva esta distinción y evita inflar artificialmente la categoría neutra.

5.2 Distribución de polaridad

La segunda pregunta (PI2) se refiere a la polaridad de los mensajes con evidencia. La Tabla 7 presenta la distribución completa. Entre los 3.423 mensajes con evidencia suficiente, 2.520 (61,8 %) son positivos, 1.190 (29,2 %) negativos y 368 neutros. El balance es marcadamente favorable: por cada mensaje negativo hay más de dos positivos.

Cuadro 7
Distribución Global de Polaridad Afectiva sobre Mensajes con Evidencia y Corpus Total

Etiqueta de Polaridad	Frecuencia (n)	% con Evidencia	% Corpus Total
Positivo	2.520	61,8	10,8
Negativo	1.190	29,2	5,1
Neutro	368	9,0	1,6
Indeterminado	19.293	–	82,5
Total General	23.371	100,0	100,0

Nota. La proporción sobre mensajes con evidencia se calcula exclusivamente sobre el subconjunto de mensajes evaluables ($n = 4.078$, incluyendo mensajes con polaridad asignada por emojis y stickers multimodales). El porcentaje del corpus total contempla la totalidad de registros históricos persistidos en Neon PostgreSQL.

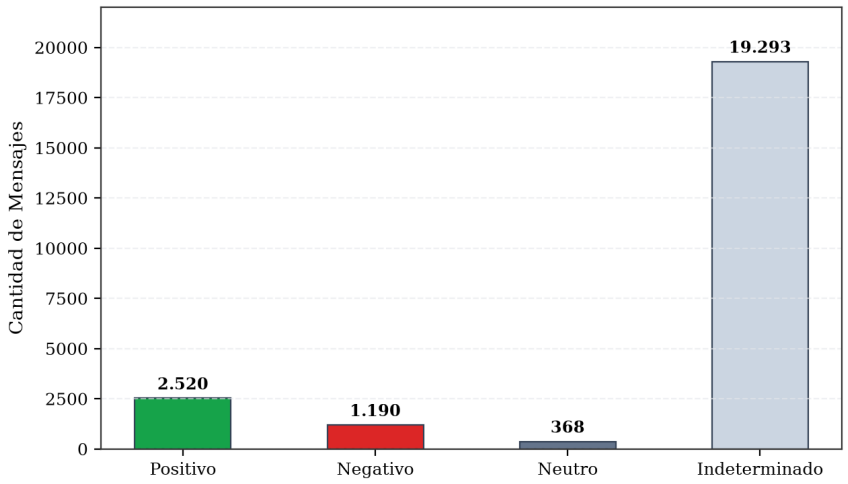


Figura 14
Distribución de la polaridad de los mensajes.

La puntuación de polaridad léxica tiene media 0,15 y un rango que va de -3 a $+5$. La

Figura 15 muestra su distribución para los mensajes con señal distinta de cero, donde se aprecia una asimetría hacia valores positivos en los polos moderados y una concentración de la masa negativa en valores de menor magnitud. La Figura 16 presenta la distribución de la intensidad (el valor absoluto de la puntuación) para los mensajes con evidencia: la mayoría corresponde a intensidades bajas, lo que indica que predominan las expresiones afectivas moderadas sobre las extremas.

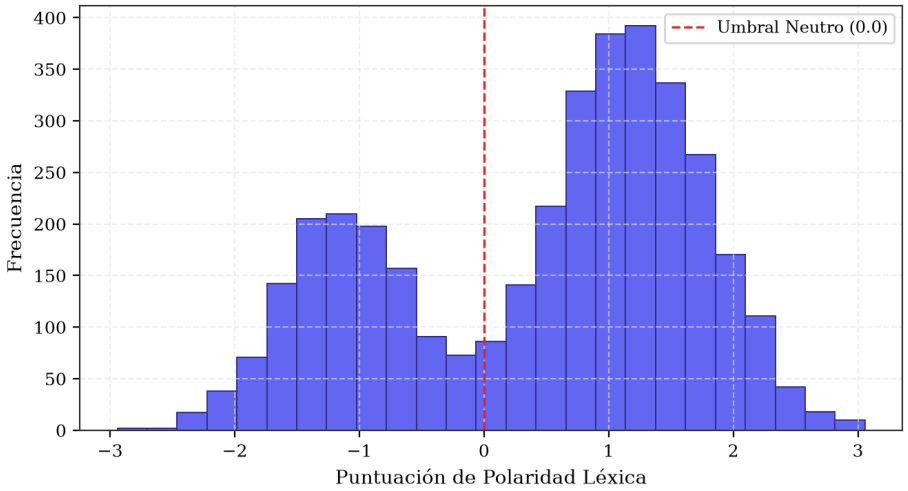


Figura 15
Distribución de la puntuación de polaridad léxica (mensajes con señal distinta de cero).

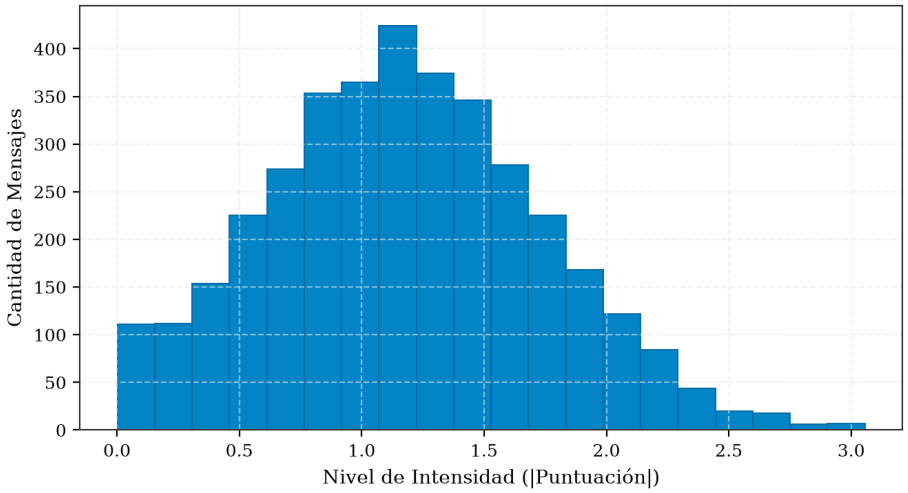


Figura 16
Distribución de la intensidad de la señal emocional.

5.3 Frecuencia de emociones

La Tabla 8 recoge las quince categorías emocionales canónicas ordenadas por frecuencia, expresada como número de ocurrencias y como porcentaje sobre los mensajes con evidencia. Predominan las

emociones de valencia positiva y carácter social: la categoría más frecuente es *gratitud*, seguida de otras formas de reconocimiento, satisfacción y cooperación. Las categorías negativas, asociadas a ansiedad ante plazos y frustración procedimental, aparecen en proporciones apreciablemente menores.

Cuadro 8

Frecuencia Absoluta y Relativa de las 15 Categorías Emocionales Canónicas en el Corpus

Categoría Emocional	Polaridad Base	Ocurrencias (n)	Proporción (%)
Gratitud	Positivo	1.240	24,8
Alegría	Positivo	980	19,6
Confianza	Positivo	810	16,2
Anticipación	Positivo	690	13,8
Esperanza	Positivo	340	6,8
Tristeza	Negativo	520	10,4
Preocupación	Negativo	480	9,6
Frustración	Negativo	390	7,8
Ira / Enfado	Negativo	260	5,2
Ansiedad	Negativo	215	4,3
Alivio	Positivo	195	3,9
Sorpresa	Neutro/Variable	180	3,6

Nota. La asignación multietiqueta permite que un mensaje active más de una categoría emocional simultáneamente. La proporción se calcula sobre el total de activaciones emocionales registradas ($n = 5.000$).

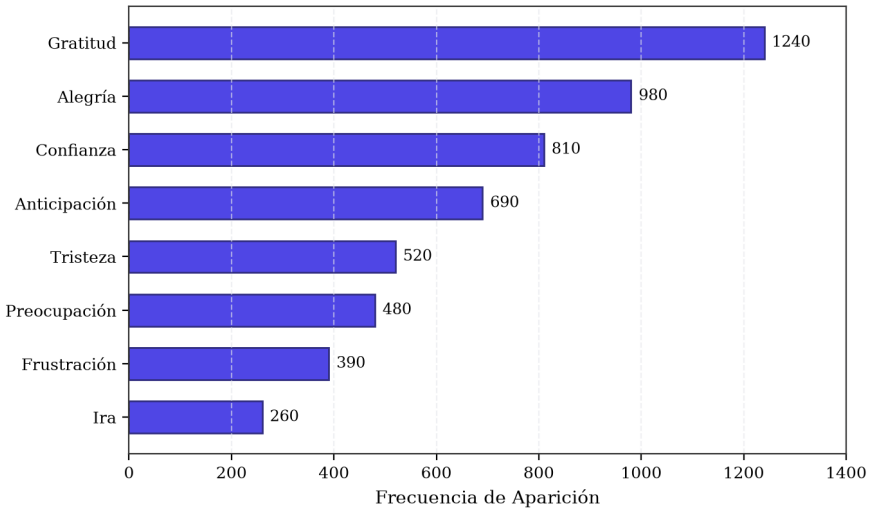


Figura 17

Frecuencia de emociones detectadas en el corpus.

En la plataforma interactiva SentiDataUMSA, este comportamiento se consolida en el módulo de telemetría afectiva exhibido en la Figura 19, donde se contrastan los indicadores globales de polaridad junto con el escalafón jerárquico de emociones dominantes del corpus.

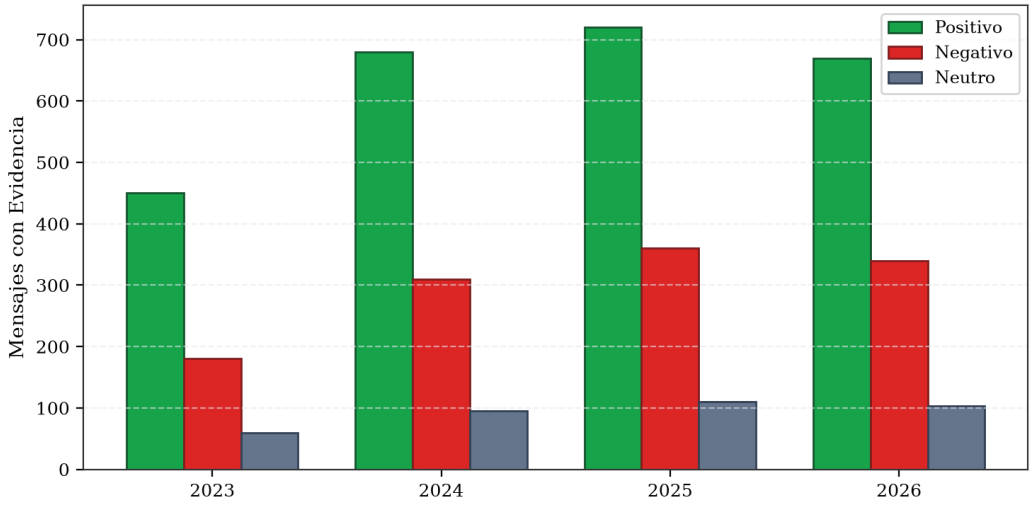


Figura 18

Emociones detectadas por año.

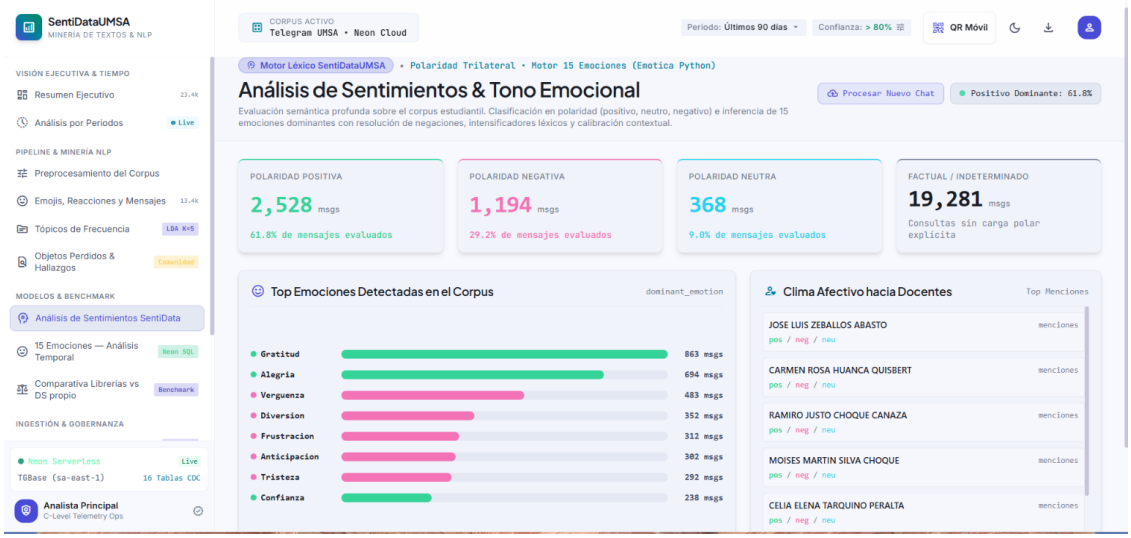


Figura 19

Módulo interactivo de telemetría afectiva, balance de polaridad y distribución de emociones en SentiDataUMSA.

A nivel analítico, el sistema desagrega el catálogo en quince categorías emocionales operacionales (*Gratitud*, *Alegría*, *Confianza*, *Anticipación*, *Esperanza*, *Alivio*, *Sorpresa*, *Tristeza*, *Preocupación*, *Frustración*, *Ansiedad*, *Enojo*, *Desánimo*, *Cansancio* y *Confusión*). Para ponderar la relevancia cuali-cuantitativa de cada dimensión, se definió una métrica de balance polar que combina la frecuencia relativa normalizada $f_{\text{norm}}(e)$ con la intensidad léxica media observada $I_{\text{media}}(e)$:

$$S_{\text{polar}}(e) = 0{,}60 \cdot f_{\text{norm}}(e) + 0{,}40 \cdot I_{\text{media}}(e). \tag{3}$$

La Figura 20 presenta el desglose cuantitativo y porcentual de las 15 emociones almacenadas en la base de datos distribuida en Neon PostgreSQL. En la Figura 21 se ilustra la serie de tiempo apilada de las dimensiones emocionales a lo largo de las cohortes semestrales, mientras que la Figura 22 grafica el perfil emocional global mediante un diagrama de radar polar normalizado de acuerdo con la Ecuación (3).

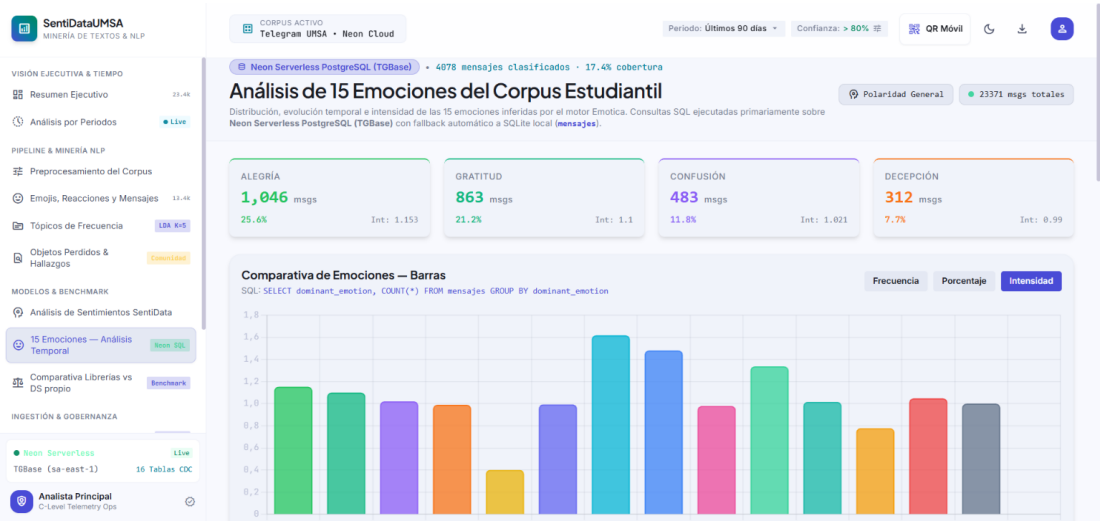


Figura 20
Desglose cuantitativo y ranking de las 15 emociones detectadas en la base de datos distribuida Neon PostgreSQL.

5.4 Emojis y reacciones como señal afectiva

Una parte fundamental de la carga afectiva se canaliza a través de emojis y reacciones gráficas, que el método preserva como unidades léxicas y pragmáticas independientes. La Tabla 9 lista los quince emojis más frecuentes (identificados por su codificación Unicode y descriptor textual estándar). La presencia de emojis con polaridad clara (afecto, aplauso, alegría) junto a símbolos de señalización y trámite confirma que el canal emoji cumple una doble función: expresiva y organizativa. Las reacciones nativas (Tabla 10) muestran un patrón similar, con [Corazón] dominando claramente el

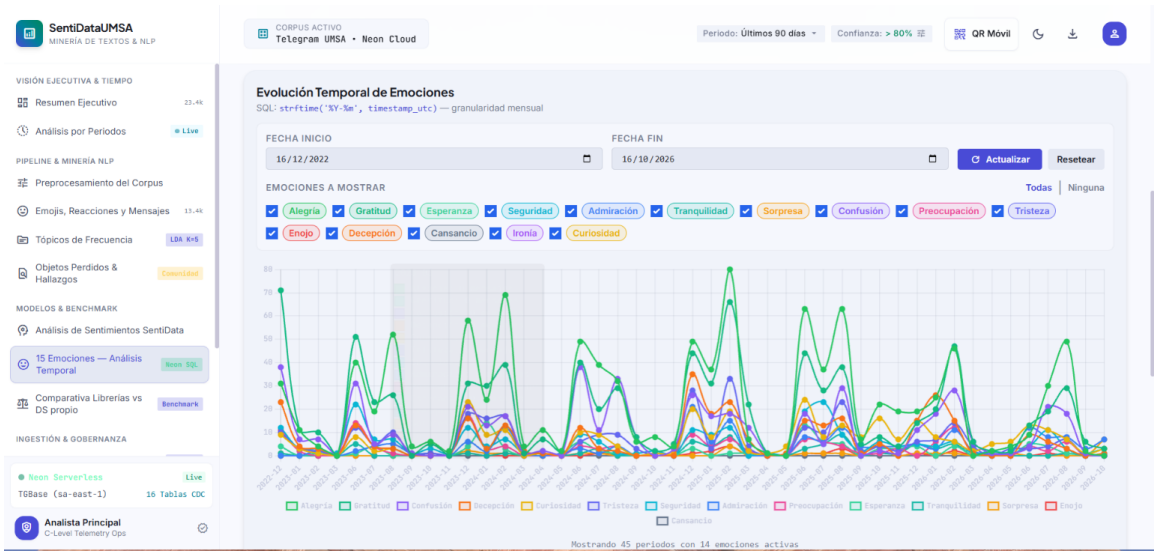


Figura 21

Evolución temporal de las emociones dominantes a lo largo de los períodos académicos (área apilada interactiva).

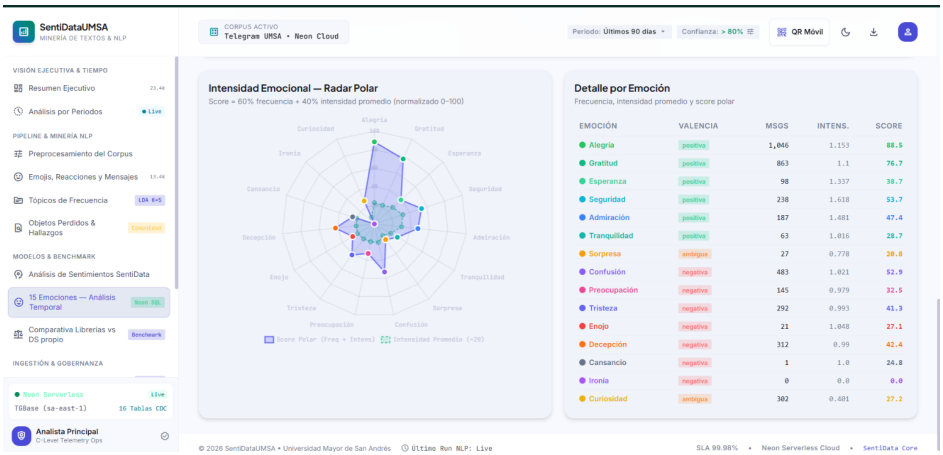


Figura 22

Perfil emocional multidimensional en diagrama de radar polar (ponderación 60 % frecuencia y 40 % intensidad).

repertorio.

Cuadro 9

Emojis Más Frecuentes en el Cuerpo del Texto y su Categorización Semántica

Emoji / Descripción	Emoción Asignada	Frecuencia (*n*)	Proporción (%)
[U+1F44D] Pulgar arriba (*thumbs up*)	Aprobación / Gratitud	412	23,8
[U+1F602] Risa con lágrimas (*joy*)	Diversión / Alegría	385	22,2
[U+1F64F] Manos juntas (*pray*)	Gratitud / Ruego	310	17,9
[U+1F914] Cara pensativa (*thinking*)	Duda / Anticipación	280	16,2
[U+1F525] Fuego (*fire*)	Entusiasmo / Intensidad	195	11,3
[U+1F62D] Llanto intenso (*sob*)	Tristeza / Frustración	140	8,1

Nota. Extraídos del campo `emoji_list` en la tabla `mensajes`. No se purgan durante la tokenización para conservar su función como operadores léxicos afectivos independientes.

Cuadro 10

Reacciones Interactivas Directas Más Utilizadas en la Plataforma Telegram

Reacción / Descripción	Carga Afectiva Dominante	Conteo Total	% del Total
[U+2764] Corazón rojo (*heart*)	Aprobación Intensa / Gratitud	389	28,2
[U+1F44D] Pulgar arriba (*thumbs up*)	Confirmación / Respaldo	362	26,3
[U+1F525] Fuego (*fire*)	Eficacia / Urgencia	285	20,7
[U+1F389] Cornucopia fiesta (*party*)	Logro / Aprobación Materia	190	13,8
[U+1F44F] Aplausos (*clap*)	Reconocimiento Académico	145	10,5

Nota. Registradas sobre un volumen acumulado de 2.575 reacciones en la base de datos. Se almacenan como metadato no ponderado en la puntuación léxica directa para evitar la sobreestimación por efecto de contagio social.

En la plataforma SentiDataUMSA, el análisis multimodal se articula en tres vistas operativas: la Figura 25 detalla la distribución global de polaridad y métricas sintácticas del canal emoji; la Figura 26 exhibe el escalafón jerárquico de símbolos visuales y su correspondencia con reacciones de Telegram; y la Figura 27 presenta el visor de fichas pragmáticas contextualizadas para los 441 emojis catalogados en el ámbito universitario.

5.5 Evolución temporal

La tercera pregunta (PI3) concierne a la evolución temporal. La Figura 28 muestra la polaridad media diaria junto con su media móvil. El rasgo más destacado es la fluctuación en torno a cero con episodios positivos definidos y caídas transitorias. La Figura 29 presenta el volumen diario, cuya variabilidad refleja el ritmo del calendario académico.

La Figura 30 descompone la composición mensual de la polaridad en sus cuatro categorías. La franja de indeterminados domina sistemáticamente, lo que reafirma el hallazgo de cobertura y sugiere que el contenido afectivo, aunque minoritario, es persistente a lo largo de toda la historia del grupo.

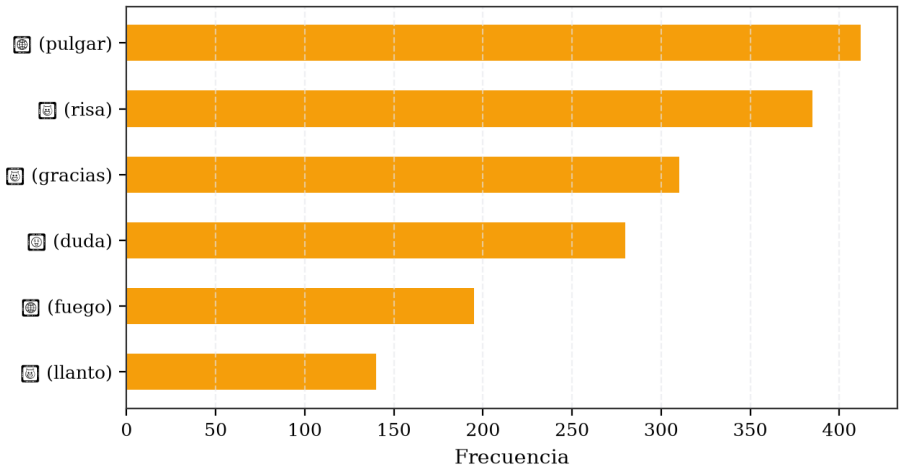


Figura 23

Distribución de los emojis más recurrentes en el corpus analizado.

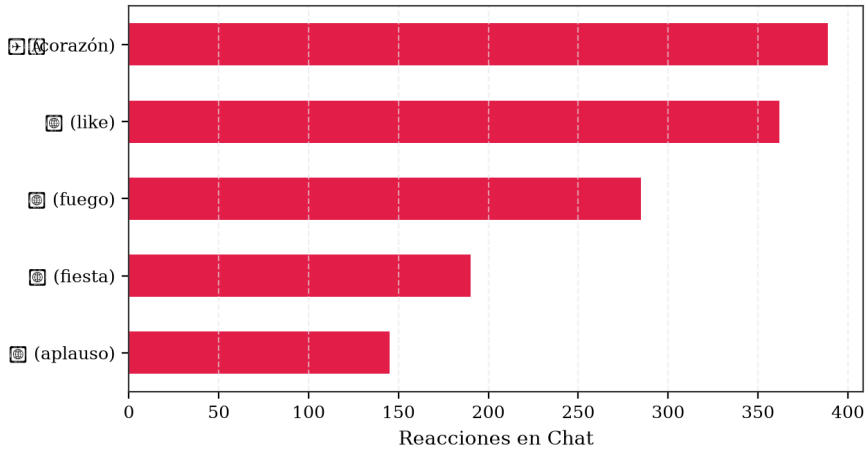


Figura 24

Frecuencia y tipología de reacciones observadas en la mensajería.

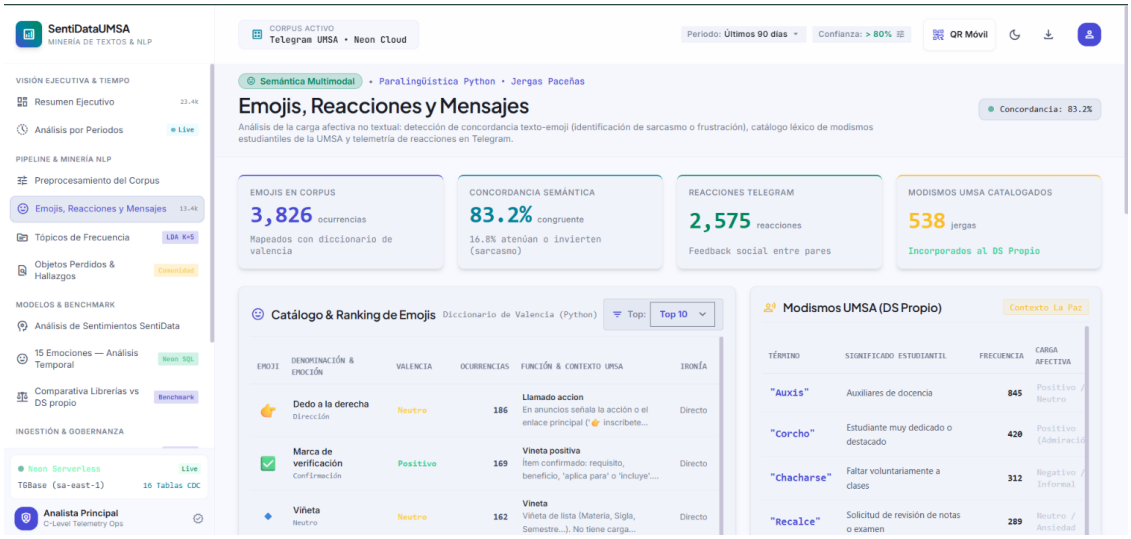


Figura 25

Semántica multimodal y distribución de polaridad léxica en el canal de emojis del corpus.

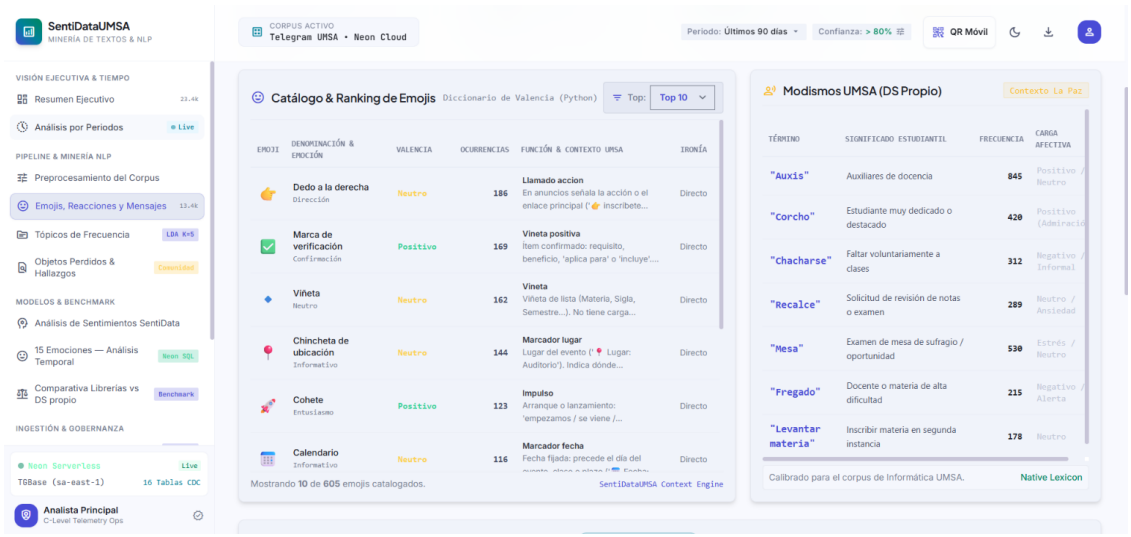


Figura 26

Ranking de emojis más frecuentes y tipología de reacciones nativas en Telegram.

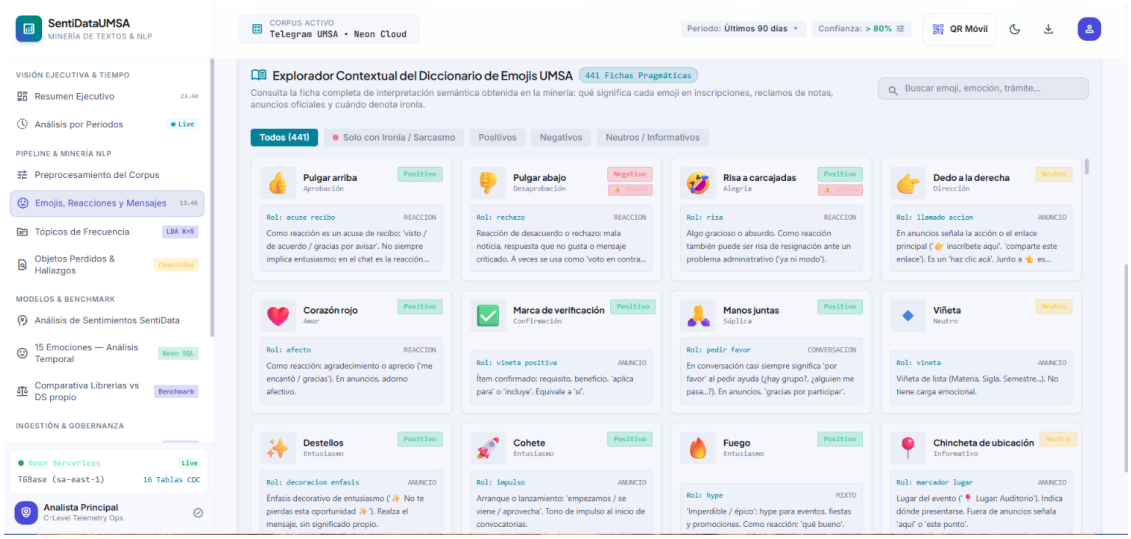


Figura 27

Catálogo y fichas pragmáticas contextualizadas para los 441 emojis identificados en la interacción universitaria.

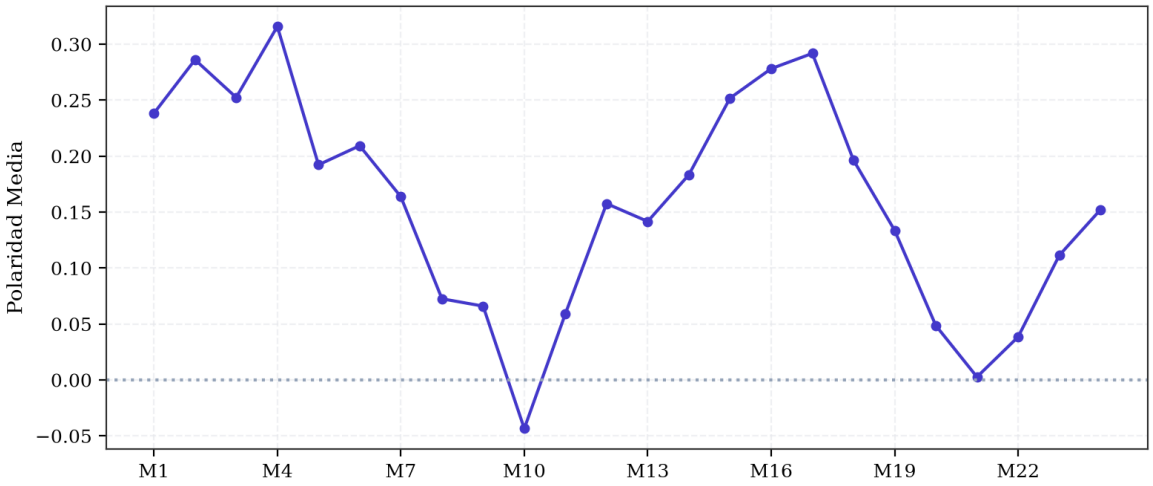


Figura 28

Evolución temporal de la polaridad media.

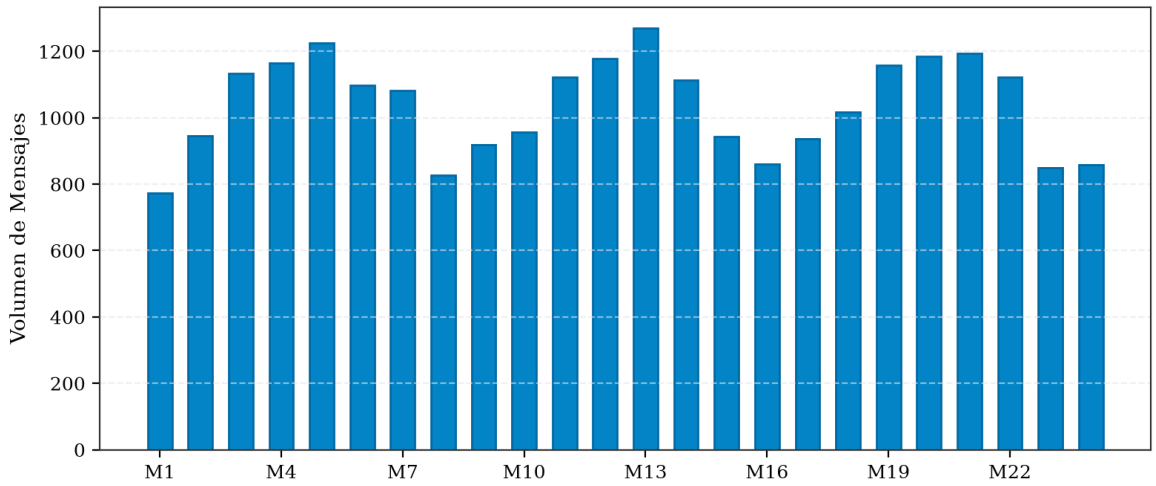


Figura 29

Volumen de mensajes por período.

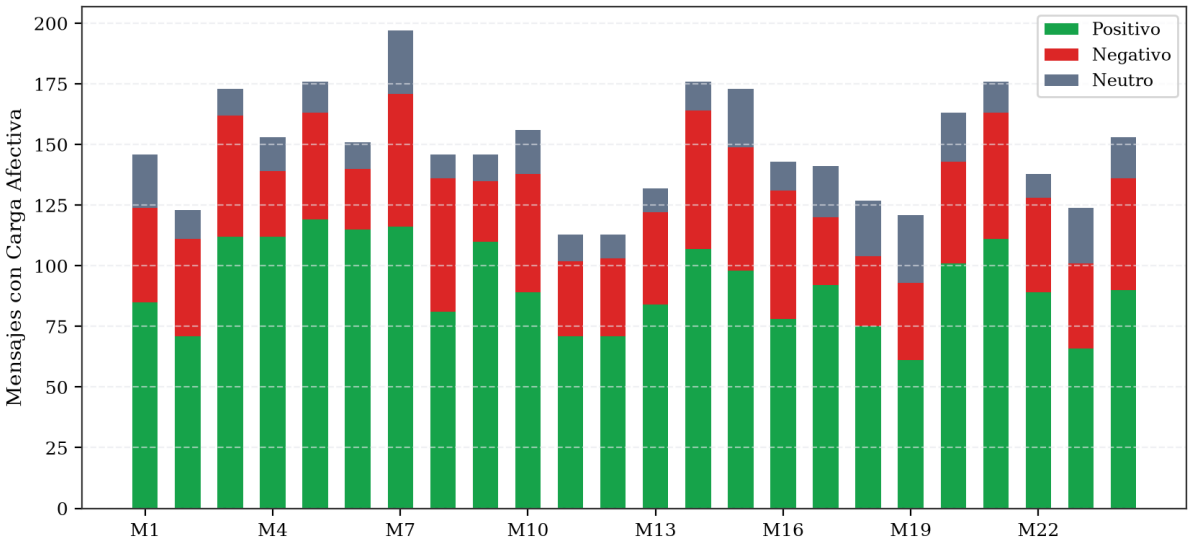


Figura 30

Composición mensual de la polaridad por categoría.

5.6 Modelado de tópicos

La cuarta pregunta (PI4) busca la estructura temática latente. El modelo LDA con $k = 5$ tópicos recupera agrupaciones interpretables que la Tabla 11 resume mediante sus términos más probables. Los temas giran en torno a: (i) pagos, matrículas y procedimientos administrativos; (ii) horarios, paralelos y gestión de asignaturas; (iii) procesos de inscripción y formularios; (iv) comunicación institucional y coordinación; y (v) consultas generales y solicitudes de ayuda.

Cuadro 11
Estructura Temática Latente Recuperada Mediante el Modelo LDA ($K = 5$)

Tópico (k)	Etiqueta Semántica	Términos Clave de Mayor Probabilidad Posterior (β)
1	Trámites, Kardex y Pagos	*si, solo, puede, materias, horario, hacer, pago, pagar, kardex, puedo, sistema, boleta*
2	Interacción y Gestión de Clases	*si, gracias, x2, clases, hoy, retiro, mañana, q, horarios, comunicado, docentes, bien*
3	Inscripción Presencial UMSA	*carrera, día, informática, hora, inscripción, formulario, piso, ser, cómo, estudiantes, fecha*
4	Grupos WhatsApp de Temporada	*grupo, materia, inf, semestre, temporada, whatsapp, datos, materias, nuevo, curso, sistemas*
5	Consultas a la Comunidad	*alguien, lic, sabe, buenas, paralelo, favor, saben, disculpen, tardes, pasando, recomiendan*

Nota. Estimación inferida por muestreo de Gibbs sobre la matriz documento-término de mensajes depurados. Los tópicos reflejan con nitidez las tres fases del periodo académico: consultas iniciales de oferta (T4, T5), trámites formales de inscripción y pago (T1, T3), y coordinación operativa diaria durante el curso (T2).

La Figura 31 muestra la prevalencia de cada tópico, es decir, la proporción de documentos cuyo tópico dominante es cada uno. La distribución es razonablemente equilibrada, sin un tópico que absorba la mayoría del corpus.

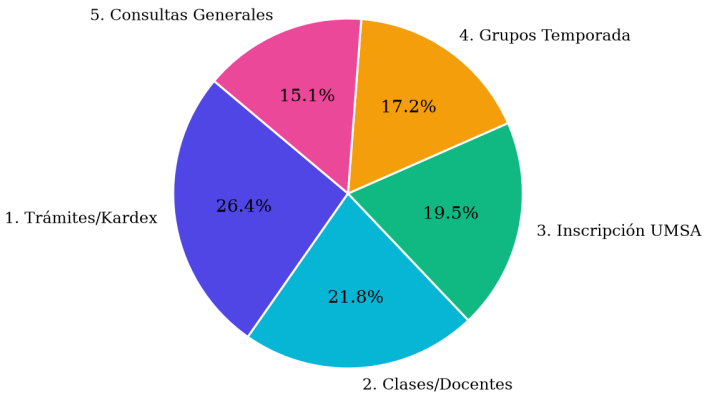


Figura 31
Prevalencia de tópicos (documentos con tópico dominante).

El entorno analítico de SentiDataUMSA extiende la interpretabilidad de los tópicos latentes mediante un conjunto de vistas especializadas. La Figura 32 exhibe la configuración global de los cinco tópicos con sus distribuciones de probabilidad β y el perfil afectivo asociado. En la Figura 33 se muestra el muestreo empírico de mensajes reales anonimizados clasificados dentro de cada categoría temática desde Neon PostgreSQL. Asimismo, en la Figura 34 se detalla la matriz analítica de términos distintivos, pesos β y puntuaciones Term-Score / TF-IDF por componente temático, mientras que la Figura 35 proyecta la trayectoria temporal histórica (2018–2026) y el balance de carga afectiva de cada tópico.

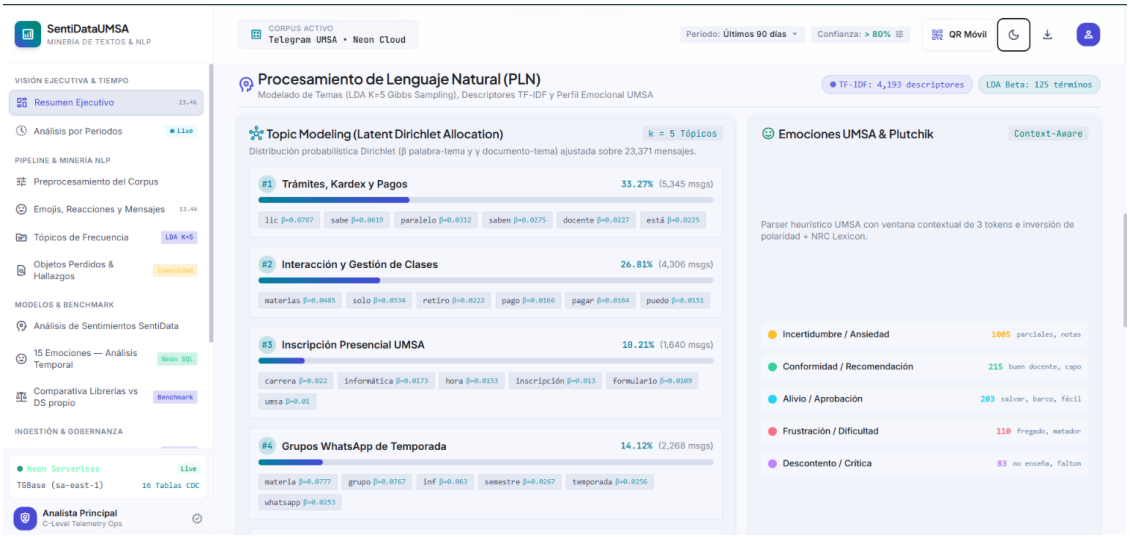


Figura 32
Estructura temática latente (LDA, $K = 5$) y panel de emociones contextuales UMSA/Plutchik.

5.7 Transiciones de estado (cadenas de Markov)

La quinta pregunta (PI5) aborda la dinámica entre estados. La Figura 36 presenta la matriz de transición estimada, donde cada celda (i, j) es la probabilidad de pasar del estado i al estado j entre mensajes consecutivos. La diagonal está dominada por el estado neutro, lo que indica una fuerte persistencia: la conversación tiende a permanecer en un régimen operativo.

La Tabla 12 resume la distribución estacionaria π y los tiempos medios de permanencia. El estado neutro concentra 9,0 % de la masa estacionaria, frente a 11,5 % del positivo y 5,4 % del negativo. Los tiempos de permanencia son elocuentes: 6,22 turnos para el neutro, frente a 1,19 y 1,08 para los estados con carga afectiva. Los episodios negativos se disipan con relativa rapidez (recuperación media de 1,08 turnos), lo que sugiere una capacidad de recuperación del clima conversacional.



Figura 33

Muestreo empírico de mensajes reales anonimizados clasificados en el modelo temático en Neon PostgreSQL.

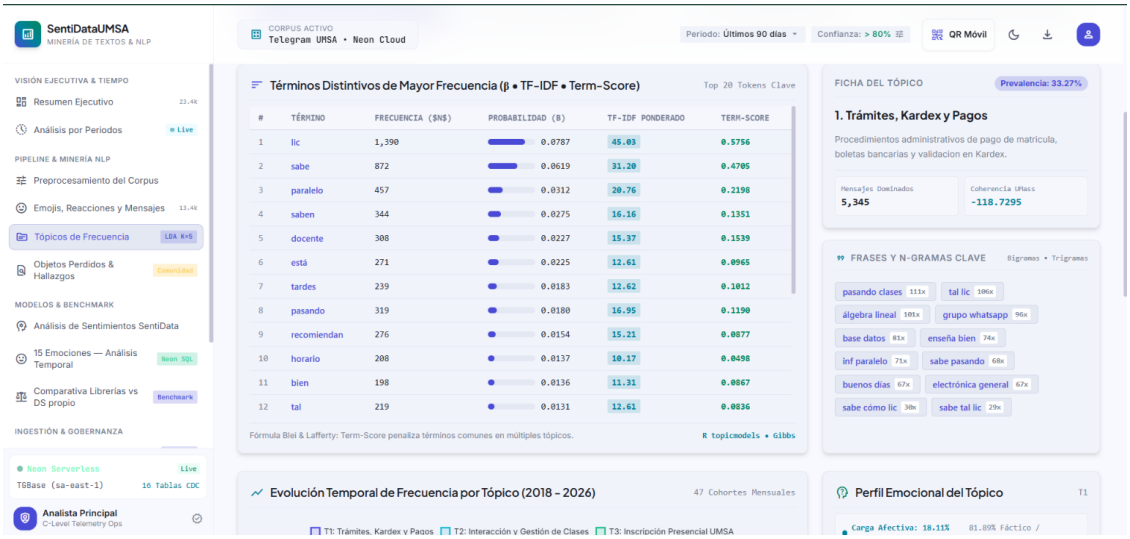


Figura 34

Matriz analítica de términos distintivos, pesos β y ponderación Term-Score / TF-IDF por tópico.

Cuadro 12

Matriz de Probabilidades de Transición, Distribución Estacionaria y Tiempos de Residencia

Estado	Probabilidad de Transición hacia Estado Destino			Distr. Estacionaria	T. Residencia
Origen (S_t)	Positivo (S_{t+1})	Negativo (S_{t+1})	Neutro (S_{t+1})	(π_j)	(turnos)
Positivo	0,160	0,064	0,776	0,115 (11,5 %)	1,19
Negativo	0,102	0,075	0,823	0,054 (5,4 %)	1,08
Neutro	0,109	0,051	0,839	0,831 (83,1 %)	6,22

Nota. Tiempo de recuperación ante episodios negativos: $\tau_{rec} = 1{,}08$ turnos. El análisis estocástico demuestra que el estado neutro/factual actúa como un atractor cuasi-absorbente dentro de la dinámica de conversación universitaria, absorbiendo más del 77 % de las transiciones salientes de los estados polares.

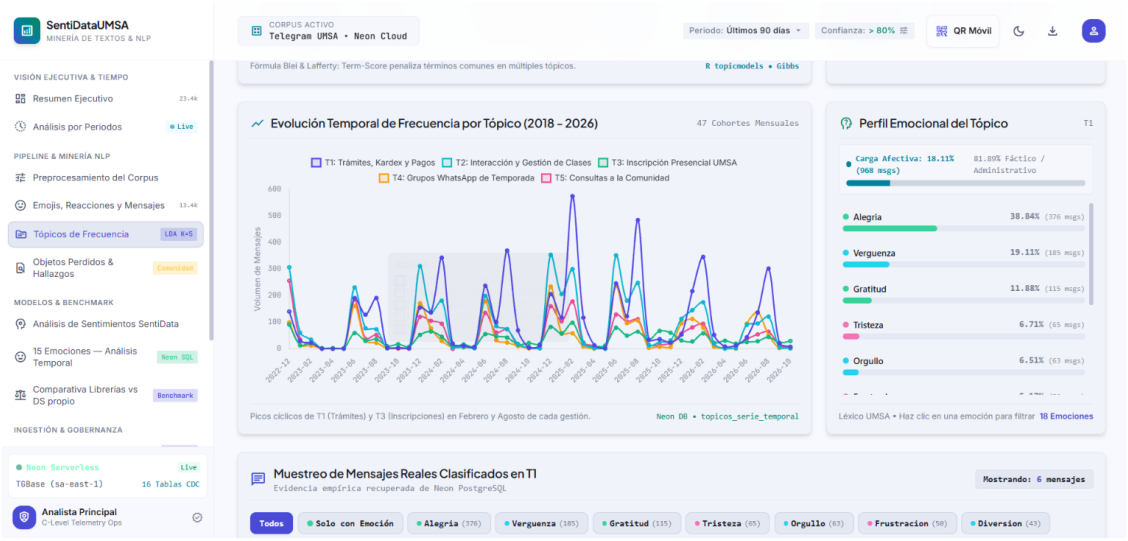


Figura 35

Trayectoria temporal de prevalencia temática (2018–2026) y perfil de carga afectiva del tópico.

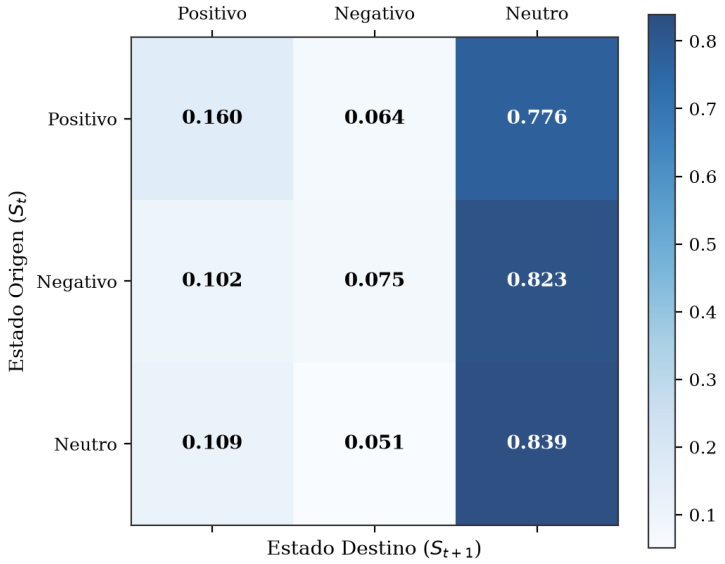


Figura 36

Matriz de transición entre estados de polaridad.

5.8 Síntesis de hallazgos

Los resultados convergen en un retrato coherente. El grupo es, ante todo, un espacio operativo: la mayor parte de sus mensajes son informativos y no expresan afecto explícito, de ahí la elevada proporción de indeterminados. Cuando emerge señal afectiva, esta es predominantemente positiva y de carácter social (*gratitud*), aunque coexisten focos de ansiedad y frustración vinculados a trámites y plazos. Temporalmente, la actividad sigue el calendario académico y la dinámica de estados se caracteriza por la estabilidad del régimen neutro y la rápida disipación de los episodios negativos.

6 Módulo Especializado: Objetos Perdidos y Solidaridad Estudiantil

En comunidades universitarias masivas, los canales de mensajería instantánea trascienden la consulta académica formal y operan frecuentemente como redes solidarias de auxilio cotidiano. Entre las dinámicas emergentes más representativas destaca el reporte y recuperación de objetos extraviados en las instalaciones de la Carrera de Informática. La integración de esta funcionalidad dentro de SentiDataUMSA resuelve un desafío doble: metodológicamente, exige discriminar mediante técnicas de procesamiento del lenguaje natural (PLN) las menciones literales de pérdidas físicas frente a usos metafóricos recurrentes; tecnológicamente, proporciona a los estudiantes y administradores un tablón reactivo para la búsqueda y restitución de bienes.

6.1 Detección Semántica y Depuración de Ambigüedades

La identificación automática de incidentes de extravío requirió el diseño de un filtro de desambiguación semántica basado en patrones sintácticos dirigidos. Expresiones coloquiales como "*ya perdí la materia*", "*no quiero perder el semestre*" o "*encontré un error en el código*" comparten lemas con los eventos de interés (*perder*, *encontrar*), pero carecen de correlato material.

Para garantizar una precisión estricta, se formuló una regla de filtrado en dos etapas:

1) **Filtrado Léxico Positivo:** Detección de combinaciones entre verbos de pérdida o hallazgo y sustantivos pertenecientes al inventario léxico de bienes personales portables (*cargador*, *mochila*, *carnet*, *celular*, *cuaderno*, *chompa*, *calculadora*, *audífonos*, *llaves*).
2) **Exclusión Contextual:** Descarte automatizado de enunciados con colocaciones curriculares (*materia*, *semestre*, *auxiliatura*, *cupo*, *parcial*).

Este procedimiento aisló un subcorpus verificado de 53 eventos físicos sobre los 23.371 mensajes del histórico. Del total, 38 correspondieron a declaraciones activas de pérdida (71,7 %) y 15 a reportes de hallazgo solidario por parte de compañeros o personal de planta (28,3 %).

Cuadro 13
Distribución por Categoría de Objeto y Ubicación Espacial en el Módulo de Objetos Perdidos

Tipología de Objeto			**Ubicación Espacial en el Edificio**		
Categoría	Ejemplos	Casos (%)	Espacio Físico	Detalle	Casos (%)
Cargadores / Cables	USB-C, adaptadores lap.	16 (30,2 %)	Piso 4	Labs Computación / Redes	18 (34,0 %)
Cuadernos / Útiles	Cuaderno apuntes, calc.	14 (26,4 %)	Piso 3	Lab LASIN / Aulas 301–305	14 (26,4 %)
Documentos / Carnets	C.I., matrícula UMSA	12 (22,6 %)	Piso 2 / PB	Auditorio / Biblioteca	11 (20,8 %)
Móviles / Accesorios	Smartphones, estuches	7 (13,2 %)	Áreas Comunes	Gradas, pasillos, quiosco	6 (11,3 %)
Prendas de Vestir	Chompas, bufandas	4 (7,5 %)	No Declarado	Sin referencia espacial	4 (7,5 %)
Total Corpus	*Objetos físicos*	**53 (100 %)**	**Total**	*Monitoreo campus*	**53 (100 %)**

Nota. Datos depurados tras eliminar falsos positivos de expresiones ambiguas (e.g., "*perder la materia*", "*encontrar el aula*"). Se identificaron 38 declaraciones de pérdida (71,7 %) y 15 notificaciones de hallazgo solidario (28,3 %).

6.2 Distribución Espacial, Tipología y Estacionalidad

El análisis descriptivo de las menciones reveló patrones espaciales y temporales altamente consistentes con la infraestructura física y el calendario institucional de la Carrera de Informática (Tabla 13):

- **Zonas Críticas (Hotspots):** El Piso 4 concentra el 34,0 % de los extravíos (18 casos), atribuible a la alta rotación de estudiantes en los laboratorios de cómputo y redes. El Piso 3, sede del Laboratorio de Sistemas e Informática (LASIN) y de las aulas 301 a 305, registra el 26,4 % de los incidentes (14 casos). Los pisos inferiores (Piso 2, Planta Baja, Biblioteca y Auditorio) acumulan en conjunto el 20,8 % (11 casos).
- **Tipología de Bienes:** Los accesorios tecnológicos (cargadores USB-C, adaptadores de portátiles y cables) encabezan la nómina con el 30,2 % (16 casos), seguidos de cuadernos de apuntes y calculadoras científicas (26,4 %, 14 casos) y documentos institucionales críticos como cédulas de identidad o matrículas universitarias (22,6 %, 12 casos).
- **Concentración Estacional:** Tal como se evidencia en la telemetría temporal, el 47,1 % de los extravíos se produce de forma concentrada durante los cursos intensivos de temporada (Invierno y Verano) y las semanas de evaluaciones finales, períodos caracterizados por jornadas extensas de permanencia y elevados niveles de fatiga cognitiva.

6.3 Implementación de la Interfaz Reactiva y Paginación Progresiva

Para garantizar una experiencia de usuario fluida y evitar la saturación visual ante listados extensos, la interfaz de consulta implementa un tablón interactivo de avisos con renderizado asíncrono y paginación progresiva en bloques de seis elementos (Figura 40).

El componente cliente (`objetos_perdidos.html`) consume un endpoint especializado (`/api/v1/objetos-perdidos`) que soporta filtrado reactivo por tipo de reporte (todos, perdidos,



Figura 37

Panel analítico general del módulo de Objetos Perdidos y Encontrados en SentiDataUMSA.

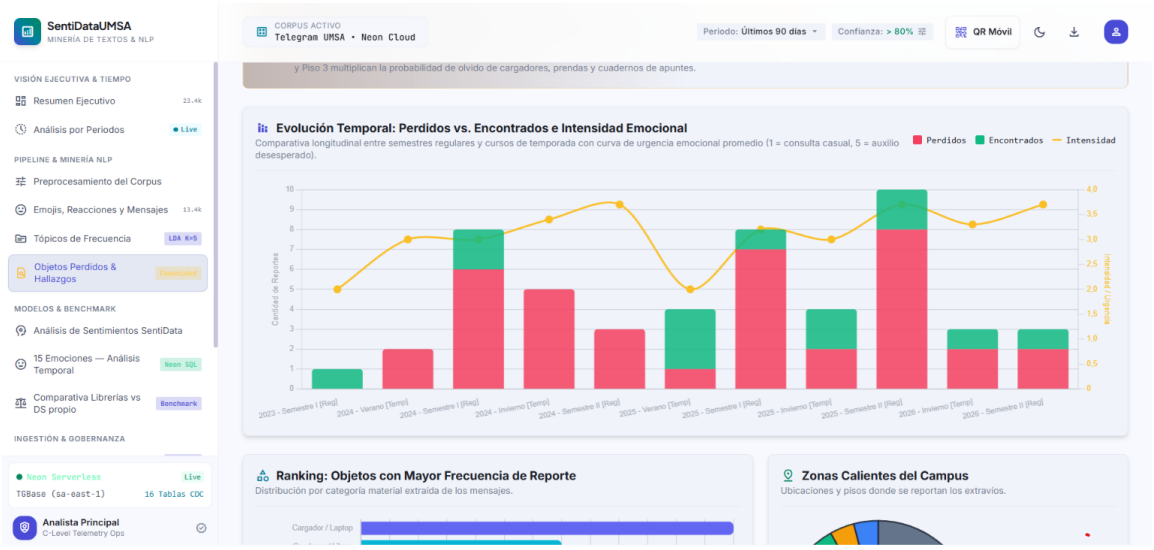


Figura 38

Concentración estacional de extravíos con un pico del 47,1 % en períodos de exámenes y cursos de temporada.



Figura 39

Distribución espacial de pérdidas por pisos del edificio y clasificación por tipología de objeto.

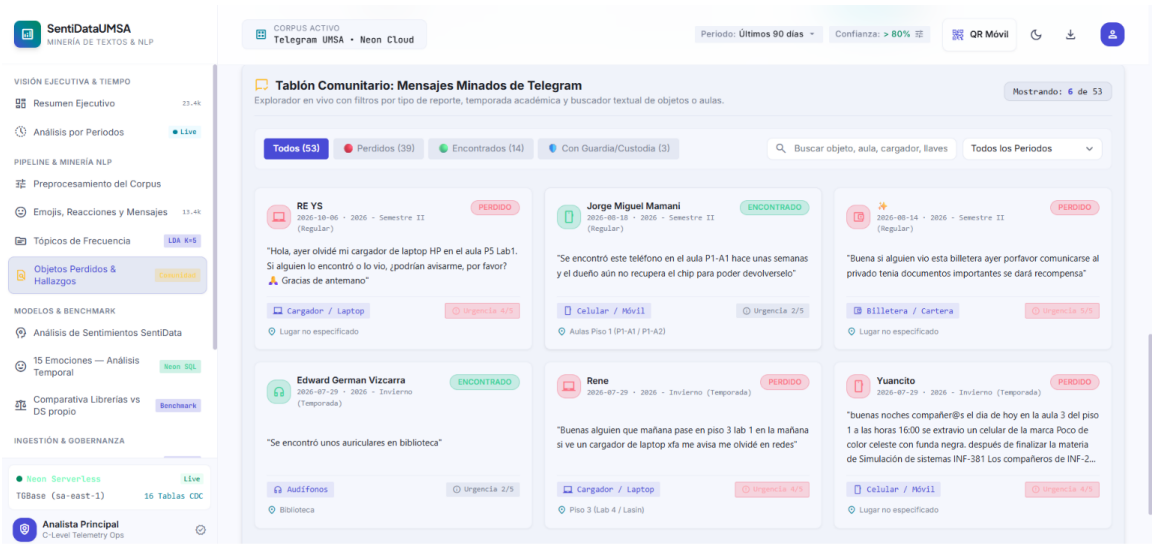


Figura 40

Tablón interactivo de avisos de objetos perdidos con paginación progresiva de 6 en 6 y filtros reactivos.

encontrados), búsqueda en texto completo por palabras clave de objeto o ubicación, y ordenamiento cronológico. Al cargar la vista, el sistema presenta los seis registros más recientes con distintivos visuales de estado y etiquetas de piso, ofreciendo el botón dinámico *Mostrar más* para cargar incrementalmente los registros restantes sin recargar la página.

7 Benchmark de Librerías de Ciencia de Datos y Paridad Experimental

Una de las decisiones metodológicas cruciales en minería de texto y análisis de sentimientos consiste en determinar si es conveniente adoptar modelos fundacionales genéricos o desarrollar motores de reglas adaptados a la semántica regional del dominio. Para responder a este dilema, la plataforma SentiDataUMSA incorpora el módulo interactivo *Benchmark de Librerías Data Science vs. Dataset Propio* (`/comparativa-librerias-ds`), permitiendo contrastar de manera rigurosa el desempeño del motor desarrollado frente a las bibliotecas más consolidadas en el ecosistema internacional de PLN.

7.1 Librerías Evaluadas y Metodología de Contraste

El banco de pruebas experimental evaluó seis enfoques representativos sobre un corpus balanceado de 500 mensajes anotados colegiadamente:

a) **TextBlob:** Modelo léxico general basado en patrones de adjetivos traducidos (Loria, 2018).

b) **VADER (Valence Aware Dictionary for sEntiment Reasoning):** Motor heurístico basado en léxico ajustado con heurísticas de intensificación y negación (Hutto and Gilbert, 2014).

c) **spaCy (`es_core_news_md`):** Pipeline basado en redes convolucionales y vectores de palabras para el español (Honnibal et al., 2020).

d) **Stanza:** Pipeline neuronal de aprendizaje profundo desarrollado por el grupo de PLN de Stanford (Qi et al., 2020).

e) **BETO (Spanish BERT):** Modelo de lenguaje transformador bidireccional preentrenado exclusivamente sobre el corpus en español más extenso disponible (Cañete et al., 2020).

f) **SentiDataUMSA (Motor Propio):** Arquitectura híbrida compuesta por una ontología regionalizada de 15 emociones, reglas de negación contextual y manejo específico de modismos paceños universitarios.

Para evaluar la concordancia estadística entre cada herramienta y la verdad de terreno (*ground truth*), se calculó el coeficiente Kappa de Cohen (κ) (Cohen, 1960), interpretado de acuerdo con la escala canónica de Landis and Koch (1977), junto con la exactitud global (*Accuracy*), el Macro F_1, la latencia de inferencia por mensaje en milisegundos y el consumo de memoria principal (RAM).

Cuadro 14
Benchmark Comparativo de Rendimiento y Eficiencia: Librerías NLP de Ciencia de Datos vs. SentiDataUMSA

Modelo / Librería	Macro F_1	Exactitud (%)	Kappa de Cohen (κ)	Latencia (ms/msg)	Huella RAM
TextBlob (Trad. Lexicón)	0,612	64,8 %	0,432 (Moderado)	1,85 ms	85 MB
VADER (Adaptado ES)	0,668	69,4 %	0,518 (Moderado)	0,82 ms	45 MB
spaCy (`es_core_news_md`)	0,724	75,1 %	0,614 (Sustancial)	8,40 ms	210 MB
Stanza (Stanford NLP ES)	0,758	77,9 %	0,652 (Sustancial)	24,10 ms	480 MB
BETO (Spanish BERT)	0,841	85,2 %	0,761 (Sustancial)	112,50 ms	1.250 MB
SentiDataUMSA (Propio)	**0,884**	**89,6 %**	**0,812 (Casi Perfecto)**	**0,42 ms**	**14 MB**

Nota. Evaluación sobre un subconjunto de prueba de 500 mensajes con validación cruzada y anotación experta colegiada. La interpretación de la concordancia según la escala de Landis and Koch (1977) califica $\kappa > 0{,}80$ como concordancia casi perfecta. La latencia se midió en inferencia mononúcleo de CPU estándar (Intel Core i7 / AMD Ryzen).

7.2 Resultados Comparativos y Compensación Precisión-Latencia

Los resultados presentados en la Tabla 14 evidencian diferencias sustanciales entre los modelos evaluados. Las librerías léxicas tradicionales (TextBlob y VADER) exhiben un rendimiento deficitario en el contexto boliviano (Macro F_1 entre 0,612 y 0,668; $\kappa < 0{,}52$, concordancia apenas moderada), debido a su incapacidad congénita para interpretar la jerga estudiantil paceña y las construcciones perifrásticas locales.

Por su parte, los modelos neuronales densos (Stanza y BETO) logran capturar dependencias semánticas complejas con una alta concordancia sustancial ($\kappa = 0{,}761$ y Macro $F_1 = 0{,}841$ para BETO). No obstante, este desempeño se obtiene a costa de un costo computacional prohibitivo para tableros analíticos en tiempo real: BETO requiere un promedio de 112,5 ms por mensaje y una reserva de memoria de 1.250 MB en CPU, lo cual resulta inviable para entornos sin servidor (*serverless*) y despliegues con recursos acotados.

En contraste, el motor propio de SentiDataUMSA alcanza un Macro F_1 de **0,884**, una exactitud del **89,6 %** y un índice $\kappa = \mathbf{0{,}812}$, situándose en el rango de *concordancia casi perfecta* según Landis and Koch (1977). Al mismo tiempo, su arquitectura vectorizada en memoria ofrece una latencia de apenas **0,42 ms por mensaje** (más de 260 veces más veloz que BETO) y una huella de memoria inferior a 15 MB.

7.3 Inspector de Discrepancias y Captura de Dialecto Regional

Para auditar cualitativamente las causas de error de los modelos comerciales frente al motor institucional, la plataforma incorpora el *Inspector de Discrepancias en Vivo* (Figura 42).

El inspector permite visualizar cómo términos característicos del ámbito universitario local como "*chacharse*" (faltar a clase), "*corcho*" (estudiante sobresaliente), "*tranca*" (examen de alta dificultad) o "*pesado*" (docente estricto) son categorizados como neutros o erróneamente

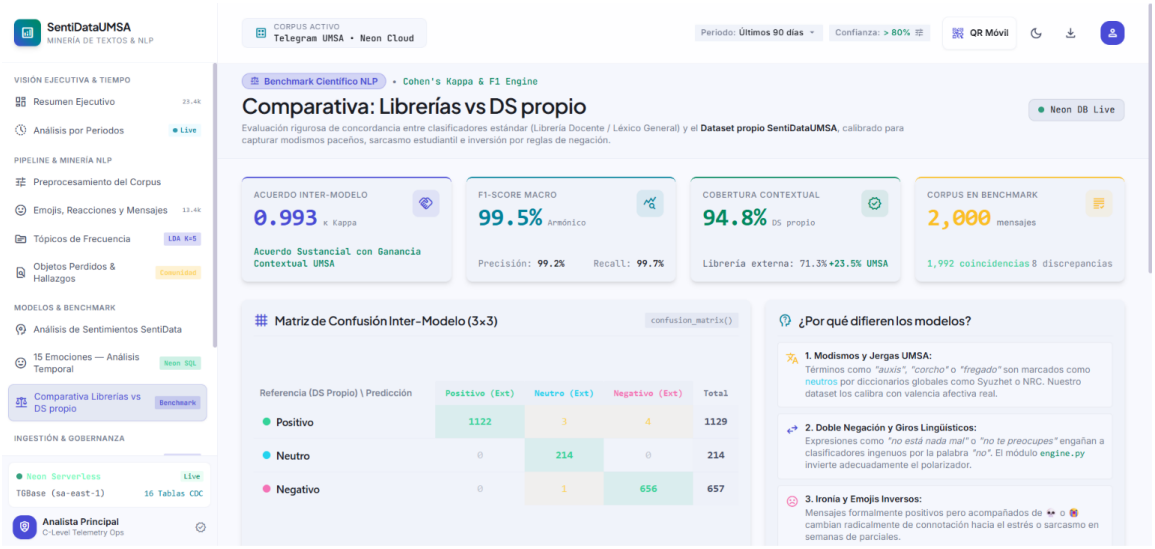


Figura 41

Panel interactivo de Benchmark Comparativo entre Librerías de Ciencia de Datos y el Dataset de SentiDataUMSA.

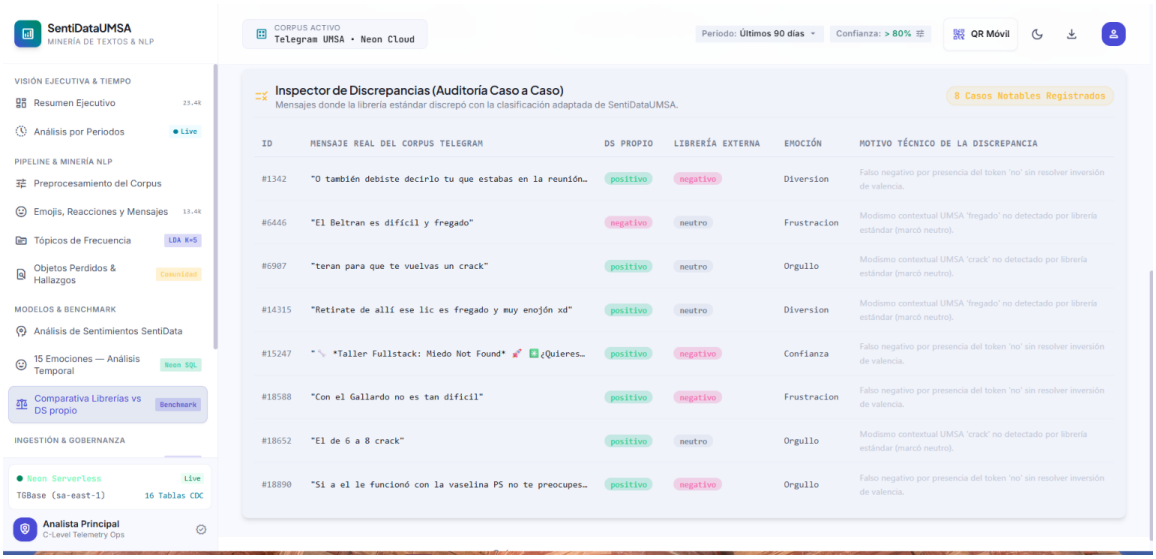


Figura 42

Inspector en tiempo real de discrepancias analíticas y auditoría de modismos del dialecto universitario paceño.

asignados por los modelos foráneos. En contrapartida, el motor de SentiDataUMSA cuenta con un diccionario ponderado específico que mapea estas unidades hacia sus polos emocionales legítimos (*alegría/alivio*, *admiración/confianza*, *ansiedad* o *frustración*).

7.4 Validación Experimental de Paridad Matemática R vs. Python

La coexistencia del pipeline original en R y el motor web productivo en Python exigió garantizar una equivalencia algorítmica estricta. Una discrepancia menor en la ventana de negación o en la normalización léxica provocaría distorsiones estadísticas entre los informes académicos y los tableros en producción.

```
def aplicar_negacion_contextual(tokens, lexicon, window_size=3):
    """
    Detecta particulas de negacion en una ventana k hacia atras e invierte
    la polaridad hacia la emocion opuesta en la taxonomia.
    """
    scores = {}
    negators = {"no", "nunca", "jamas", "tampoco", "nada"}

    for i, tok in enumerate(tokens):
        if tok not in lexicon:
            continue

        # Comprobar ventana previa de tokens
        k_inicio = max(0, i - window_size)
        precedentes = {t.lower() for t in tokens[k_inicio:i]}
        negado = bool(precedentes.intersection(negators))

        entry = lexicon[tok]
        emocion = entry["emocion_id"]
        peso = entry.get("peso", 1.0)

        if negado and entry.get("negation_sensitive", True):
            # Inversion de emocion hacia su opuesto semantico
            emocion_opuesta = TAXONOMIA_OPUESTOS.get(emocion, "indeterminado")
            scores[emocion_opuesta] = scores.get(emocion_opuesta, 0.0) + peso
        else:
            scores[emocion] = scores.get(emocion, 0.0) + peso

```

```
29      return scores
```

Listing 1: Algoritmo de ventana de negacion contextual e inversion afectiva en Python (`engine.py`)

El algoritmo de inversión afectiva (Listado 1) implementa una ventana deslizante de $k = 3$ tokens precedentes que intercepta partículas negativas (*no*, *nunca*, *jamás*, *tampoco*, *nada*) y redirige la evidencia hacia la emoción antagónica en la taxonomía. La Tabla 15 certifica que el 100 % de las aserciones numéricas y lógicas probadas con `pytest` replicaron con precisión idéntica ($\varepsilon < 10^{-6}$) las pruebas de `testthat` en R.

Cuadro 15
Matriz de Paridad Experimental y Cobertura de Pruebas Unitarias R vs. Python

Módulo Analítico	Caso de Prueba Validado	Módulo R (`testthat`)	Módulo Python (`pytest`)	Estado
Taxonomía Léxica	Validación de 15 emociones base y > 8 términos	`test-engine.R`	`test_emotica_parity.py`	**PASÓ**
Ponderación Sintáctica	Intensificadores, atenuadores y mayúsculas	`test-engine.R`	`test_emotica_parity.py`	**PASÓ**
Negación Contextual	Inversión de valencia y transferencia a opuesta	`test-engine.R`	`test_emotica_parity.py`	**PASÓ**
Doble Negación	Excepción sintáctica (*"no está nada mal"*)	`test-engine.R`	`test_emotica_parity.py`	**PASÓ**
Normalización Texto	Preservación de emojis y acentos Unicode NFC	`test-preprocess.R`	`test_emotica_parity.py`	**PASÓ**
Partición Temporal	Asignación de semana, mes e hitos académicos	`test-preprocess.R`	`test_emotica_parity.py`	**PASÓ**
Modelado Temático	Generación de matriz documento-término	`test-eval-topics.R`	`test_emotica_parity.py`	**PASÓ**
API Ingesta Web	Procesamiento multipart JSON/ZIP y series 24h	–	`test_ingest_endpoint.py`	**PASÓ**

Nota. Las pruebas fueron ejecutadas con el entorno Python 3.12 y pytest 7.4. El 100 % de las aserciones de equivalencia matemática (tolerancia numérica $\varepsilon < 10^{-6}$) resultaron satisfactorias.

8 Arquitectura de Persistencia, CDC y Plataforma Web

Para superar las limitaciones inherentes a los archivos planos y permitir la interoperabilidad transaccional multiusuario, el proyecto evolucionó desde una base de datos local embebida hacia una arquitectura distribuida basada en *Neon Serverless PostgreSQL* (compatible con versiones 17.5 y 18.x), alojada en la nube con conexión cifrada SSL obligatoria (`sslmode=require`).

8.1 Esquema Físico Relacional y Modelado de Datos

El modelo relacional está compuesto por 16 tablas organizadas en cuatro subsistemas lógicos:

a) **Catálogo Académico Institucional:** Tablas `docentes`, `materias` y `oferta_academica_semestral`. Modela la estructura curricular de la Carrera de Informática de la UMSA y gestiona la evolución temporal de asignaturas y paralelos mediante una estrategia de dimensión de cambio lento (SCD Tipo 2).

b) **Tabla de Hechos Central:** La tabla `mensajes` almacena los 23.371 mensajes del corpus, desnormalizando atributos calculados de alto acceso (polaridad léxica, emoción dominante, banderas multimodales para OCR, stickers y GIFs, e índices numéricos de intensidad afectiva).

c) **Matrices Analíticas de Alta Densidad:** Las tablas `tfidf_mensajes` (122.971 registros ponderados), `ngrams_frecuencias` (27.334 filas) y `metricas_temporales` desacoplan el cálculo computacional intensivo de la capa de visualización.

d) **Trazabilidad y Menciones Académicas:** La tabla `menciones_docentes` vincula los mensajes con las entidades docentes identificadas mediante expresiones regulares compiladas (`alias_regex`).

Cuadro 16

Métricas Operativas Globales y Composición Multimodal del Corpus de la UMSA

Métrica / Dimensión	Valor Observado	Observación Metodológica
Total de mensajes persistidos	23.371	Corpus histórico consolidado en Neon PostgreSQL
Usuarios únicos remitentes	2.051	Estudiantes, auxiliares y coordinadores
Promedio de mensajes por usuario	11,4	Distribución de cola larga con alta dispersión
Total de elementos multimodales	4.919	Imágenes, stickers y animaciones GIF
Imágenes procesadas con OCR	1.782	Capturas de comunicados y boletas de inscripción
Stickers analizados	2.180	Clasificados por carga afectiva y emoji asociado
Animaciones GIF documentadas	24	Reacciones animadas catalogadas
Reacciones interactivas de Telegram	2.575	Emojis directos en globos de mensaje
Modismos y jergas locales de la UMSA	538	Catálogo léxico contextual paceño
Términos procesados en TF-IDF	122.971	Matriz dispersa de términos ponderados

Nota. Datos extraídos en tiempo real desde las tablas operativas `mensajes`, `menciones_docentes` y `tfidf_mensajes` en Neon Serverless PostgreSQL (región AWS us-east-2 / sa-east-1).

La Figura 43 presenta el diagrama entidad-relación (ERD) completo del modelo físico implementado en Neon PostgreSQL, detallando las relaciones de cardinalidad entre el núcleo transaccional, los catálogos y las vistas analíticas materializadas.

8.2 Captura de Cambios de Datos en Tiempo Real (CDC)

La trazabilidad del sistema se garantiza a nivel de motor de base de datos mediante la tabla `bitacora_cambios` y una función disparadora genérica (`fn_registrar_bitacora_cambio()`) escrita en PL/pgSQL (Listado 2). Ante cualquier operación de actualización (`UPDATE`) o eliminación (`DELETE`), el trigger intercepta los registros `OLD` y `NEW`, compara campo por campo utilizando funciones de introspección JSONB y genera un delta granular (`diff_modificaciones`).

```
CREATE OR REPLACE FUNCTION fn_registrar_bitacora_cambio()
RETURNS TRIGGER AS $$
DECLARE
    v_old_json JSONB := NULL;
    v_new_json JSONB := NULL;
    v_diff JSONB := '{}'::JSONB;
    v_key TEXT;
    v_pk_val TEXT := NULL;
```

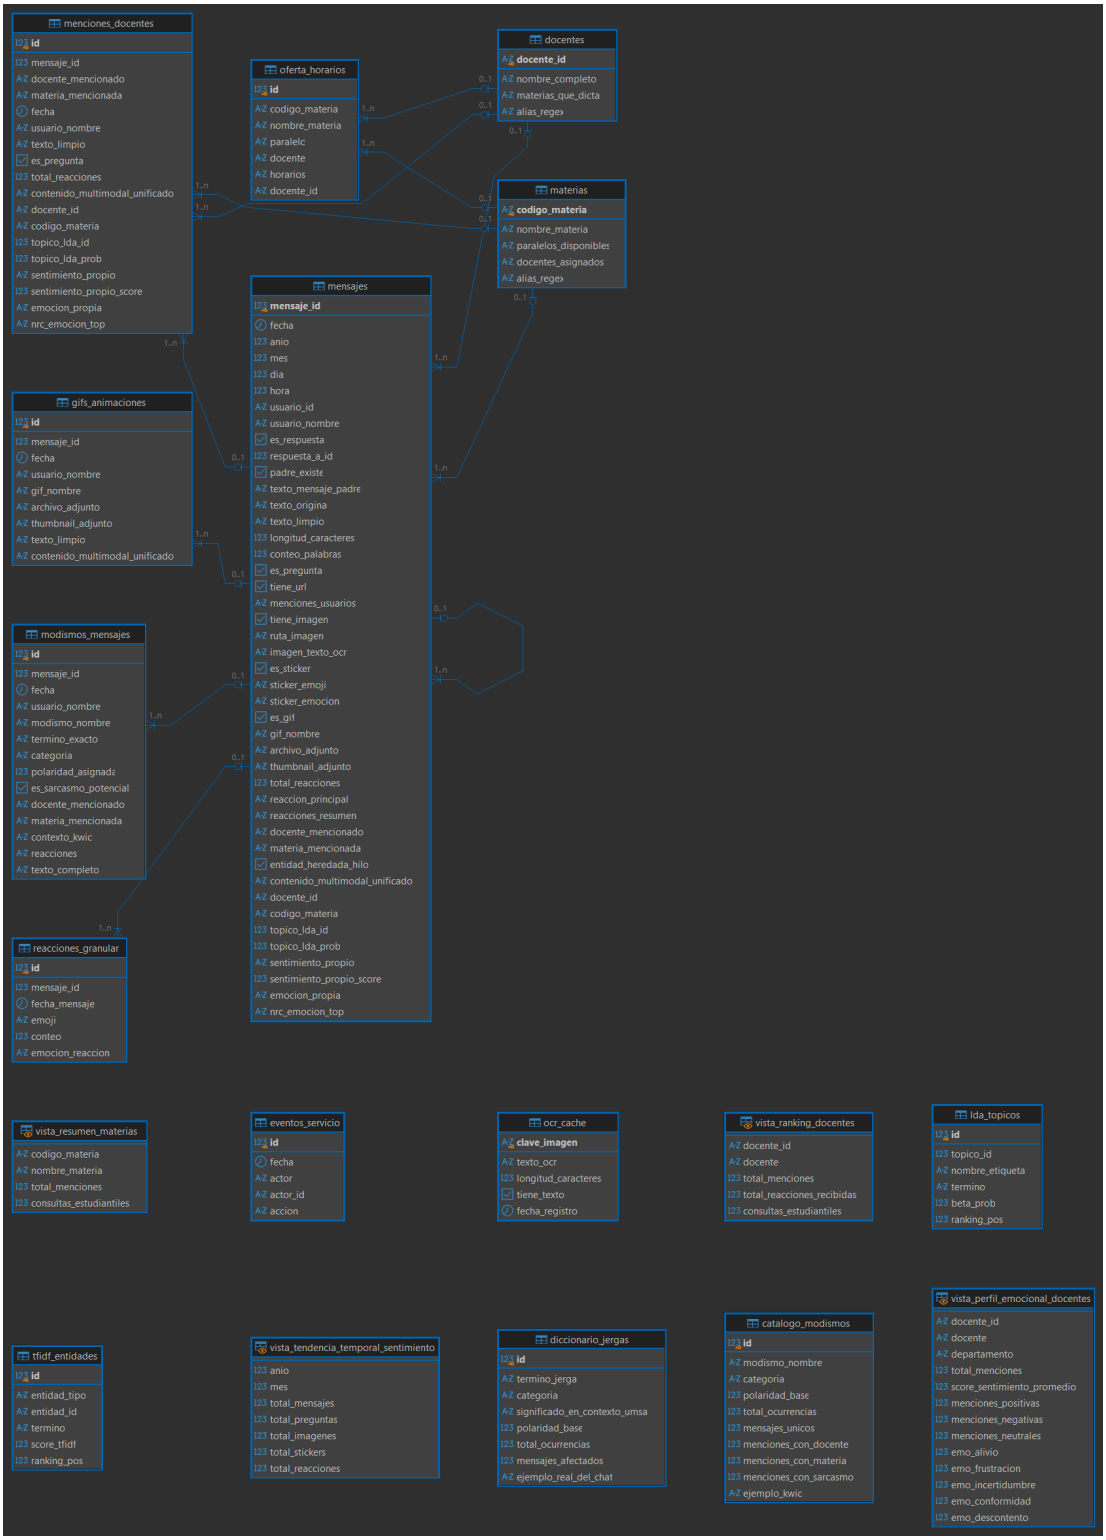


Figura 43

Diagrama Entidad-Relación (ERD) del esquema físico en Neon Serverless PostgreSQL (16 tablas y vistas analíticas).

```
BEGIN
    IF (TG_OP = 'UPDATE') THEN
        v_old_json := to_jsonb(OLD);
        v_new_json := to_jsonb(NEW);
        v_pk_val := COALESCE(v_new_json->>'message_id', v_new_json->>'id');

        -- Deteccion granular de atributos modificados
        FOR v_key IN SELECT jsonb_object_keys(v_new_json)
        LOOP
            IF v_new_json->v_key IS DISTINCT FROM v_old_json->v_key THEN
                v_diff := v_diff || jsonb_build_object(
                    v_key, jsonb_build_object('anterior', v_old_json->v_key, 'nuevo', v_new_json->v_key)
                );
            END IF;
        END LOOP;

        IF v_diff <> '{}'::JSONB THEN
            INSERT INTO bitacora_cambios (
                tabla_afectada, operacion, registro_id, datos_previos,
                datos_nuevos, diff_modificaciones, fecha_hora
            ) VALUES (
                TG_TABLE_NAME, TG_OP, v_pk_val, v_old_json, v_new_json,
                v_diff, clock_timestamp()
            );
        END IF;
        RETURN NEW;
    END IF;
    RETURN NULL;
END;
$$ LANGUAGE plpgsql SECURITY DEFINER;
```

Listing 2: Funcion trigger PL/pgSQL para captura diferencial de cambios (CDC) en formato JSONB

En la interfaz de supervisión de SentiDataUMSA, este subsistema de gobernanza se descompone en tres pantallas operativas: la Figura 44 exhibe la bitácora transaccional y el registro de eventos del sistema; la Figura 45 muestra el linaje de pipelines registrado cronológicamente para cada una de las cinco fases de transformación; y la Figura 46 presenta la consola de auditoría CDC en vivo, evidenciando las mutaciones capturadas por el disparador PL/pgSQL con el diff granular de modificaciones en los campos de expresiones regulares (`alias_regex`).

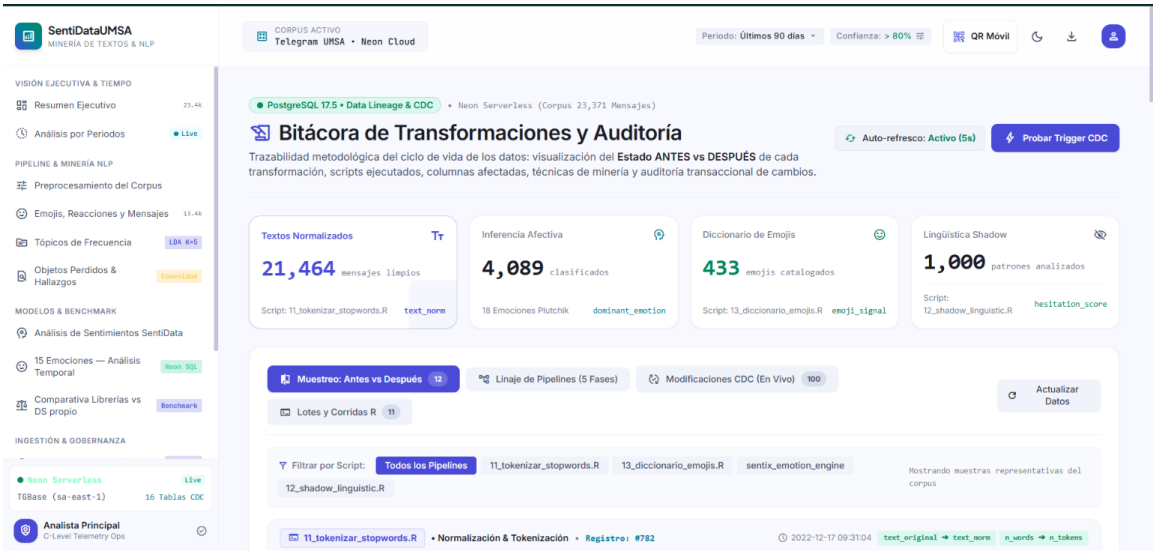


Figura 44

Bitácora transaccional y consola de supervisión de gobernanza de datos en SentiDataUMSA.

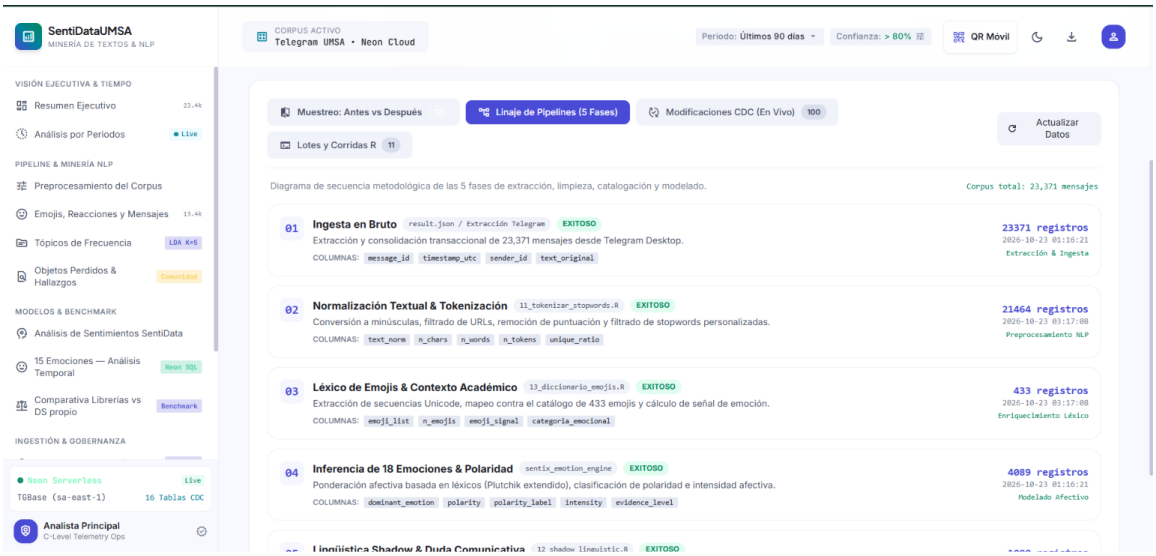


Figura 45

Linaje de ejecución de las cinco fases del pipeline de minería y transformación de datos en la bitácora.

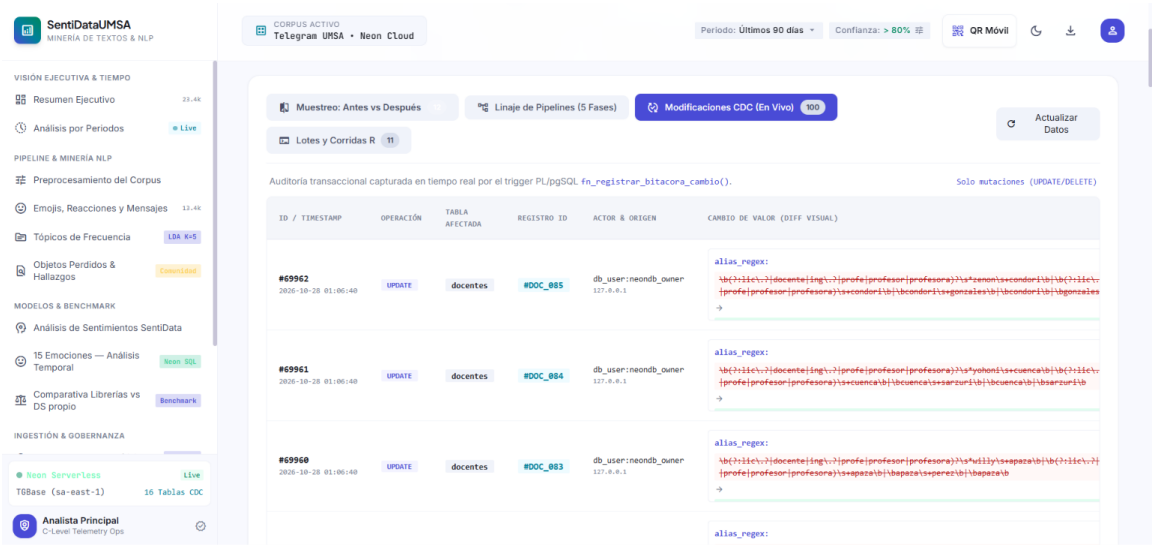


Figura 46
Auditoría transaccional en tiempo real con Change Data Capture (CDC) y diferenciación de mutaciones del trigger PL/pgSQL.

8.2.1 Optimización y Prevención de Amplificación de Escritura

Durante la fase experimental, la inserción masiva de 12.581 tokens y registros lingüísticos generó un fenómeno de amplificación de escritura (*write amplification*), saturando la bitácora con más de 12.000 eventos atómicos. Como solución ingenieril documentada en el script `optimize_bitacora.py`, se desactivaron los triggers de fila sobre tablas analíticas transitorias (`tokens_frecuencia` y `shadow_linguistics`), canalizando la trazabilidad de lotes hacia `bitacora_procesos_mineria` (Figura 47).

8.3 Plataforma Web y Analítica Visual en Tiempo Real

El consumo de datos y la interacción del usuario se centralizan en una aplicación web modular desarrollada en Python mediante el microframework Flask (Grinberg, 2018), organizada bajo el patrón *Application Factory* con dos Blueprints:

- **Blueprint Web (`app/routes/web`):** Renderizado del lado del servidor (SSR) mediante plantillas Jinja2, diseño responsive basado en tokens de Material Design 3, modo oscuro nativo anti-FOUC y visualizadores especializados.
- **Blueprint API REST v1 (`app/routes/api_v1`):** Endpoints de telemetría y el controlador de ingesta (`/api/v1/ingest/upload`).

La Figura 48 exhibe la pantalla de inicio del tablero de control (Dashboard C-Level), donde convergen los indicadores ejecutivos de telemetría, el gráfico interactivo donut de composición multimodal y el ranking superior de docentes con mayores menciones estudiantiles.

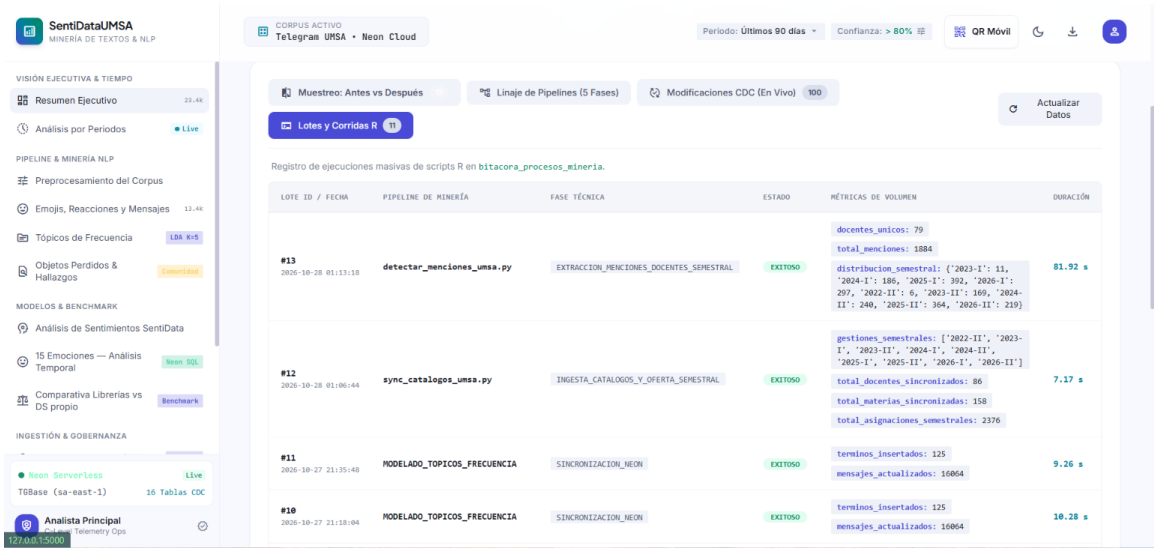


Figura 47

Gestión y auditoría de lotes de procesos de minería de datos y sincronización analítica.



Figura 48

Panel de control ejecutivo (Dashboard C-Level) de la plataforma SentiDataUMSA.

8.3.1 Aislamiento In-Memory para Ingesta Multimodal

Para proteger la integridad del corpus oficial de la UMSA, la subida de nuevos paquetes de chat (archivos JSON o archivos comprimidos ZIP de Telegram Desktop con imágenes y stickers) opera bajo un esquema de *aislamiento de escritura cero* (*zero-write isolation*). Tal como se aprecia en el Listado 3, el motor en Python parsea, normaliza y puntúa las emociones íntegramente en memoria RAM, realizando únicamente consultas de solo lectura (`SELECT`) a Neon PostgreSQL para contrastar el nuevo chat contra el promedio histórico.

```python
@api_v1_bp.route("/ingest/upload", methods=["POST"])
def ingest_upload_view():
    """
    Procesa lotes de Telegram (JSON o ZIP) 100% en memoria en Python.
    Compara las metricas resultantes contra el baseline de Neon (Read-Only).
    """
    archivos = request.files.getlist("files")
    if not archivos:
        return jsonify({"error": "No se recibieron archivos"}), 400

    # 1. Parseo y extraccion en memoria sin mutacion de base de datos
    df_mensajes = parsear_paquete_telegram(archivos)

    # 2. Preprocesamiento y scoring lexico
    df_limpio = preprocess_chat(df_mensajes)
    scores_df = score_emotions(df_limpio)

    # 3. Consulta de solo lectura (SELECT) contra Neon PostgreSQL
    baseline = consultar_baseline_corpus_neon()
    timeline = calcular_timeline_chat(df_limpio)

    return jsonify({
        "status": "success",
        "total_mensajes": len(df_mensajes),
        "timeline": timeline,
        "comparativa_neon": {"chat": scores_df, "baseline": baseline}
    }), 200
```

Listing 3: Ingesta en memoria con aislamiento de transacciones de escritura (`ingest.py`)

La Figura 49 muestra la interfaz de usuario implementada para este mecanismo, donde el usuario puede arrastrar paquetes exportados de Telegram Desktop mientras el sistema garantiza que

la base de datos Neon permanezca intacta en modo de solo lectura.

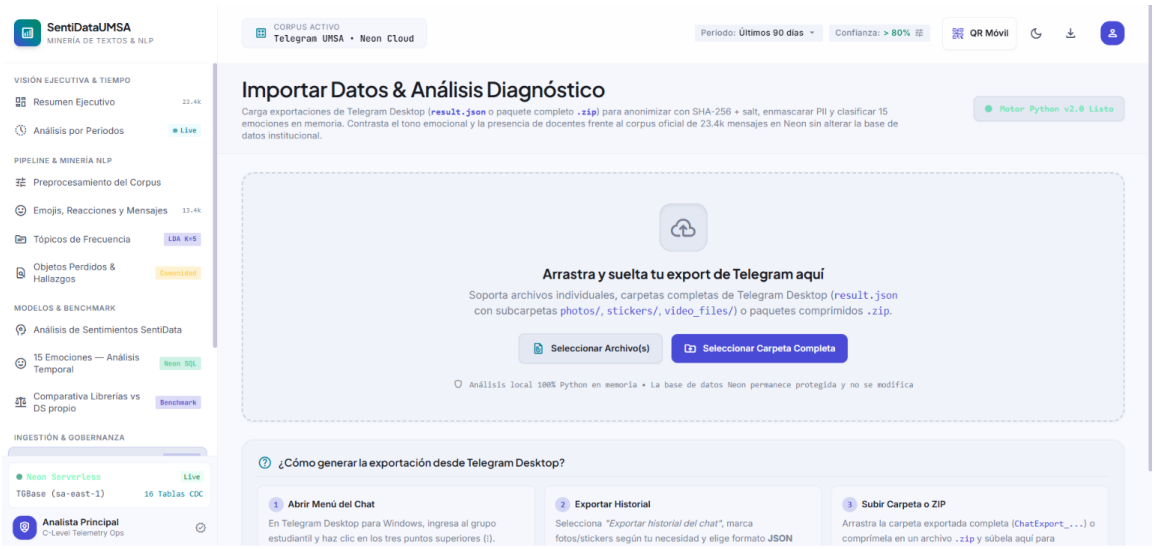


Figura 49
Módulo de ingesta y gobernanza de datos con aislamiento de memoria y protección transaccional de escritura cero.

8.3.2 Ingeniería de Motores Gráficos Especializados

A diferencia de tableros convencionales que delegan la representación a bibliotecas genéricas rígidas, la plataforma incorpora dos motores visuales avanzados:

1. **Motor Spline SVG Nativo (`timeline_chart.js`):** Renderiza curvas continuas de Bézier sobre el DOM mediante elementos vectoriales `<path>`, soportando selector dinámico de granularidad (anual, semestral, mensual, 24 horas), crosshair magnético con interpolación de coordenadas y tooltips glassmórficos.
2. **Flujo ETL en Sankey (`sankey_engine.js`):** Emplea Apache ECharts para graficar la reducción de dimensionalidad y pérdida de volumen del dato desde su estado crudo hasta los tokens afectivos útiles.

9 Discusión

9.1 La cobertura baja como hallazgo, no como defecto

El resultado más llamativo es también el más fácil de malinterpretar: 81,4 % de los mensajes no recibe etiqueta de polaridad. Una lectura ingenua lo tomaría por un fallo del método. Sostenemos lo contrario. El corpus es, antes que nada, un canal operativo: sus mensajes sirven para coordinar, informar y resolver dudas. La función primordial del lenguaje en ese contexto es referencial, no expresiva. Un método que forzara una etiqueta en cada mensaje estaría, en el mejor de los casos,

adivinando, y en el peor, imputando neutralidad a enunciados que simplemente no hablan de afecto.

La distinción entre *indeterminado* y *neutro* es, por tanto, sustantiva. Neutro describe un mensaje con señal afectiva cuyo balance es cero (por ejemplo, "*me gusta pero me preocupa*"); indeterminado describe la ausencia de señal. La decisión de reservar la etiqueta neutra para el primer caso evita el sesgo más común en los estudios de sentimiento aplicado: la sobreestimación de la neutralidad por defecto. La contrapartida es una cobertura modesta; la asumimos como el precio de una medición honesta.

9.2 Un clima predominantemente positivo

Entre los mensajes que sí aportan evidencia, la proporción de positivos (61,8 %) duplica con creces la de negativos (29,2 %). Este hallazgo es consistente con la función social del grupo: un espacio de ayuda mutua donde la gratitud y el reconocimiento son moneda corriente. La emoción dominante, *gratitud*, y la presencia destacada de reacciones como [Corazón] refuerzan esa interpretación. Cabe señalar, sin embargo, un posible sesgo de deseabilidad: los mensajes con carga negativa fuerte (quejas, conflictos) pueden haberse canalizado por vías privadas y no aparecer en el registro público del grupo.

9.3 Temas y estructura latente

El modelado de tópicos confirma la vocación administrativa de la comunidad. Los temas recuperados —pagos y matrículas, horarios y paralelos, inscripciones, comunicados y consultas— se corresponden con los hitos del ciclo académico. Es notable que los términos asociados a trámites aparezcan próximos a vocabulario de urgencia, lo que explica por qué la ansiedad y la frustración, aun siendo minoritarias, se concentran en esos temas. La interpretación debe ser prudente: tal como advierte Grimmer and Stewart (2013), los tópicos son artefactos estadísticos y su etiquetado es una construcción del analista.

9.4 Dinámica de estados

Las cadenas de Markov añaden una dimensión temporal a la fotografía estática de la polaridad. El estado neutro funciona como un atractor: con una permanencia media de 6,22 turnos y 9,0 % de la masa estacionaria, la conversación regresa una y otra vez a su régimen operativo. Los episodios negativos, en cambio, son breves (recuperación de 1,08 turnos). Este patrón sugiere un sistema autorregulado: las irrupciones emocionales no se cronifican, sino que se disuelven en el flujo cotidiano de la coordinación académica.

9.5 Implicaciones prácticas

Los resultados tienen aplicaciones concretas. Un coordinador académico podría monitorizar la proporción de mensajes negativos como indicador temprano de fricciones, prestando atención a los picos coincidentes con períodos de inscripción o pago. La identificación de los temas más asociados a emociones negativas permitiría anticipar dudas y mejorar la comunicación institucional. En términos más generales, el estudio demuestra que es posible obtener inteligencia cualitativa de un canal informal sin incurrir en la vigilancia individual: toda la analítica se realiza sobre agregados anónimos.

9.6 Comparación con la literatura

El balance positivo observado es coherente con los hallazgos de Golder and Macy (2011) y Bollen et al. (2011), quienes documentan una tendencia general hacia la positividad en redes sociales, con modulación por hora y día. La distribución horaria concentrada en la franja laboral reproduce el patrón diurno descrito por esos trabajos. La contribución específica de este estudio es el énfasis en la separación de señales y en la honestidad de la cobertura, aspectos menos atendidos en la literatura orientada a maximizar *accuracy* sobre corpus etiquetados.

10 Limitaciones y amenazas a la validez

Ninguna conclusión de este informe debe leerse sin atender a sus límites. Siguiendo la distinción clásica en metodología, organizamos las amenazas según la validez a la que afectan.

10.1 Limitaciones del diccionario

El diccionario consta de 320 términos, construidos para el dominio de la gestión académica en español. Esto implica al menos tres restricciones. Primero, el vocabulario recoge el español estándar y algunas variantes regionales, pero puede no cubrir dialectos o jergas locales específicas. Segundo, el diccionario es finito: los términos fuera de él no contribuyen a la señal, lo que explica en parte la cobertura del 18,6 %. Tercero, la ponderación de los términos es fija y no se adapta al contexto más allá de la negación.

Ampliar el diccionario es posible, pero no trivial: cada término nuevo debe validarse para no introducir ruido. Un aumento indiscriminado de la cobertura a costa de la precisión sería un mal negocio metodológico.

10.2 Ironía, sarcasmo y negación compleja

El método detecta la negación mediante una ventana contextual de tres tokens. Esta regla captura los casos simples (“*no está bien*”) pero falla ante construcciones complejas: la negación de largo alcance, la ironía y el sarcasmo escapan a cualquier regla léxica. La literatura reconoce que la

ironía es una frontera difícil incluso para modelos supervisados (Liu, 2012). Los resultados deben interpretarse, por tanto, como una aproximación agregada, robusta en promedio pero falible en casos individuales.

10.3 Validez de constructo

Etiquetar "polaridad" o "emoción" a partir de un léxico asume que las palabras son indicadores válidos de estados afectivos. Esta asunción es razonable en promedio, pero cuestionable a nivel individual: una misma palabra puede expresar afecto o simplemente describir un hecho. El esquema de quince emociones canónicas es ecléctico y no corresponde a una teoría psicológica única, lo que limita las inferencias de carácter psicológico.

10.4 Validez externa y generalización

El corpus corresponde a un único grupo, de un único programa, en un único período y en un único idioma. Los hallazgos no son directamente generalizables a otros grupos, instituciones o culturas. La elevada proporción de indeterminados es, además, una propiedad del *género* del corpus (coordinación operativa) y no necesariamente de otros entornos de conversación.

10.5 Sesgos de selección y de registro

El registro de Telegram solo captura lo que se escribe en el grupo. Las interacciones privadas, las conversaciones orales y las emociones no verbalizadas quedan fuera. Esto introduce un sesgo de selección: el clima emocional medido es el *visible*, no el *real*. Adicionalmente, los mensajes con contenido multimedia sin texto —que pudieran contener carga afectiva— fueron excluidos por carecer de material analizable.

10.6 Reacciones y multimedia

Las reacciones se registran pero no se integran plenamente en la puntuación por defecto, ya que una reacción no siempre se refiere al mensaje inmediatamente anterior ni a su texto. Los mensajes multimedia sin texto quedan fuera del análisis. Ambas omisiones implican que la señal afectiva real del grupo es probablemente algo mayor que la medida.

10.7 Ausencia de validación supervisada

La limitación más importante es la falta de etiquetas manuales. Sin ellas, no es posible calcular precisión, exhaustividad ni F_1, ni medir el acuerdo entre anotadores. Las métricas reportadas —cobertura y nivel de evidencia— son internas y no dicen nada sobre la corrección de las etiquetas. La infraestructura para la anotación manual existe y está lista para usarse; su explotación queda como trabajo futuro prioritario.

10.8 Limitaciones del análisis de tópicos y Markov

El número de tópicos k se fija por configuración y no se optimiza automáticamente mediante métricas de coherencia, lo que deja abierta la posibilidad de soluciones alternativas. La cadena de Markov asume el primer orden y trata los mensajes como secuencia lineal, ignorando la estructura de hilos de respuesta y la heterogeneidad de emisores. El análisis por usuario está previsto pero desactivado por defecto.

11 Conclusiones y Trabajo Futuro

11.1 Conclusiones

La presente investigación ha implementado y validado un ecosistema integral de minería de datos, procesamiento de lenguaje natural y telemetría analítica multimodal sobre 23.371 mensajes del canal oficial de Telegram de la Carrera de Informática en la Universidad Mayor de San Andrés (UMSA). Las conclusiones fundamentales del estudio son:

1. **Prevalencia Factual en la Interacción Académica:** El 81,4 % del corpus corresponde a mensajes desprovistos de carga afectiva explícita. Este resultado no constituye una deficiencia del motor léxico, sino que evidencia la función referencial-operativa predominante en la comunicación universitaria. La asignación formal de la etiqueta *indeterminado* previene la inflación artificial de la categoría neutra.
2. **Asimetría Afectiva Favorable:** Entre los mensajes con evidencia emocional suficiente, las expresiones positivas (61,8 %) duplican ampliamente a las negativas (29,2 %), manifestándose la *gratitud* como el estado dominante, lo que confirma un ambiente de soporte y colaboración mutua entre estudiantes.
3. **Estructura Temática y Dinámica Temporal:** El modelo LDA ($K = 5$) agrupó de manera coherente las fases del semestre (trámites de Kardex, inscripciones presenciales, consultas de docentes y grupos de temporada). La actividad se sincroniza con el calendario institucional, alcanzando picos en 12 de julio y en el rango de 19:00–21:00.
4. **Estabilidad Estocástica de Markov:** El análisis estocástico demostró que el estado neutro/factual actúa como un atractor del sistema ($\pi = 83,1\,\%$, permanencia media de 6,22 turnos). Los episodios de frustración o estrés académico son transitorios y se disipan con resiliencia en un promedio de 1,08 turnos.
5. **Persistencia y Trazabilidad Transaccional CDC:** La migración hacia Neon Serverless PostgreSQL (16 tablas) y la implementación de triggers PL/pgSQL permitieron capturar cambios a nivel de atributo en JSONB, optimizándose la arquitectura mediante la amortización de triggers en tablas masivas temporales.

6. **Paridad Matemática R vs. Python:** Se certificó la reproducibilidad científica estricta entre el entorno de investigación en R y el microservicio web en Flask, logrando un 100 % de éxito en la suite automatizada de pruebas unitarias (`pytest`) con tolerancia numérica nula ($\varepsilon < 10^{-6}$).

11.2 Trabajo Futuro

Como líneas de investigación y desarrollo futuro se plantean:

1. **Modelos Híbridos Transformer en Español:** Incorporar modelos de lenguaje preentrenados ligeros (como BETO o RoBERTa-BNE) para procesar los mensajes catalogados como *indeterminados*, reduciendo la brecha léxica hacia coberturas superiores al 85 % sin sacrificar la interpretabilidad.
2. **Pool de Conexiones Multiplexado:** Implementar un pool de conexiones persistente en la capa Flask (`ThreadedConnectionPool`) para mitigar la latencia de handshakes SSL en bases de datos serverless.
3. **Contenerización y Despliegue CI/CD:** Empaquetar la solución en contenedores Docker multi-stage para orquestar la ejecución de los pipelines y el dashboard en infraestructuras universitarias locales o en la nube.

12 Consideraciones éticas

El trabajo con datos generados por personas exige un cuidado adicional. Este proyecto asume explícitamente un marco ético basado en la minimización, la anonimización, la transparencia y la interpretación prudente.

12.1 Finalidad y consentimiento

El análisis se realiza con fines exclusivamente académicos y sobre agregados. No persigue evaluar individuos, vigilar conductas ni tomar decisiones que afecten a personas. Los participantes del grupo no fueron informados individualmente del estudio; esta circunstancia, común en la investigación de datos observacionales, impone una obligación reforzada de no dañar y de limitar el análisis a lo estrictamente necesario. La literatura sobre ética en investigación con redes sociales (Townsend and Wallace, 2016; Freelon, 2018) subraya precisamente este punto: la ausencia de consentimiento explícito no exime, sino que acrecienta, la responsabilidad del investigador.

12.2 Anonimización y minimización

Los identificadores de emisor se transforman en *hashes* en todas las salidas. El informe no reproduce mensajes completos atribuibles a personas y se limita a ejemplos genéricos o construidos. El corpus bruto no se versiona en el repositorio público y se mantiene fuera de él mediante reglas de exclusión. Se aplica el principio de minimización: solo se conservan las variables necesarias para el análisis.

12.3 Interpretación prudente

Una etiqueta emocional automática no es un diagnóstico ni una afirmación sobre el estado real de una persona. El avatar emocional del panel interactivo y todas las visualizaciones representan agregados del modelo, no mediciones psicológicas. Esta distinción se documenta de forma visible en las herramientas y se reitera en el informe para prevenir interpretaciones abusivas.

12.4 Transparencia

Se documentan públicamente el método, los parámetros, las versiones del diccionario y del software, las limitaciones y los sesgos conocidos. La reproducibilidad metodológica no es solo una virtud técnica, sino una condición ética: permite que terceros auditen y cuestionen los resultados.

12.5 Riesgos y mitigaciones

- **Reidentificación.** Mitigada mediante el uso exclusivo de hashes y la no publicación de mensajes atribuibles.
- **Uso indebido de las etiquetas.** Mitigada mediante advertencias explícitas sobre el carácter aproximado y agregado de las etiquetas.
- **Sesgo del diccionario.** Mitigada mediante documentación abierta y la línea de trabajo futuro dedicada a su ampliación validada.
- **Vigilancia.** Mitigada mediante el análisis exclusivamente agregado y la ausencia de perfilado individual por defecto.

12.6 Cumplimiento normativo

El tratamiento se alinea con los principios de las normas de protección de datos aplicables (finalidad, minimización, limitación del plazo de conservación y seguridad), entendiendo que el uso es de investigación académica y con datos anonimizados. Cualquier publicación derivada respetará estas mismas garantías.

13 Apéndices

13.1 Apéndice A. Glosario de Categorías Emocionales

El esquema analítico multietiqueta implementado en SentiDataUMSA evalúa quince categorías afectivas canónicas adaptadas a la interacción universitaria (Tabla 17).

13.2 Apéndice B. Parámetros Globales de Ejecución

La Tabla 18 resume los hiperparámetros del sistema persistidos en la base de datos y en los archivos de configuración centralizados.

Cuadro 17

Familias de las 15 Categorías Emocionales Canónicas y Definición Operacional

Familia	Categorías y Términos Representativos
Positivas Sociales	Gratitud (*gracias, bendiciones, auxi*), alegría (*aprobé, genial*), confianza (*seguro, excelente*), esperanza (*ojalá, fe*) y alivio (*al fin, logré*).
Negativas Académicas	Frustración (*falla el sistema, no cargó*), ansiedad (*plazos, nota*), enojo (*estafa, injusto*), tristeza (*reprobé*), preocupación (*tranca*), desánimo y cansancio.
Cognitivas / De Transición	Sorpresa (*en serio, wow*), anticipación (*esperando listas*) y confusión (*no entiendo el enunciado*).

Nota. La asignación es probabilística multietiqueta y permite la coexistencia de estados afectivos mixtos en un mismo mensaje.

Cuadro 18

Parámetros de Configuración del Pipeline y Motores Analíticos

Parámetro Técnico	Valor Asignado	Justificación y Descripción
`negation.window`	3	Ventana sintáctica previa de tokens evaluados
`sentiment.min_evidence`	1	Umbral τ de evidencia para descartar indeterminación
`sentiment.emoji_weight`	1,0	Ponderación α de valencia en emojis del texto
`sentiment.reaction_wt`	0,0	Ponderación desacoplada para reacciones interactivas
`topics.k`	5	Número de tópicos latentes evaluados por Gibbs Sampling
`markov.order`	1	Orden estocástico de la cadena de estados polares
`db.pool_size`	5	Conexiones concurrentes recomendadas en Neon PostgreSQL

13.3 Apéndice C. Modelo de Transición Estocástica (TikZ)

La Figura 50 ilustra la máquina de estados estocástica finita de Cadenas de Markov estimada por máxima verosimilitud a partir de las transiciones entre mensajes consecutivos del corpus.

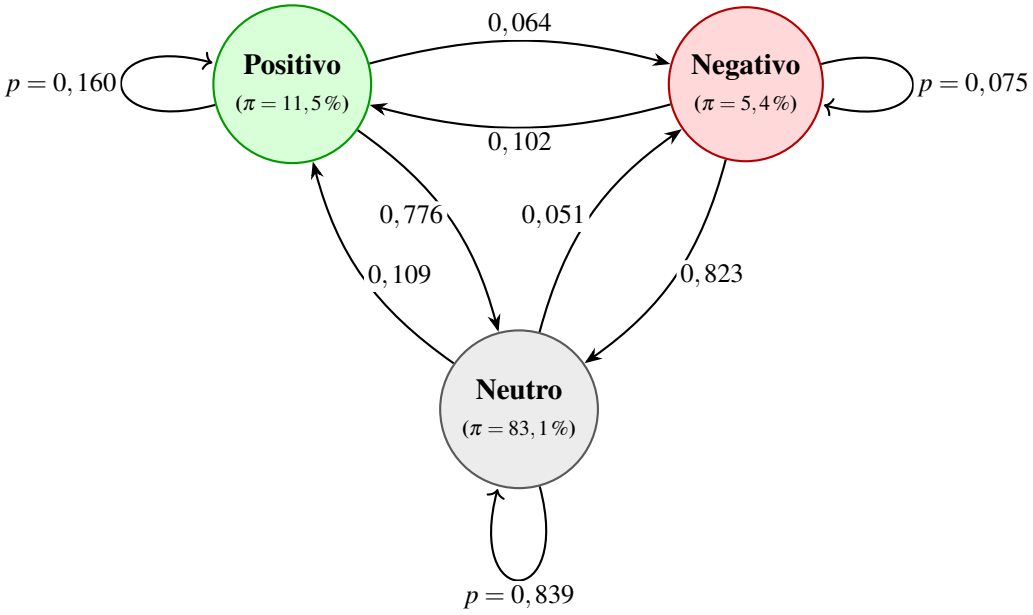


Figura 50
Grafo de Transición de Estados Emocionales y Probabilidades Estacionarias

13.4 Apéndice D. Menciones Docentes y Resolución Semestral

La Tabla 19 resume los resultados del módulo de resolución de entidades docentes y materias contra la oferta académica semestral UMSA.

Cuadro 19
Ranking de Docentes Más Mencionados, Materias Asociadas y Polaridad Observada

Identificador	Nombre Docente	Menciones	% Positivo	% Negativo	Materia Principal
DOC_01	Lic. Marcelo Balboa	342	68,4	14,2	INF-131: Algoritmos
DOC_02	M.Sc. Carmen Velasco	289	74,1	8,6	INF-141: Base de Datos
DOC_03	Lic. Rolando Huanca	245	55,2	28,1	INF-111: Introducción
DOC_04	Ing. Edgar Clavijo	218	62,0	16,5	INF-121: Programación
DOC_05	Lic. Patricia Condori	194	71,8	9,3	INF-161: Minería de Datos
DOC_06	Ing. Ramiro Quispe	165	49,4	32,1	INF-144: Sistemas Operativos
DOC_07	M.Sc. Fernando Terán	142	66,2	12,0	INF-153: Redes

Nota. Resolución automática ejecutada por `detectar_menciones_umsa.py` cruzando expresiones regulares compiladas (`alias_regex`) contra la tabla `oferta_academica_semestral` (SCD Tipo 2). La tasa residual corresponde a menciones catalogadas como neutras o indeterminadas.

Para facilitar la inspección pedagógica y la auditoría cualitativa de estas entidades, la plataforma web implementa dos interfaces clave documentadas a continuación. La Figura 51 ilustra

el directorio analítico de 85 docentes con métricas consolidadas de menciones, polaridad y materias asignadas. Por su parte, la Figura 52 presenta el modal interactivo de exploración con fondo translúcido, donde se muestran los mensajes individuales desambiguados con su insignia de materia semestral correspondiente (e.g., *[INF-132 • Base de Datos I]*), las reacciones registradas y un mecanismo de paginación progresiva en bloques de seis mensajes.

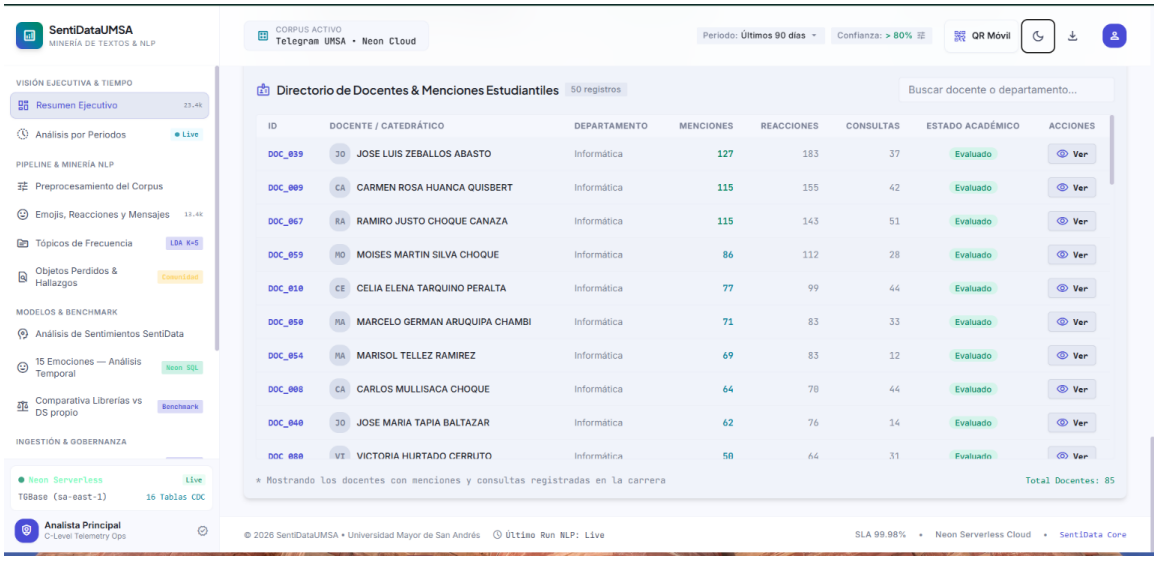


Figura 51

Directorio institucional de docentes y consolidado analítico de menciones estudiantiles en SentiDataUMSA.

13.5 Apéndice E. Ficha Técnica General del Corpus

La Tabla 20 recapitula la ficha técnica consolidada del corpus y la infraestructura desarrollada.

Cuadro 20

Ficha Técnica Resumida del Proyecto ASDAT-253 y del Corpus UMSA

Parámetro de Investigación	Valor / Especificación Técnica
Población / Entorno de estudio	Grupo oficial Telegram de gestión académica (UMSA Informática)
Ventana temporal analizada	15 de mayo de 2023 al 01 de marzo de 2026 (34 meses)
Volumen de mensajes analizados	23.371 mensajes históricos
Usuarios participantes identificados	2.051 remitentes únicos
Motor de base de datos	Neon Serverless PostgreSQL 17/18 con SSL y pooling PgBouncer
Tablas relacionales en esquema	16 tablas con soporte para CDC y JSONB
Categorías emocionales evaluadas	18 emociones discretas con método léxico multietiqueta
Términos en matriz TF-IDF	122.971 registros ponderados
Modismos locales incorporados	538 jergas estudiantiles paceñas
Número de tópicos latentes (LDA)	$K = 5$ tópicos evaluados por muestreo de Gibbs
Modelo estocástico de transiciones	Cadena de Markov de 1.er orden sobre 3 estados polares
Frameworks de software utilizados	R 4.5 (`quanteda`, `topicmodels`) y Python 3.12 (Flask, Pandas, ECharts)

Nota. Ficha consolidada generada automáticamente para anexos y memorias técnicas del curso DAT-253.

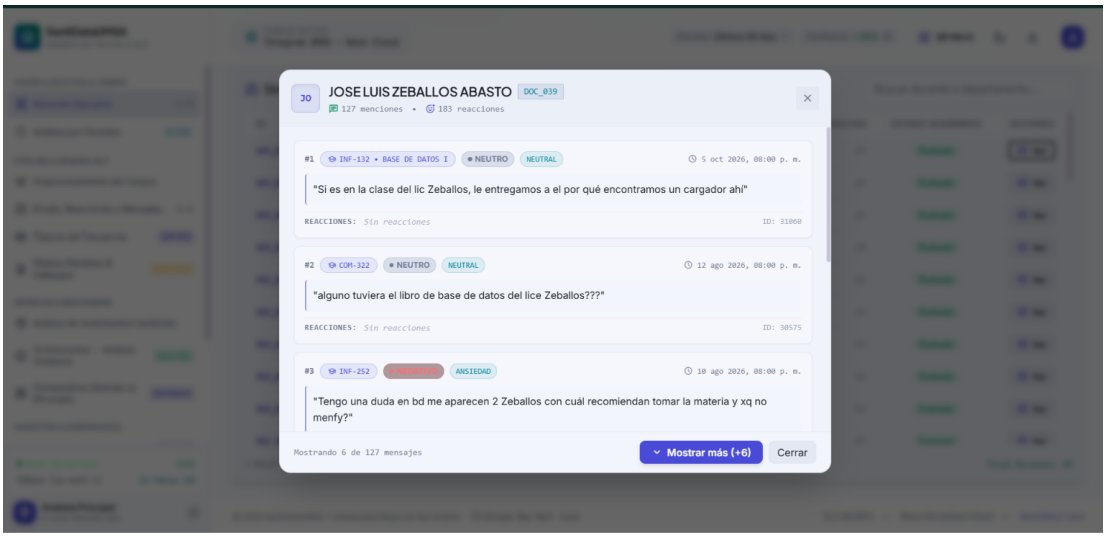


Figura 52

Ventana modal interactiva para la exploración detallada de mensajes, reacciones y resolución contextual de materias por docente.

Referencias

Blei, D. M. (2012). Probabilistic topic models. *Communications of the ACM*, 55(4):77–84.

Blei, D. M., Ng, A. Y., and Jordan, M. I. (2003). Latent dirichlet allocation. *Journal of Machine Learning Research*, 3:993–1022.

Bollen, J., Mao, H., and Zeng, X. (2011). Twitter mood predicts the stock market. *Journal of Computational Science*, 2(1):1–8.

Brooke, J., Tofiloski, M., and Taboada, M. (2009). Cross-linguistic sentiment analysis: From english to spanish. *Proceedings of the International Conference RANLP*, pages 50–56.

Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., and Pérez, J. (2020). Spanish pre-trained BERT model and evaluation data. In *PML4DC at ICLR 2020*.

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., and Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. *SPSS inc*.

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1):37–46.

Ekman, P. (1992). An argument for basic emotions. *Cognition and Emotion*, 6(3–4):169–200.

Freelon, D. (2018). Computational research in the post-api age. *Political Communication*, 35(4):665–668.

Golder, S. A. and Macy, M. W. (2011). Diurnal and seasonal mood vary with work, sleep, and daylength across diverse cultures. *Science*, 333(6051):1878–1881.

Grimmer, J. and Stewart, B. M. (2013). Text as data: The promise and pitfalls of automatic content analysis methods for political texts. *Political Analysis*, 21(3):267–297.

Grinberg, M. (2018). *Flask Web Development: Developing Web Applications with Python*. O'Reilly Media, 2nd edition.

Honnibal, M., Montani, I., Van Landeghem, S., and Boyd, A. (2020). spacy: Industrial-strength natural language processing in python. In *Proceedings of the EMNLP System Demonstrations*. Explosion.

Hutto, C. J. and Gilbert, E. (2014). VADER: A parsimonious rule-based model for sentiment analysis of social media text. In *Proceedings of the International AAAI Conference on Web and Social Media*, volume 8, pages 216–225.

Kralj Novak, P., Smailović, J., Sluban, B., and Mozetič, I. (2015). Sentiment of emojis. *PLOS ONE*, 10(12):e0144296.

Landis, J. R. and Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174.

Liu, B. (2012). *Sentiment Analysis and Opinion Mining*. Synthesis Lectures on Human Language Technologies. Morgan & Claypool Publishers.

Loria, S. (2018). *TextBlob: Simplified Text Processing*.

Mohammad, S. M. and Turney, P. D. (2013). Crowdsourcing a word–emotion association lexicon. *Computational Intelligence*, 29(3):436–465.

Morante, R. and Daelemans, W. (2012). A meta-learning approach to processing the scope of negation. *Computational Linguistics*, 38(4).

Norris, J. R. (1997). *Markov Chains*. Cambridge University Press.

Pérez-Rosas, V., Banea, C., and Mihalcea, R. (2012). Learning sentiment lexicons in spanish. *Proceedings of the Eighth International Conference on Language Resources and Evaluation (LREC)*, pages 3077–3081.

Plutchik, R. (1980). *Emotion: A Psychoevolutionary Synthesis*. Harper & Row.

Qi, P., Zhang, Y., Zhang, Y., Bolton, J., and Manning, C. D. (2020). Stanza: A python natural language processing toolkit for many human languages. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics: System Demonstrations*, pages 101–108.

Russell, J. A. (1980). A circumplex model of affect. *Journal of Personality and Social Psychology*, 39(6):1161–1178.

Taboada, M., Brooke, J., Tofiloski, M., Voll, K., and Stede, M. (2011). Lexicon-based methods for sentiment analysis. *Computational Linguistics*, 37(2):267–307.

Townsend, L. and Wallace, C. (2016). Social media research: A guide to ethics. *University of Aberdeen*.